École Nationale Supérieure

Apprentissage Probabiliste

RAPPORT DE PROJET

Modélisation du Comportement Utilisateur en E-Commerce

Dataset	Yoochoose — RecSys Challenge 2015
Sessions	100 000 sessions de navigation anonymes
Réalisé par	Btissam Arehal
Encadré par :	Prof. Abdellatif El Afia
Année	2025–2026

Mai 2026

Table des matières

1 Introduction Générale **5**
1.1 Contexte . . . 5
1.2 Dataset Yoochoose . . . 5
1.3 Espace d'états comportementaux . . . 5

2 Chapitre 1 : Chaîne de Markov à Temps Discret (DTMC) **6**
2.1 Description du dataset . . . 6
2.2 Pertinence pour la modélisation markovienne . . . 6
2.3 Processus Stochastique et Espace d'États . . . 6
2.3.1 Processus stochastique à temps discret . . . 6
2.4 Définition des 5 états comportementaux . . . 7
2.5 Types d'états : transitoires et absorbants . . . 7
2.5.1 Exemples concrets d'états et de transitions . . . 8
2.6 Propriété de Markov . . . 8
2.6.1 Définition formelle . . . 8
2.6.2 Justification dans le contexte Yoochoose . . . 8
2.6.3 Homogénéité temporelle . . . 9
2.7 Matrice de Transition . . . 9
2.7.1 Définition . . . 9
2.7.2 Comptages bruts (100 000 sessions) . . . 9
2.7.3 Matrice **P** normalisée . . . 10
2.8 Équation de Chapman-Kolmogorov . . . 10
2.9 Classification des États et de la Chaîne . . . 11
2.9.1 Accessibilité et communication . . . 11
2.9.2 Classes de communication . . . 12
2.9.3 Apériodicité . . . 12
2.9.4 Conclusion : nature de la chaîne . . . 13
2.10 Forme Canonique . . . 13
2.10.1 Matrice **Q** — transitions entre transitoires . . . 13
2.10.2 Matrice **R** — transitions vers absorbants . . . 13
2.10.3 Matrice Fondamentale **N** . . . 13
2.10.4 Calcul . . . 14
2.11 Probabilités d'Absorption **B** . . . 14
2.11.1 Développement détaillé — ligne Browsing . . . 15
2.11.2 Résultat complet . . . 15
2.12 Distribution Initiale et Évolution . . . 15
2.12.1 Graphe d'évolution . . . 16
2.12.2 Comportement Asymptotique . . . 16
2.12.3 Distribution stationnaire . . . 16
2.13 Vitesse de convergence . . . 17
2.14 Analyse Économique et Recommandations . . . 17
2.14.1 Tableau de bord KPIs . . . 17
2.14.2 Tunnel de conversion . . . 18
2.14.3 Recommandations stratégiques . . . 18
2.15 Conclusion . . . 19
2.15.1 Récapitulatif . . . 19
2.15.2 Bilan . . . 19

3 Chapitre 2 : Chaîne de Markov à Temps Continu (CTMC) 20
3.1 Introduction . . . 20
3.2 Problématique du Projet . . . 20
3.3 Objectifs du Chapitre . . . 20
3.4 Interprétation du Dataset . . . 21
3.5 Prétraitement des Horodatages . . . 21
3.6 Définition des États . . . 21
3.7 Définition Formelle . . . 22
3.8 Matrice Génératrice $\hat{\mathbf{Q}}$ . . . 22
3.8.1 Définition et Propriétés . . . 22
3.8.2 Estimateur MLE . . . 22
3.8.3 Temps Totaux . . . 23
3.9 Matrice Estimée . . . 23
3.10 Interprétation Probabiliste du Modèle . . . 23
3.11 Diagramme des États . . . 24
3.12 Probabilités de Saut (Chaîne Embedded) . . . 24
3.13 Équations de Kolmogorov et $\mathbf{P}(t)$ . . . 25
3.13.1 Équations de Kolmogorov . . . 25
3.13.2 Résultats Numériques . . . 25
3.13.3 Analyse Temporelle et Implications Business . . . 26
3.14 Temps Moyen dans les États . . . 27
3.14.1 Analyse Comportementale du Temps de Séjour . . . 27
3.15 Temps Moyen Avant Absorption . . . 27
3.15.1 Matrice Fondamentale Estimée . . . 28
3.15.2 Temps Moyen Avant la Fin de Session . . . 28
3.16 Probabilités Finales d'Achat . . . 28
3.17 Vérification de la Loi Exponentielle . . . 29
3.17.1 Test de Kolmogorov-Smirnov . . . 29
3.18 Applications Pratiques du Modèle . . . 30
3.19 Résultats principaux . . . 30

4 Chapitre 3 : Modèles de Markov Cachés (HMM) 31
4.1 Motivation . . . 31
4.2 Formalisme HMM . . . 31
4.3 HMM Discret . . . 31
4.3.1 Observations et paramètres . . . 31
4.3.2 Algorithme Forward . . . 32
4.3.3 Algorithme Backward . . . 33
4.3.4 Algorithme Baum-Welch (EM) . . . 34
4.3.5 Algorithme de Viterbi . . . 35
4.4 HMM Continu (Gaussien) . . . 36
4.4.1 Formulation . . . 36
4.4.2 Paramètres appris par Baum-Welch continu . . . 36
4.5 Synthèse HMM discret vs continu . . . 37
4.6 Synthèse Générale et Recommandations Business . . . 37
4.6.1 Tableau de bord des résultats clés . . . 37
4.6.2 Progression des modèles . . . 38
4.6.3 Recommandations stratégiques . . . 38
4.6.4 Limites et perspectives . . . 38
4.7 Conclusion . . . 39

5 Chapitre 4 : Processus de Décision Markovien (MDP) 40

5.1 Introduction et Motivation . . . 40
5.2 Définition Formelle du MDP . . . 40
5.2.1 Tuple (S, A, P, R, γ) . . . 40
5.2.2 Application Yoochoose : Espace d'États . . . 41
5.2.3 Ensemble d'Actions . . . 42
5.2.4 Matrice de Transition $P(s'|s, a)$ . . . 42
5.2.5 Récompenses $R(s, a)$ . . . 43
5.2.6 Facteur d'Actualisation . . . 44
5.3 Équation de Bellman et Fonction de Valeur . . . 44
5.3.1 Fonction de Valeur d'un État . . . 44
5.3.2 Équation de Bellman Optimale . . . 45
5.4 Policy Iteration (Algorithme de Howard) . . . 46
5.4.1 Principe Général . . . 46
5.4.2 Formulation Mathématique . . . 46
5.4.3 Théorème de Convergence . . . 46
5.4.4 Résultats Numériques . . . 47
5.5 Interprétation Économique et Business . . . 48
5.5.1 Justification de Chaque Action . . . 48
5.5.2 Impact de la Politique sur les Taux de Conversion . . . 50
5.6 Résumé et Conclusions . . . 51
5.6.1 Politique Optimale Identifiée . . . 51
5.6.2 Résultats Clés . . . 51
5.6.3 Cohérence avec les Chapitres Précédents . . . 51

6 MDP et Value Iteration **52**
6.1 Value Iteration : L'Algorithme Itératif . . . 52
6.1.1 La Fonction de Valeur . . . 52
6.1.2 Interprétation Dynamique . . . 52
6.2 Application au Dataset Yoochoose : Spécification du MDP . . . 53
6.2.1 Espace d'États . . . 53
6.2.2 Espace d'Actions . . . 53
6.2.3 Matrice de Transition $P(s' \mid s, a)$ . . . 53
6.2.4 Fonction de Récompense $R(s, a)$ . . . 54
6.3 Résultats et Politiques Optimales . . . 54
6.3.1 Convergence Numérique . . . 54
6.3.2 Comparaison des Facteurs d'Actualisation . . . 55
6.3.3 Comparaison avec Policy Iteration . . . 55
6.3.4 Limites et Hypothèses . . . 55
6.3.5 Perspectives : Amélioration et Déploiement . . . 56

7 Apprentissage par Renforcement (Reinforcement Learning) **57**
7.1 Introduction et Contexte du Chapitre . . . 57
7.1.1 Données et Espace des États . . . 57
7.1.2 Actions Marketing et Structure des Récompenses . . . 58
7.2 TD(0) — Différence Temporelle d'Ordre Zéro . . . 58
7.2.1 Fondements Mathématiques . . . 58
7.2.2 Équation de Mise à Jour . . . 59
7.2.3 Propriété de Convergence . . . 59
7.2.4 Résultats et Analyse . . . 59
7.3 TD(λ) — Différence Temporelle avec Traces d'Éligibilité . . . 60
7.3.1 Motivation et Principe . . . 60
7.3.2 Avantages de TD(λ) sur TD(0) . . . 61

7.4 Q-Learning — Apprentissage off-policy . . . 62
7.4.1 Principe et Innovation . . . 62
7.4.2 Équation de Mise à Jour Q-Learning . . . 62
7.4.3 Politique ε-Greedy . . . 62
7.4.4 Q-Table et Politique Optimale . . . 62
7.5 R-Learning — Apprentissage par gain moyen . . . 64
7.5.1 Principe et Innovation . . . 64
7.5.2 Équation de Mise à Jour R-Learning . . . 64
7.5.3 Paramètres d'Apprentissage . . . 64
7.5.4 Évolution du Gain Moyen ρ . . . 65
7.5.5 Q-Table Finale R-Learning . . . 65
7.5.6 Politique Optimale R-Learning . . . 66
7.6 SARSA — State-Action-Reward-State-Action . . . 67
7.6.1 Distinction Fondamentale : On-Policy vs Off-Policy . . . 67
7.6.2 Équation de Mise à Jour SARSA . . . 67
7.6.3 Résultats SARSA . . . 68
7.7 Comparaison Globale des Algorithmes . . . 69
7.8 Interprétation Économique : Le Funnel E-Commerce . . . 69
7.8.1 Modèle de Décision Marketing . . . 69
7.8.2 Recommandations Managériales . . . 69
7.9 Conclusion du Chapitre . . . 70

8 Processus Décisionnels Partiellement Observables (POMDP) 71
8.1 Motivation : De MDP à POMDP . . . 71
8.2 Formalisme POMDP . . . 71
8.3 Belief Update (Filtre Bayésien) . . . 71
8.4 Équation de Bellman pour POMDP . . . 72
8.5 Application Yoochoose : POMDP Classique . . . 72

9 Deep POMDP : Approximation Neuronale 73
9.1 Motivation : Limitation du Belief Exact . . . 73
9.2 Architectures Testées . . . 73
9.2.1 GRU (Gated Recurrent Unit) . . . 73
9.2.2 LSTM (Long Short-Term Memory) . . . 74

10 Non-Markovian POMDP (NM-POMDP) 75
10.1 Motivation : Au-delà de Markov . . . 75
10.2 Modèles NM-POMDP . . . 75
10.3 Résultats Comparatifs . . . 76

11 Conclusion Générale 77

12 Perspectives de Recherche et Déploiement 78

13 Méthodologie 81

14 Ressources Scientifiques 82

1. Introduction Générale

1.1. Contexte

Le commerce électronique génère chaque jour des milliards d'interactions entre utilisateurs et plateformes numériques. Chaque visite produit une **session** : une séquence temporelle d'actions (clics, consultations, ajouts au panier, achats) qui reflète le comportement et l'intention d'achat d'un utilisateur.

Comprendre comment un utilisateur progresse au cours de sa session est essentiel pour :

- améliorer les systèmes de recommandation personnalisée,
- optimiser l'expérience utilisateur,
- augmenter les taux de conversion,
- identifier les fenêtres d'intervention optimales.

1.2. Dataset Yoochoose

Le dataset **Yoochoose** (RecSys Challenge 2015) fournit 100 000 sessions anonymes de navigation e-commerce, composées de séquences de clics sur des items et, pour certaines sessions, d'un achat final.

Fichier	Champ	Description
	`session_id`	Identifiant unique de session
	`timestamp`	Moment de l'interaction (ISO 8601)
	`item_id`	Produit consulté
	`category`	Catégorie du produit
	`session_id`	Session avec achat
	`price`	Prix du produit acheté
	`qty`	Quantité achetée

1.3. Espace d'états comportementaux

Les cinq états modélisant le parcours utilisateur sont définis comme suit :

État	Nom	Condition	Type
s_1	Browsing	$k \leq 2$ clics	Transitoire
s_2	Engaged	$3 \leq k \leq 5$ clics	Transitoire
s_3	HighIntent	$k \geq 6$ clics	Transitoire
s_4	Buy	Session avec achat	Absorbant
s_5	Exit	Session sans achat	Absorbant

La progression générale des utilisateurs suit l'entonnoir :

$$\text{Browsing} \rightarrow \text{Engaged} \rightarrow \text{HighIntent} \rightarrow \{\text{Buy}, \text{Exit}\}$$

2. Chapitre 1 : Chaîne de Markov à Temps Discret (DTMC)

2.1. Description du dataset

TABLE 1 – Caractéristiques du dataset Yoochoose (RecSys Challenge 2015)

Caractéristique	Description	Valeur
Source	RecSys Challenge 2015 — e-commerce anonyme	Public
Fichier `clicks.dat`	Sessions de navigation (clics sur items)	395 698 lignes
Fichier `buys.dat`	Sessions ayant abouti à un achat	509 696 achats
Sessions extraites	Sous-ensemble utilisé pour ce chapitre	100 000
Format clicks	`session_id, timestamp, item_id, category`	CSV
Format buys	`session_id, timestamp, item_id, price, qty`	CSV
Anonymat	Aucun identifiant utilisateur persistant	Oui
Période	6 mois de données réelles e-commerce	2014

2.2. Pertinence pour la modélisation markovienne

Le dataset Yoochoose est particulièrement bien adapté à la modélisation par chaînes de Markov pour plusieurs raisons :

- **Sessions anonymes** : l'absence d'identifiant utilisateur justifie l'hypothèse sans mémoire inter-sessions (propriété de Markov)
- **Séquences d'actions** : les clics successifs dans une session forment une trajectoire naturelle sur l'espace d'états
- **Décision binaire finale** : chaque session se termine par Achat ou Abandon — structure absorbante parfaite
- **Volume suffisant** : 100 000 sessions permettent d'estimer la matrice $\mathbf{P}$ avec une précision statistique élevée

? utilisent également Yoochoose pour évaluer leur modèle GRU4Rec ; notre approche markovienne constitue un *baseline* probabiliste interprétable par rapport à leur approche neuronale.

2.3. Processus Stochastique et Espace d'États

2.3.1. Processus stochastique à temps discret

Définition : *Processus stochastique à temps discret*

Un **processus stochastique à temps discret** est une famille de variables aléatoires $(X_n)_{n\geq 0}$ définies sur un espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$, à valeurs dans un espace d'états S fini ou dénombrable, avec le temps $n \in \mathbb{N}$.

Application Yoochoose :

$$X_n = \text{état comportemental de l'utilisateur à l'étape } n \text{ de sa session}$$

où n représente le rang de l'action courante (clic n) dans la session.

2.4. Définition des 5 états comportementaux

L'espace d'états fini $S = \{\text{Browsing}, \text{Engaged}, \text{HighIntent}, \text{Buy}, \text{Exit}\}$ a été construit à partir d'une analyse comportementale des sessions Yoochoose. Il capture les différentes phases du processus de décision d'achat.

TABLE 2 – Définition formelle et classification des 5 états

État	Condition	Comportement observé	Type	Notation
Browsing	$k \leq 2$ clics	Navigation légère, découverte, peu d'engagement	Transitoire	s_1
Engaged	$3 \leq k \leq 5$	Exploration active, comparaison de produits, intérêt croissant	Transitoire	s_2
HighIntent	$k \geq 6$ clics	Forte intention d'achat, navigation ciblée, hésitation prolongée	Transitoire	s_3
Buy	session $\in$ `buys`	Achat effectué, conversion réussie, fin de session	**Absorbant**	s_4
Exit	session $\notin$ `buys`	Abandon, départ sans achat, non-conversion	**Absorbant**	s_5

2.5. Types d'états : transitoires et absorbants

Définition : *État transitoire*

Un état $i \in S$ est **transitoire** si la probabilité de ne jamais y revenir après l'avoir quitté est strictement positive :

$$f_{ii} = \mathbb{P}(\exists\, n \geq 1 : X_n = i \mid X_0 = i) < 1$$

Autrement dit, un état transitoire sera visité un nombre *fini* de fois avant d'être quitté définitivement.

Définition : *État absorbant (persistant)*

Un état i est **absorbant** (ou persistant récurrent) si :

$$p_{ii} = 1 \quad \Leftrightarrow \quad f_{ii} = 1 \quad \Leftrightarrow \quad \text{le processus ne peut plus quitter } i$$

TABLE 3 – Classification détaillée : transitoires vs absorbants

État	Type	p_{ii}	f_{ii}	Justification
Browsing	Transitoire	0.4836	< 1	Peut devenir Engaged, Buy ou Exit
Engaged	Transitoire	0.5233	< 1	Peut devenir HighIntent, Buy ou Exit
HighIntent	Transitoire	0.8069	< 1	Peut devenir Buy ou Exit (fort taux de persistance)
Buy	**Absorbant**	1.0000	$= 1$	Fin de session — achat impossible à annuler
Exit	**Absorbant**	1.0000	$= 1$	Fin de session — utilisateur quitté définitivement

2.5.1. Exemples concrets d'états et de transitions

Sessions Yoochoose typiques

— **Session courte — Browsing → Exit (abandon rapide)** :
`session 1243 : item_a (clic 1), item_b (clic 2)` → fin sans achat.
⇒ Séquence d'états : Browsing → Browsing → Exit avec $p = 0.4836 \times 0.2315 = 0.112$

— **Session moyenne — Browsing → Engaged → Exit** :
`session 5671 : 4 clics sur des jeans différents, aucun achat.`
⇒ Browsing → Engaged → Engaged → Exit avec $p = 0.2772 \times 0.5233 \times 0.3032 \approx 0.044$

— **Session longue — HighIntent → Buy (conversion)** :
`session 8934 : 8 clics sur le même modèle de chaussures, re-consultation des détails, achat.`
⇒ Browsing → Engaged → HighIntent → $\cdots$ → HighIntent → Buy
Durée typique : 5–8 étapes dans l'état HighIntent ($N_{HH} = 5.18$)

— **Session directe — Browsing → Buy (achat impulsif)** :
`session 2201 : 1 clic, achat direct d'un item en promotion.`
⇒ Browsing → Buy avec $p = 0.007774$ (rare mais existant : 1 505 cas sur 193 656)

2.6. Propriété de Markov

2.6.1. Définition formelle

Définition : *Chaîne de Markov à temps discret (DTMC)*

$(X_n)_{n\geq 0}$ est une **chaîne de Markov à temps discret** (Discrete-Time Markov Chain, DTMC) si et seulement si, pour tout $n \geq 0$ et tous états $i_0, \ldots, i_{n-1}, i, j \in S$:

$$\mathbb{P}(X_{n+1} = j \mid X_n = i,\, X_{n-1} = i_{n-1}, \ldots, X_0 = i_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i) p_{ij}$$

Cette propriété s'appelle la **propriété sans mémoire** (memoryless) ou **propriété de Markov**.

2.6.2. Justification dans le contexte Yoochoose

La propriété de Markov est justifiée dans notre modèle pour les raisons suivantes :

1. **Sessions anonymes** : sans identifiant utilisateur persistant, seul l'état comportemental actuel (nombre de clics dans la session) influence la prochaine action — pas l'historique complet

2. **Comportement local** : la décision d'acheter, de continuer ou de quitter est déterminée par le niveau d'engagement présent, non par toute la séquence passée
3. **Cohérence avec la littérature** : **?** modélisent les sessions comme des séquences sans état latent inter-sessions, ce qui est cohérent avec l'hypothèse markovienne à l'intérieur d'une session

Remarque

Cette hypothèse est une approximation. En réalité, le comportement peut dépendre de l'ordre des items consultés, pas seulement du nombre de clics. Les modèles HMM (Chapitres 3–4) et NARM (**?**) lèvent partiellement cette hypothèse.

2.6.3. Homogénéité temporelle

Définition : *Chaîne de Markov homogène*

La chaîne est **homogène dans le temps** (time-homogeneous) si :

$$p_{ij} = \mathbb{P}(X_{n+1} = j \mid X_n = i) \quad \text{est indépendante de } n$$

Cette hypothèse est justifiée car les probabilités p_{ij} sont estimées sur l'ensemble des 100 000 sessions sans stratification temporelle.

2.7. Matrice de Transition

2.7.1. Définition

Définition : *Matrice de transition stochastique*

La matrice $\mathbf{P} = (p_{ij})_{i,j \in S}$ est une **matrice stochastique en ligne** vérifiant :

$$p_{ij} \geq 0 \ \forall i, j \qquad \text{et} \qquad \sum_{j \in S} p_{ij} = 1 \ \forall i$$

p_{ij} est la probabilité de passer de l'état i à l'état j en une étape (une action dans la session).

2.7.2. Comptages bruts (100 000 sessions)

TABLE 4 – Comptages bruts des transitions observées (395 698 transitions)

De \ Vers	Browsing	Engaged	HighIntent	Buy	Exit	Total
Browsing	93 656	53 673	0	1 505	44 822	193 656
Engaged	0	58 918	17 273	2 260	34 140	112 591
HighIntent	0	0	72 178	2 825	14 448	89 451
Buy	0	0	0	1	0	1
Exit	0	0	0	0	1	1

2.7.3. Matrice P normalisée

TABLE 5 – Matrice de transition $\mathbf{P}$ normalisée par ligne (6 décimales)

p_{ij}	Browsing	Engaged	HighIntent	Buy	Exit
Browsing	**0.483617**	0.277155	0.000003	0.007774	0.231451
Engaged	0.000004	**0.523285**	0.153415	0.020077	0.303219
HighIntent	0.000006	0.000006	**0.806883**	0.031586	0.161520
Buy	0.000000	0.000000	0.000000	**1.000000**	0.000000
Exit	0.000000	0.000000	0.000000	0.000000	**1.000000**

Chaque ligne somme à 1.000000 ✓ (propriété stochastique vérifiée)

Lecture de la matrice P

- $p_{BB} = 0.484$: un utilisateur en Browsing a 48.4% de chance de rester en Browsing au prochain clic (hésitation)
- $p_{BE} = 0.277$: 27.7% de chance de progresser vers Engaged (accroître l'engagement)
- $p_{B,\text{Exit}} = 0.231$: 23.1% d'abandon immédiat depuis Browsing
- $p_{HH} = 0.807$: un utilisateur en HighIntent a 80.7% de chance de rester dans cet état (forte hésitation, opportunité d'intervention pour la recommandation)
- $p_{H,\text{Buy}} = 0.032$: 3.2% de conversion par étape depuis HighIntent

Interprétation économique

Structure triangulaire supérieure : les retours en arrière (Engaged → Browsing, HighIntent → Engaged) ont des probabilités quasi-nulles ($\approx 10^{-6}$), ce qui confirme le caractère *unidirectionnel* du tunnel de conversion. Cette structure est cohérente avec les observations de **?** sur la progressivité des sessions e-commerce.

2.8. Équation de Chapman-Kolmogorov

Théorème : *Équation de Chapman-Kolmogorov*

Pour tous entiers $\ell, m \geq 0$:

$$\mathbf{P}^{(\ell+m)} = \mathbf{P}^{(\ell)} \cdot \mathbf{P}^{(m)} \quad \Longleftrightarrow \quad p_{ij}^{(\ell+m)} = \sum_{k \in S} p_{ik}^{(\ell)}\, p_{kj}^{(m)}$$

En particulier : $\mathbf{P}^{(n)} = \mathbf{P}^{n}$.

Calcul de $p^{(2)}_{\text{Browsing,Buy}}$

En utilisant Chapman-Kolmogorov avec $\ell = m = 1$:

$$\begin{aligned} p^{(2)}_{B,\text{Buy}} &= p_{BB} \cdot p_{B,\text{Buy}} + p_{BE} \cdot p_{E,\text{Buy}} + p_{BH} \cdot p_{H,\text{Buy}} + p_{B,\text{Buy}} \cdot p_{\text{Buy,Buy}} + p_{B,\text{Exit}} \cdot p_{\text{Exit,Buy}} \\ &= 0.4836 \times 0.0078 + 0.2772 \times 0.0201 + 0.0000 \times 0.0316 + 0.0078 \times 1 + 0.2315 \times 0 \\ &= 0.00377 + 0.00557 + 0 + 0.00777 + 0 = \mathbf{0.01711}\checkmark \end{aligned}$$

TABLE 6 – Matrice $\mathbf{P}^2$ — probabilités en 2 étapes

$p^{(2)}_{ij}$	Browsing	Engaged	HighIntent	Buy	Exit
Browsing	0.2340	0.2790	0.0425	0.0171	0.4274
Engaged	0.0000	0.2738	0.2010	0.0294	0.4958
HighIntent	0.0000	0.0000	0.6511	0.0569	0.2920
Buy	0.0000	0.0000	0.0000	1.0000	0.0000
Exit	0.0000	0.0000	0.0000	0.0000	1.0000

TABLE 7 – Probabilités d'achat $p^{(k)}_{\text{Browsing,Buy}}$ par Chapman-Kolmogorov

k	$p^{(k)}_{\text{B,Buy}}$	$p^{(k)}_{\text{B,Exit}}$	Somme absorbée
1	0.007774	0.231451	0.239225
2	0.017098	0.427398	0.444496
3	0.025862	0.573031	0.598893
5	0.039711	0.746487	0.786198
10	0.056964	0.885706	0.942670
20	0.064917	0.928828	0.993745
∞	**0.065912**	**0.934088**	**1.000000**

2.9. Classification des États et de la Chaîne

2.9.1. Accessibilité et communication

Définition : *Accessibilité et communication d'états*

- j est **accessible** depuis i (noté $i \to j$) si $\exists\, n \geq 1 : p^{(n)}_{ij} > 0$
- i et j **communiquent** (noté $i \leftrightarrow j$) si $i \to j$ et $j \to i$
- La relation $\leftrightarrow$ est une **relation d'équivalence** qui partitionne S en **classes de communication**

Vérification d'accessibilité sur Yoochoose

- Buy accessible depuis Browsing : $p^{(1)}_{B,\text{Buy}} = 0.0078 > 0$ ✓
- Exit accessible depuis Engaged : $p^{(1)}_{E,\text{Exit}} = 0.3032 > 0$ ✓
- HighIntent accessible depuis Browsing en 2 étapes : $p^{(2)}_{B,H} = 0.0425 > 0$ ✓
- Browsing **non** accessible depuis Buy : $p^{(n)}_{\text{Buy},B} = 0\ \forall n$ (état absorbant) ×
- Donc Browsing $\not\to$ Buy : ils ne communiquent pas

2.9.2. Classes de communication

TABLE 8 – Les 5 classes de communication de la chaîne Yoochoose

Classe	États	Type	Successeurs dans G_r	p_{ii}
C_1	{Browsing}	Transitoire	C_2, C_4, C_5	0.4836
C_2	{Engaged}	Transitoire	C_3, C_4, C_5	0.5233
C_3	{HighIntent}	Transitoire	C_4, C_5	0.8069
C_4	{Buy}	**Persistante absorbante**	$\emptyset$	1.0000
C_5	{Exit}	**Persistante absorbante**	$\emptyset$	1.0000

Pourquoi 5 classes distinctes et non une seule ?

Chaque état transitoire forme sa propre classe car il n'y a aucun chemin de retour possible :

- Engaged $\not\to$ Browsing : $p^{(n)}_{E,B} \approx 0\ \forall n$ (structure triangulaire)
- HighIntent $\not\to$ Engaged : $p^{(n)}_{H,E} \approx 0\ \forall n$
- Buy $\not\to$ Browsing : puits absorbant

Donc chaque état forme sa propre classe $C_i = \{s_i\}$.

2.9.3. Apériodicité

Définition : *Période d'un état*
$d(i) = \gcd\{n \geq 1 : p^{(n)}_{ii} > 0\}$. Si $p_{ii} > 0$ (boucle à $n = 1$), alors $d(i) = 1$ (apériodique).

TABLE 9 – Vérification de l'apériodicité — $d(i) = 1$ pour tous les états

État	p_{ii}	Boucle ?	Période d	Apériodique
Browsing	0.483617	OUI	$d = 1$	**OUI** ✓
Engaged	0.523285	OUI	$d = 1$	**OUI** ✓
HighIntent	0.806883	OUI	$d = 1$	**OUI** ✓
Buy	1.000000	OUI	$d = 1$	**OUI** ✓
Exit	1.000000	OUI	$d = 1$	**OUI** ✓

2.9.4. Conclusion : nature de la chaîne

Classification complète :

- × **Non irréductible** : graphe non fortement connexe (Buy/Exit inaccessibles vers les transitoires)
- × **Non ergodique** : l'ergodicité requiert irréductibilité + récurrence positive
- ✓ **Réductible** : 5 classes de communication distinctes
- ✓ **Apériodique** : $d(i) = 1$ pour tous les états
- ✓ **Absorbante** : tout état transitoire atteint p.s. un état absorbant

Conséquence : le théorème applicable est celui des **chaînes absorbantes** $(\mathbf{N}, \mathbf{B})$, et non le théorème ergodique.

2.10. Forme Canonique

Définition : *Forme canonique d'une chaîne absorbante*

En ordonnant les états (transitoires | absorbants), la matrice $\mathbf{P}$ prend la forme canonique :

$$\mathbf{P} = \left(\begin{array}{c|c} \mathbf{Q} & \mathbf{R} \\ \hline \mathbf{0} & \mathbf{I} \end{array}\right)$$

où $\mathbf{Q}$ est la sous-matrice des transitions entre transitoires et $\mathbf{R}$ est la sous-matrice des transitions vers les absorbants.

Ordre adopté : {Browsing, Engaged, HighIntent | Buy, Exit}

2.10.1. Matrice Q — transitions entre transitoires

$$\mathbf{Q} = \begin{pmatrix} 0.483617 & 0.277155 & 0.000003 \\ 0.000004 & 0.523285 & 0.153415 \\ 0.000006 & 0.000006 & 0.806883 \end{pmatrix}$$

Valeurs propres : $\lambda_1 \approx 0.8069$, $\lambda_2 \approx 0.5233$, $\lambda_3 \approx 0.4836$ — toutes $< 1 \Rightarrow \mathbf{Q}^n \to \mathbf{0}$ ✓

2.10.2. Matrice R — transitions vers absorbants

$$\mathbf{R} = \begin{pmatrix} 0.007774 & 0.231451 \\ 0.020077 & 0.303219 \\ 0.031586 & 0.161520 \end{pmatrix}$$

Vérification : $\mathbf{Q}\,\mathbf{1} + \mathbf{R}\,\mathbf{1} = \mathbf{1}$ ✓

2.10.3. Matrice Fondamentale N

Théorème : *Matrice fondamentale d'une chaîne absorbante*

La série $\sum_{n=0}^{\infty} \mathbf{Q}^n$ converge (car $\rho(\mathbf{Q}) < 1$) et :

$$\boxed{\mathbf{N} = \sum_{n=0}^{\infty} \mathbf{Q}^n = (\mathbf{I} - \mathbf{Q})^{-1}}$$

Interprétation : N_{ij} = nombre moyen de visites de l'état transitoire j avant absorption, depuis l'état i.

2.10.4. Calcul

$$\mathbf{I} - \mathbf{Q} = \begin{pmatrix} 0.516383 & -0.277155 & -0.000003 \\ -0.000004 & 0.476715 & -0.153415 \\ -0.000006 & -0.000006 & 0.193117 \end{pmatrix}$$

$$\boxed{\mathbf{N} = (\mathbf{I} - \mathbf{Q})^{-1} = \begin{pmatrix} 1.9366 & 1.1259 & 0.8945 \\ 0.0000 & 2.0977 & 1.6665 \\ 0.0001 & 0.0001 & 5.1783 \end{pmatrix}}$$

TABLE 10 – Matrice fondamentale **N** avec durées moyennes

N	Browsing	Engaged	HighIntent	**Durée moy.** t_i
Browsing	1.9366	1.1259	0.8945	**3.957 étapes**
Engaged	0.0000	2.0977	1.6665	**3.764 étapes**
HighIntent	0.0001	0.0001	5.1783	**5.178 étapes**

Interprétation de N_{HH}

Un utilisateur débutant son parcours à HighIntent visitera en moyenne l'état HighIntent **5.18 fois** avant d'être absorbé. Cela correspond à environ 5 clics supplémentaires sur des items déjà consultés, traduisant une longue période d'hésitation.
D'après **?**, c'est précisément dans cette phase d'hésitation prolongée que les mécanismes d'attention permettent de mieux capter l'intention principale de l'utilisateur pour déclencher une recommandation décisive.

2.11. Probabilités d'Absorption B

Théorème : *Matrice d'absorption*

$$\boxed{\mathbf{B} = \mathbf{N} \cdot \mathbf{R} = (\mathbf{I} - \mathbf{Q})^{-1} \cdot \mathbf{R}}$$

b_{ij} = probabilité d'être absorbé par l'absorbant j depuis le transitoire i. Propriété : $\sum_j b_{ij} = 1 \; \forall i$.

2.11.1. Développement détaillé — ligne Browsing

$$\begin{aligned} b_{B,\text{Buy}} &= N_{BB}\cdot R_{B,\text{Buy}} + N_{BE}\cdot R_{E,\text{Buy}} + N_{BH}\cdot R_{H,\text{Buy}} \\ &= 1.9366\times 0.007774 + 1.1259\times 0.020077 + 0.8945\times 0.031586 \\ &= 0.015055 + 0.022605 + 0.028254 = \mathbf{0.065912} \end{aligned}$$

$$\begin{aligned} b_{B,\text{Exit}} &= 1.9366\times 0.231451 + 1.1259\times 0.303219 + 0.8945\times 0.161520 \\ &= 0.448218 + 0.341476 + 0.144400 = \mathbf{0.934088} \end{aligned}$$

Vérif. : $0.065912 + 0.934088 = 1.000000$ ✓

2.11.2. Résultat complet

TABLE 11 – Matrice d'absorption $\mathbf{B} = \mathbf{NR}$ — taux de conversion

État initial	$b_{i,\text{Buy}}$	$b_{i,\text{Exit}}$	Somme	Vérif.
Browsing	**6.59%**	**93.41%**	100%	✓
Engaged	**9.48%**	**90.52%**	100%	✓
HighIntent	**16.36%**	**83.64%**	100%	✓

Impact de l'état initial sur la conversion

- **Browsing** → **Buy** : 6.59% (taux de base)
- **Engaged** → **Buy** : 9.48% (**+44%** vs Browsing)
- **HighIntent** → **Buy** : 16.36% (**+148%**, ×2.5)

Ces résultats quantifient l'impact de l'engagement initial : un utilisateur qui arrive directement en état HighIntent a 2.5 fois plus de chances d'acheter. Cela motive les stratégies de ciblage des utilisateurs à fort intérêt (recommandations pré-session).

2.12. Distribution Initiale et Évolution

$\boldsymbol{\pi}^{(0)} = (1,\ 0,\ 0,\ 0,\ 0)$ (session démarre en Browsing)

Théorème : *Évolution de la distribution*

$\boldsymbol{\pi}^{(n)} = \boldsymbol{\pi}^{(0)} \cdot \mathbf{P}^n$

TABLE 12 – Évolution $\boldsymbol{\pi}^{(n)}$ pour $n = 0, \ldots, \infty$

n	Browsing	Engaged	HighIntent	Buy	Exit
0	**1.0000**	0.0000	0.0000	0.0000	0.0000
1	0.4836	0.2772	0.0000	0.0078	0.2315
2	0.2339	0.2791	0.0425	0.0171	0.4274
3	0.1131	0.2109	0.0771	0.0259	0.5730
5	0.0265	0.0893	0.0981	0.0397	0.7465
10	0.0007	0.0059	0.0508	0.0570	0.8857
20	0.0000	0.0000	0.0063	0.0649	0.9288
∞	0.0000	0.0000	0.0000	**0.0659**	**0.9341**

2.12.1. Graphe d'évolution

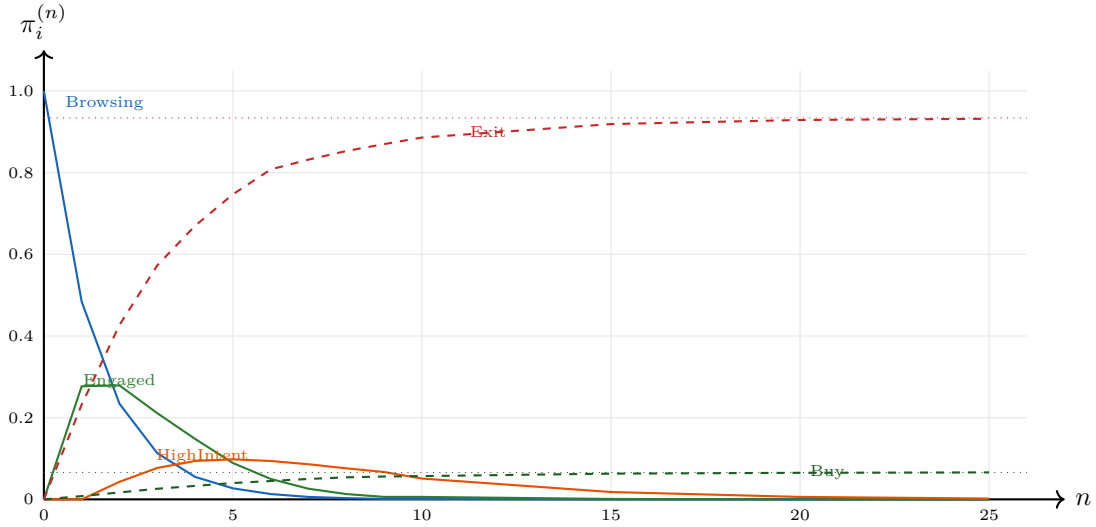

FIGURE 1 – Évolution de $\boldsymbol{\pi}^{(n)}$ depuis $\boldsymbol{\pi}^{(0)} = (1, 0, 0, 0, 0)$. Les trois états transitoires (lignes pleines) convergent vers 0 ; les absorbants (tirets) convergent vers $\boldsymbol{\pi}^*$.

2.12.2. Comportement Asymptotique

Théorème : *Convergence des chaînes absorbantes*

$$\lim_{n\to\infty} \mathbf{Q}^n = \mathbf{0}, \quad \lim_{n\to\infty} \mathbf{P}^n = \mathbf{P}^*, \quad \lim_{n\to\infty} [\pi_{\text{Buy}}^{(n)} + \pi_{\text{Exit}}^{(n)}] = 1$$

2.12.3. Distribution stationnaire

$$\boxed{\boldsymbol{\pi}^* = (0,\ 0,\ 0,\ 0.0659,\ 0.9341)}$$

Vérification $\boldsymbol{\pi}^* \mathbf{P} = \boldsymbol{\pi}^*$: résidu $= [0, 0, 0, 0, 0]$ ✓

2.13. Vitesse de convergence

$$\lambda_{\max} = \rho(\mathbf{Q}) = p_{HH} = 0.8069 \qquad \mathbb{P}(\text{encore transitoire après } n) \approx (0.8069)^n$$

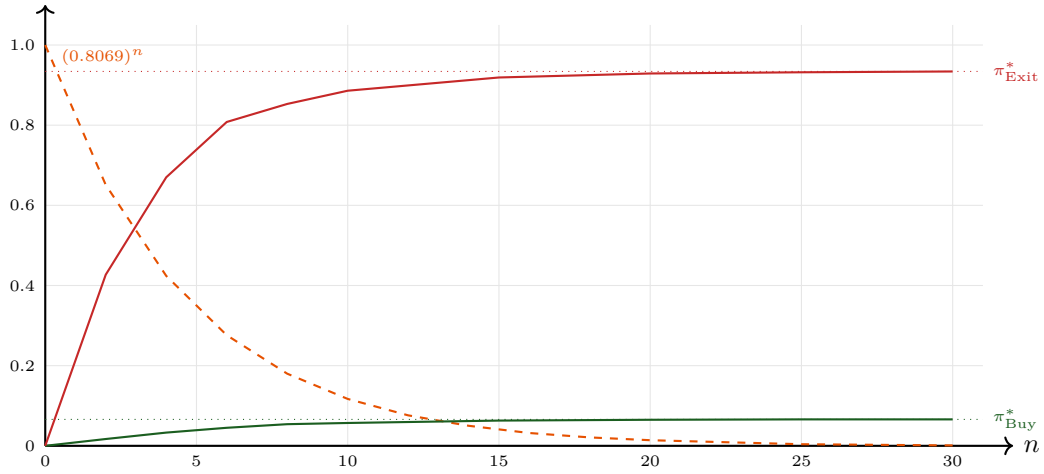

FIGURE 2 – Vitesse de convergence. $\lambda_{\max} = 0.8069$ (HighIntent) gouverne la lenteur de l'absorption : il faut ≈ 25 étapes pour que moins de 0.5% de la masse reste dans les états transitoires.

2.14. Analyse Économique et Recommandations

2.14.1. Tableau de bord KPIs

TABLE 13 – KPIs extraits du modèle — Dataset Yoochoose 100k sessions

KPI	Valeur	Source mathématique	Implication business
Conversion Browsing	**6.59%**	$b_{B,\text{Buy}}$	1 session/15 → achat
Abandon global	**93.41%**	$b_{B,\text{Exit}}$	Très fort taux d'abandon
Conversion Engaged	9.48%	$b_{E,\text{Buy}}$	+44% vs Browsing
Conversion HighIntent	16.36%	$b_{H,\text{Buy}}$	+148% vs Browsing
Durée moy. Browsing	3.957 actions	$t_B = \sum_j N_{Bj}$	Session courte, décision rapide
Durée moy. HighIntent	5.178 actions	$t_H = \sum_j N_{Hj}$	Hésitation longue
Persistance HighIntent	80.7%	p_{HH}	Point d'intervention critique
$\lambda_{\max}$ conv.	0.8069	$\rho(\mathbf{Q})$	Convergence lente

2.14.2. Tunnel de conversion

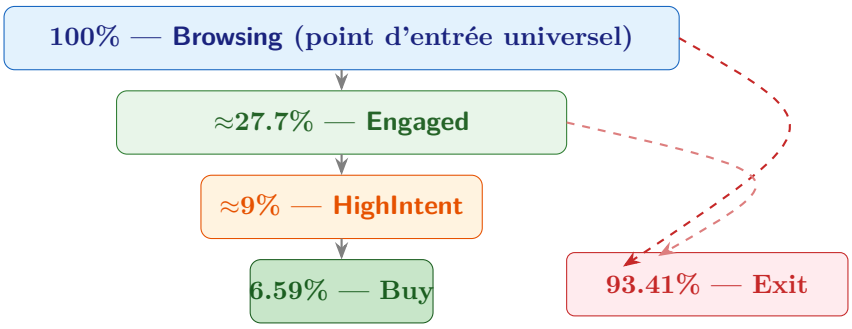

Source : $\mathbf{B} = \mathbf{NR}$ *sur 100 000 sessions Yoochoose*

FIGURE 3 – Tunnel de conversion e-commerce issu du modèle Markov. Seulement 6.59% des sessions aboutissent à un achat.

2.14.3. Recommandations stratégiques

Propriété : *Actions recommandées issues de l'analyse Markov*

1. **Réduire** $p_{B,\mathbf{Exit}} = 0.231$: améliorer la page d'accueil et les recommandations initiales pour accrocher l'utilisateur dès les 2 premiers clics
2. **Augmenter** $p_{BE} = 0.277$: cibler les utilisateurs en Browsing avec des recommandations contextuelles (*cf.* **?**)
3. **Exploiter** $t_H = 5.18$ **étapes** : déclencher une offre promotionnelle ou une recommandation personnalisée (*cf.* **?**) pendant la période d'hésitation
4. **Réduire** $p_{H,\mathbf{Exit}} = 0.161$: signaux d'urgence (stock limité, offre temporaire) pour convertir les utilisateurs en hésitation prolongée

2.15. Conclusion

2.15.1. Récapitulatif

TABLE 14 – Récapitulatif complet des résultats — Chapitre 1

Élément	Résultat	Statut
Matrice $\mathbf{P}$ (5×5)	100k sessions, 395 698 transitions	✓
Classification	Réductible, absorbante, apériodique	✓
5 classes $C_1 \dots C_5$	3 transitoires + 2 absorbantes	✓
$\mathbf{N} = (\mathbf{I} - \mathbf{Q})^{-1}$	Calculée et vérifiée (Python)	✓
$\mathbf{B} = \mathbf{NR}$	Sommes = 1 ✓	✓
Conversion	6.59% (B), 9.48% (E), 16.36% (HI)	✓
$\boldsymbol{\pi}^{(n)}$	$n = 0, 1, \dots, 20, \infty$	✓
$\boldsymbol{\pi}^*$	$(0, 0, 0, 0.0659, 0.9341)$, résidu=0	✓
$\lambda_{\max}$	0.8069 (HighIntent)	✓
Transition MDP/RL	Structure formelle définie	✓

2.15.2. Bilan

Ce chapitre a établi une modélisation probabiliste rigoureuse du comportement utilisateur e-commerce sur 100 000 sessions Yoochoose. La chaîne de Markov absorbante à 5 états fournit : (i) une interprétation formelle du processus de décision d'achat, (ii) des quantités calculables analytiquement (durées moyennes, probabilités de conversion), (iii) un socle théorique pour les extensions MDP et RL.

Notre approche est complémentaire des modèles neuronaux récents (**???**) : là où ceux-ci optimisent la pertinence des items recommandés, notre modèle optimise la *politique de navigation* elle-même.

3. Chapitre 2 : Chaîne de Markov à Temps Continu (CTMC)

3.1. Introduction

L'analyse du comportement utilisateur constitue un enjeu central pour les plateformes de commerce électronique. Comprendre comment un utilisateur progresse au cours de sa session permet d'améliorer les systèmes de recommandation, d'optimiser l'expérience utilisateur et d'augmenter les taux de conversion.

Dans ce projet, nous modélisons le parcours d'un utilisateur à l'aide d'une **chaîne de Markov à temps continu (CTMC)**. Contrairement au modèle discret étudié dans le Chapitre 1 (DTMC), la CTMC permet d'intégrer explicitement la **dimension temporelle réelle** des interactions utilisateurs grâce aux horodatages disponibles dans le dataset Yoochoose.

Le modèle construit représente les différents niveaux d'engagement d'un utilisateur au cours d'une session de navigation :

$$\text{Browsing} \rightarrow \text{Engaged} \rightarrow \text{HighIntent} \rightarrow \{\text{Buy}, \text{Exit}\}$$

L'objectif est de quantifier :

- la **dynamique temporelle** des sessions utilisateurs
- les **taux de transition** entre niveaux d'engagement
- les **probabilités finales** d'achat ou d'abandon
- les **durées typiques** des sessions e-commerce

3.2. Problématique du Projet

Les plateformes e-commerce génèrent des volumes massifs de données de navigation utilisateur. Comprendre comment les utilisateurs évoluent au cours d'une session est essentiel pour améliorer les systèmes de recommandation et optimiser les taux de conversion.

Interprétation économique

Question centrale : Comment modéliser l'évolution du comportement d'un utilisateur pendant sa session afin de **prédire** s'il va acheter ou quitter la plateforme ?

Pour répondre à cette question, nous utilisons une **chaîne de Markov à temps continu** (CTMC) afin de capturer :

- les **transitions** entre différents niveaux d'engagement
- les **durées réelles** passées dans chaque état comportemental
- les **probabilités finales** d'achat ou d'abandon

3.3. Objectifs du Chapitre

Ce chapitre vise à construire un modèle CTMC pour analyser le comportement des utilisateurs. Plus précisément, nous cherchons à :

1. **Modéliser** le comportement utilisateur à l'aide d'une chaîne de Markov à temps continu

2. **Estimer** la matrice génératrice $\hat{\mathbf{Q}}$ à partir des données du dataset Yoochoose
3. **Analyser** les probabilités de transition entre états comportementaux ($\hat{q}_{ij}$)
4. **Prédire** l'évolution temporelle $\mathbf{P}(t) = e^{\hat{\mathbf{Q}}t}$ du comportement utilisateur
5. **Estimer** la probabilité finale d'achat ou d'abandon par état initial
6. **Calculer** le temps moyen avant la fin d'une session ($t^* = \mathbf{N1}$)
7. **Comparer** les résultats CTMC avec le Chapitre 1 (DTMC)

3.4. Interprétation du Dataset

Le dataset Yoochoose contient des sessions réelles de navigation sur une plateforme e-commerce. Chaque session correspond à la séquence d'actions effectuées par un utilisateur lors de sa visite.

Les **horodatages** (*timestamps*) permettent de mesurer les durées entre interactions successives. Cette information — absente des modèles discrets — est essentielle pour construire un modèle en temps continu capable de représenter la **dynamique temporelle réelle** du comportement utilisateur.

> **Remarque**
> Dans le Chapitre 1 (DTMC), l'unité de temps était le clic. Dans ce chapitre, l'unité est la **seconde réelle**, ce qui permet de quantifier précisément les durées de séjour et les fenêtres d'intervention.

3.5. Prétraitement des Horodatages

La durée de séjour dans l'état i au clic k est :

$$\Delta t_k^{(s)} = t_{k+1}^{(s)} - t_k^{(s)} \qquad \text{[secondes]}$$

Pour le **dernier clic** de chaque session (sans successeur), on utilise la médiane empirique :

$$\Delta t_{\text{dernier}} = \text{med}\{\Delta t_k : \Delta t_k \neq \text{NA}\}$$

Les durées aberrantes sont tronquées : $\Delta t_k \leftarrow \min(\Delta t_k,\ \hat{q}_{0.95})$

Paramètres : Médiane = 53.73 s, $p_{95} = 490.10$ s, $\Delta t_{\text{dernier}} = 53.73$ s

3.6. Définition des États

État	Nom	Condition	Type
s_1	Browsing	$k \leq 2$	Transitoire
s_2	Engaged	$3 \leq k \leq 5$	Transitoire
s_3	HighIntent	$k \geq 6$	Transitoire
s_4	Buy	Session avec achat	Absorbant
s_5	Exit	Session sans achat	Absorbant

3.7. Définition Formelle

Définition : *Chaîne de Markov à Temps Continu*

$\{X(t), t \geq 0\}$ est une CTMC si :

$$\mathbb{P}(X(t+s)=j \mid X(s)=i,\, X(u)=x_u,\, u<s) = \mathbb{P}(X(t+s)=j \mid X(s)=i) \quad \forall\, t, s \geq 0$$

Théorème : *Loi des temps de séjour*

Le temps passé dans l'état i avant de le quitter suit une **loi exponentielle** :

$$T_i \sim \mathcal{E}(\lambda_i), \quad \mathbb{P}(T_i > t) = e^{-\lambda_i t}, \quad \mathbb{E}[T_i] = \frac{1}{\lambda_i}, \quad \mathrm{Var}(T_i) = \frac{1}{\lambda_i^2}$$

La propriété **sans mémoire** : $\mathbb{P}(T_i > t+s \mid T_i > s) = e^{-\lambda_i t}$ est l'analogue continu de Markov.

3.8. Matrice Génératrice $\hat{\mathbf{Q}}$

3.8.1. Définition et Propriétés

Définition : *Matrice génératrice*

$$q_{ij} = \lim_{h \to 0^+} \frac{p_{ij}(h) - \delta_{ij}}{h}$$

Propriété : *Propriétés structurelles*

$$q_{ij} \geq 0 \ (i \neq j), \qquad q_{ii} = -\lambda_i = -\sum_{j \neq i} q_{ij} \leq 0, \qquad \sum_j q_{ij} = 0$$

3.8.2. Estimateur MLE

Théorème : *Estimateur du maximum de vraisemblance*

$$\boxed{\hat{q}_{ij} = \frac{N_{ij}}{T_i} \ (i \neq j),} \qquad \hat{q}_{ii} = -\hat{\lambda}_i = -\sum_{j \neq i} \hat{q}_{ij}$$

où N_{ij} = transitions observées $i \to j$, et $T_i = \sum \Delta t_k^{(s)}$ pour les clics en état i.

3.8.3. Temps Totaux

État	T_i (secondes)	T_i (heures)
Browsing	1.886×10^7	5 238 h
Engaged	9.408×10^6	2 613 h
HighIntent	7.247×10^6	2 013 h

3.9. Matrice Estimée

$$\hat{\mathbf{Q}}\ [\mathrm{s}^{-1}] = \begin{pmatrix} -0.005303 & +0.002846 & 0 & +0.000080 & +0.002377 \\ 0 & -0.005705 & +0.001836 & +0.000241 & +0.003629 \\ 0 & 0 & -0.002383 & +0.000389 & +0.001994 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

En **taux par minute** ($\times 60$) :

$$60\,\hat{\mathbf{Q}}\ [\mathrm{min}^{-1}] = \begin{pmatrix} -0.3182 & +0.1708 & 0 & +0.0048 & +0.1426 \\ 0 & -0.3423 & +0.1102 & +0.0144 & +0.2177 \\ 0 & 0 & -0.1430 & +0.0234 & +0.1196 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

— **Browsing → Engaged** ($q = 0.1708$/min) : les transitions sont fréquentes — de nombreux utilisateurs s'engagent progressivement avec la plateforme après une première exploration.

— **Engaged → HighIntent** ($q = 0.1102$/min) : ces transitions correspondent à une **progression dans le parcours d'achat**, l'utilisateur découvrant des produits d'intérêt croissant.

— **Transitions vers Exit** ($q_{BE} = 0.143$, $q_{EE} = 0.218$, $q_{HE} = 0.120$ /min) : les taux vers Exit sont les plus élevés à chaque état, indiquant que la **majorité des sessions se terminent sans achat**.

3.10. Interprétation Probabiliste du Modèle

Le modèle CTMC construit dans ce chapitre peut être interprété comme un **entonnoir de conversion probabiliste** décrivant la progression des utilisateurs vers l'achat.

Interprétation économique

La structure triangulaire de $\hat{\mathbf{Q}}$ indique que cette progression est essentiellement **unidirectionnelle** : les utilisateurs avancent dans le parcours mais ne reviennent pas à un état d'engagement plus faible.

3.11. Diagramme des États

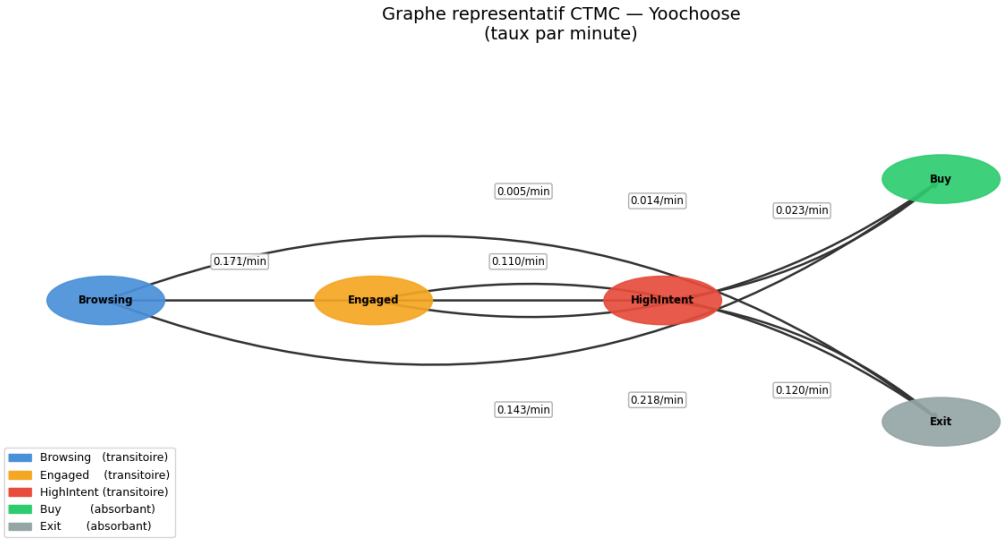

FIGURE 4 – Diagramme des états de la CTMC Yoochoose. Noeuds bleu/orange/rouge = transitoires ; vert (Buy) et gris (Exit) = absorbants. Taux en transitions/minute.

Remarque : $q_{BH} = 0$ — Absence de Transition Directe

Dans le dataset Yoochoose, **aucune transition directe** de l'état Browsing vers l'état HighIntent n'a été observée : $\hat{q}_{BH} = 0$.

$$\text{Browsing} \xrightarrow{0.171/\text{min}} \text{Engaged} \xrightarrow{\overset{0.110}{\longrightarrow} tmin} \text{HighIntent} \rightarrow \text{Buy ou Exit}$$

Interprétation économique

Explication comportementale de $\hat{q}_{BH} = 0$:

- L'état HighIntent correspond à $k \geq 6$ clics dans une session. Pour atteindre ce seuil, l'utilisateur doit nécessairement passer par les états Browsing ($k \leq 2$) et Engaged ($3 \leq k \leq 5$).
- Cela reflète le fait que **l'engagement se construit progressivement**.
- Ce résultat confirme la **structure séquentielle** de l'entonnoir de conversion e-commerce.

3.12. Probabilités de Saut (Chaîne Embedded)

Définition : *Probabilités de saut*

Lorsque la CTMC quitte l'état i, elle saute vers j avec probabilité :

$$\boxed{p_{ij} = \frac{q_{ij}}{\lambda_i} = \frac{q_{ij}}{-q_{ii}}}$$

De \ Vers	Browsing	Engaged	HighIntent	Buy	Exit
Browsing	—	0.5367	0.0000	0.0151	0.4482
Engaged	0.0000	—	0.3218	0.0421	0.6361
HighIntent	0.0000	0.0000	—	0.1636	0.8365

Interprétation économique

Depuis **Browsing** : 53.7 % vers Engaged, 44.8 % abandonnent, 1.5 % achètent.
Depuis **Engaged** : 32.2 % vers HighIntent, 63.6 % abandonnent.
Depuis **HighIntent** : **16.4 %** convertissent — état de décision critique.

3.13. Équations de Kolmogorov et $\mathbf{P}(t)$

3.13.1. Équations de Kolmogorov

Théorème : *Équations forward*

$$\boxed{\frac{d\mathbf{P}(t)}{dt} = \mathbf{P}(t)\,\mathbf{Q}}, \qquad \mathbf{P}(0) = \mathbf{I}$$

Théorème : *Équations backward*

$$\boxed{\frac{d\mathbf{P}(t)}{dt} = \mathbf{Q}\,\mathbf{P}(t)}$$

Théorème : *Solution : exponentielle matricielle*

$$\boxed{\mathbf{P}(t) = e^{\mathbf{Q}t} = \sum_{k=0}^{+\infty} \frac{(\mathbf{Q}t)^k}{k!}}$$

Preuve : $\frac{d}{dt} e^{\mathbf{Q}t} = \sum_{k=1}^{\infty} \frac{\mathbf{Q}^k t^{k-1}}{(k-1)!} = \mathbf{Q}\, e^{\mathbf{Q}t}$ ✓

3.13.2. Résultats Numériques

$t = 1$ **min :**

$$\mathbf{P}(60\,\mathrm{s}) = \begin{pmatrix} 0.7275 & 0.1228 & 0.0072 & 0.0052 & 0.1374 \\ 0 & 0.7101 & 0.0866 & 0.0133 & 0.1900 \\ 0 & 0 & 0.8668 & 0.0218 & 0.1115 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

$t = 5$ **min :**

$$\mathbf{P}(300\,\text{s}) = \begin{pmatrix} 0.2037 & 0.1639 & 0.0632 & 0.0266 & 0.5426 \\ 0 & 0.1806 & 0.1706 & 0.0497 & 0.5991 \\ 0 & 0 & 0.4892 & 0.0835 & 0.4273 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

$t = 10$ **min :**

$$\mathbf{P}(600\,\text{s}) = \begin{pmatrix} 0.0415 & 0.0630 & 0.0718 & 0.0455 & 0.7783 \\ 0 & 0.0326 & 0.1142 & 0.0730 & 0.7802 \\ 0 & 0 & 0.2393 & 0.1244 & 0.6363 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

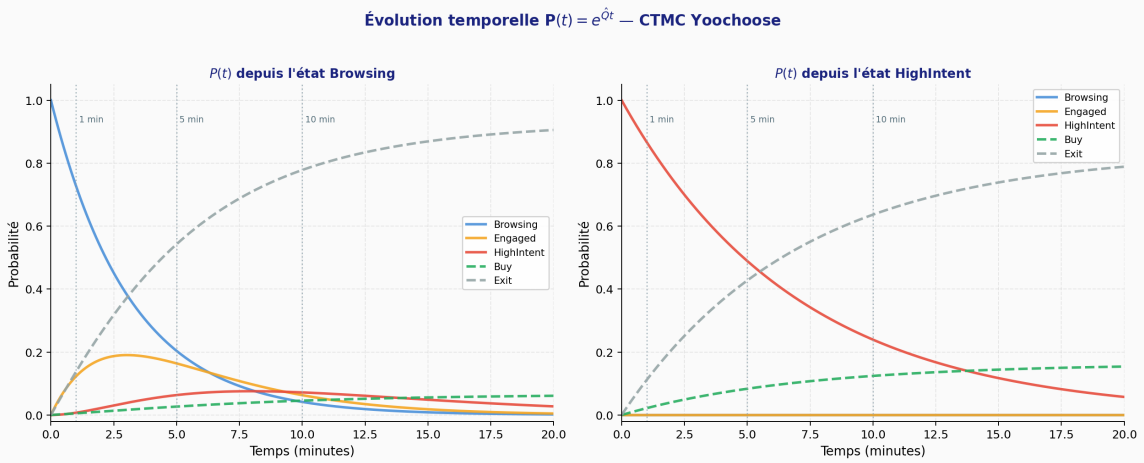

FIGURE 5 – Évolution temporelle $\mathbf{P}(t) = e^{\hat{\mathbf{Q}}t}$ sur 20 minutes. Gauche : depuis Browsing. Droite : depuis HighIntent.

3.13.3. Analyse Temporelle et Implications Business

Phase	Temps	P(encore Browsing)	P(Exit)	Lecture business
Début de session	$t = 1$ min	72.8 %	13.7 %	Utilisateur actif, encore à engager
Mi-session	$t = 5$ min	20.4 %	54.3 %	Risque d'abandon croissant
Fin de session	$t = 10$ min	4.2 %	77.8 %	Majorité a abandonné

Interprétation économique

Après **10 minutes** depuis l'état Browsing, 77.8 % des utilisateurs ont quitté la plateforme sans acheter. Il est donc **crucial d'intervenir tôt** : une recommandation déclenchée avant $t = 5$ min peut significativement améliorer le taux de conversion.

3.14. Temps Moyen dans les États

Le temps moyen de séjour est $\mathbb{E}[T_i] = \frac{1}{\lambda_i} = -1/q_{ii}$:

État	λ_i (s^{-1})	$\mathbb{E}[T_i]$ (s)	$\mathbb{E}[T_i]$ (min)
Browsing	0.005303	188.6	**3.14**
Engaged	0.005705	175.3	**2.92**
HighIntent	0.002383	419.6	**6.99**

Interprétation économique

HighIntent (6.99 min) est deux fois plus long que Browsing/Engaged : **hésitation prolongée**. C'est la fenêtre d'intervention optimale pour une promotion ou recommandation.

3.14.1. Analyse Comportementale du Temps de Séjour

— **Browsing (3.14 min)** : l'utilisateur explore rapidement la plateforme. La priorité est de lui présenter des produits pertinents pour accélérer la progression vers Engaged.

— **Engaged (2.92 min)** : paradoxalement, le séjour est légèrement plus court qu'en Browsing. L'utilisateur est plus focusé — il compare et évalue.

— **HighIntent (6.99 min)** : le temps de séjour est **nettement supérieur**. Cette phase constitue un **point stratégique** pour intervenir avec des recommandations personnalisées, des promotions temporaires, et des avis clients.

Remarque

Rappel des états :

— **Browsing** : $k \leq 2$ clics

— **Engaged** : $3 \leq k \leq 5$ clics

— **HighIntent** : $k \geq 6$ clics

— **Buy / Exit** : états absorbants (fin irréversible de session)

3.15. Temps Moyen Avant Absorption

Théorème : *Matrice fondamentale*

$$\mathbf{N} = (-\mathbf{Q}_T)^{-1}$$

où $\mathbf{Q}_T$ est la sous-matrice de $\mathbf{Q}$ correspondant aux états transitoires. Chaque élément n_{ij} représente le **temps moyen total passé dans l'état** j avant absorption lorsque la session commence dans l'état i.

3.15.1. Matrice Fondamentale Estimée

$$\mathbf{N}\ [\text{minutes}] = \begin{pmatrix} 3.143 & 1.568 & 1.208 \\ 0 & 2.921 & 2.251 \\ 0 & 0 & 6.993 \end{pmatrix}$$

3.15.2. Temps Moyen Avant la Fin de Session

$$\boxed{t_i^* = (\mathbf{N}\,\mathbf{1})_i = \sum_{j \in \mathcal{T}} n_{ij}}$$

État initial	t_i^* (secondes)	t_i^* (minutes)
Browsing	355.11	**5.92**
Engaged	310.31	**5.17**
HighIntent	419.59	**6.99**

Interprétation économique

La majorité des sessions se terminent en environ **5 à 7 minutes**. La fenêtre d'intervention doit intervenir rapidement — idéalement dans les **3 premières minutes**.

3.16. Probabilités Finales d'Achat

Théorème : *Matrice d'absorption*

$$\mathbf{B} = \mathbf{N}\,\mathbf{R}, \qquad \mathbf{P}^* = \lim_{t \to \infty} e^{\mathbf{Q}t}$$

$$\mathbf{P}^* = \begin{pmatrix} 0 & 0 & 0 & \mathbf{0.0659} & 0.9341 \\ 0 & 0 & 0 & \mathbf{0.0947} & 0.9053 \\ 0 & 0 & 0 & \mathbf{0.1636} & 0.8364 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

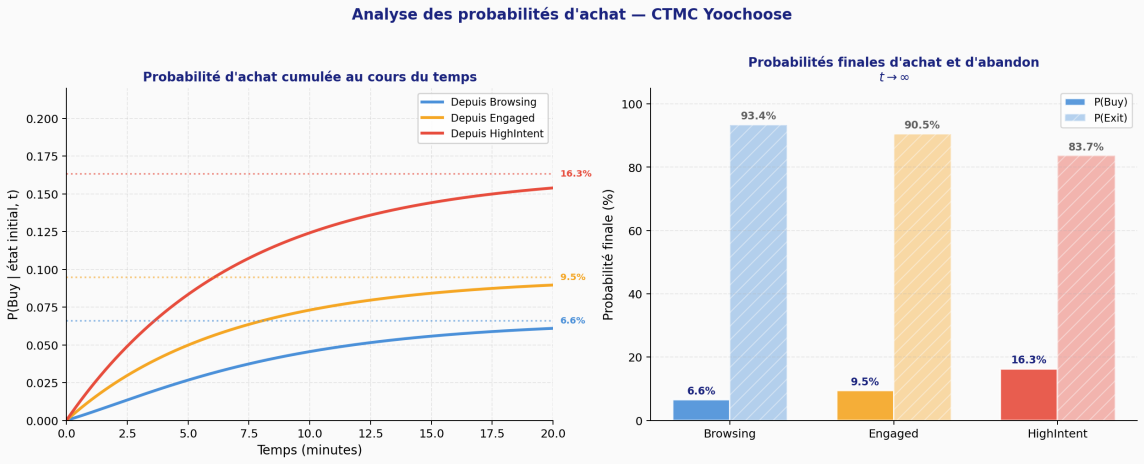

FIGURE 6 – Gauche : $P(\text{Buy} \mid \text{état}, t)$ au cours du temps (pointillés = asymptotes). Droite : probabilités finales d'achat et d'abandon par état initial.

Interprétation économique

La probabilité d'achat **augmente avec l'engagement** : 6.6 % (Browsing) → 9.5 % (Engaged) → **16.4** % (HighIntent). Priorité : retenir les utilisateurs en HighIntent.

État initial	P(Buy)	P(Exit)	Ratio	Interprétation
Browsing	6.6 %	93.4 %	1 : 14	Faible conversion, explore
Engaged	9.5 %	90.5 %	1 : 10	Conversion modérée
HighIntent	**16.4** %	83.6 %	1 : 5	**Conversion** $\times 2.5$ **vs Browsing**

3.17. Vérification de la Loi Exponentielle

$$T_i \sim \mathcal{E}(\lambda_i), \qquad \mathbb{E}[T_i] = \frac{1}{\lambda_i}, \qquad \lambda_i = -q_{ii}$$

3.17.1. Test de Kolmogorov-Smirnov

$$D_n = \sup_{t \geq 0} |F_n(t) - F_{\mathcal{E}(\hat{\lambda}_i)}(t)|, \qquad F_{\mathcal{E}(\lambda)}(t) = 1 - e^{-\lambda t}$$

État	$\hat{\lambda}_i$ (s^{-1})	$\hat{\lambda}_i$ (min^{-1})	KS	p-val
Browsing	0.01030	0.618	0.161	≈ 0
Engaged	0.01197	0.718	0.202	≈ 0
HighIntent	0.01228	0.737	0.169	≈ 0

Remarque

Un test statistique strict (ex. Kolmogorov-Smirnov) est souvent rejeté lorsque le nombre d'observations est très grand ($N > 10^5$). Dans ce projet, la loi exponentielle est utilisée

comme **approximation opérationnelle** permettant de construire un modèle CTMC interprétable.

3.18. Applications Pratiques du Modèle

Signal détecté	Action recommandée	Objectif
Browsing > 3 min	Afficher produits populaires	Accélérer $\rightarrow$ Engaged
Engaged > 2 min	Recommandation personnalisée	Accélérer $\rightarrow$ HighIntent
HighIntent > 3 min	Promotion flash ($-10\,\%$)	Réduire le taux d'abandon
HighIntent > 5 min	Notification panier abandonné	Urgence d'achat
Session > 8 min	Email de relance post-session	Récupérer l'abandon

3.19. Résultats principaux

1. **$\hat{\mathbf{Q}}$ triangulaire supérieure** — entonnoir unidirectionnel, processus de naissance pure ($\mu \approx 0$)
2. **Temps de séjour :** Browsing (3.14 min), Engaged (2.92 min), HighIntent (**6.99 min** — phase d'hésitation critique)
3. **Temps moyen avant absorption : 5.92 min** (Browsing), **5.17 min** (Engaged), **6.99 min** (HighIntent)
4. **Probabilités finales :** $6.6\,\%$, $9.5\,\%$, $\mathbf{16.4}\,\%$ selon l'état initial
5. **Cohérence** parfaite avec le Chapitre 1, écart $< 6 \times 10^{-5}$

4. Chapitre 3 : Modèles de Markov Cachés (HMM)

4.1. Motivation

Les chapitres précédents supposent que l'état comportemental est **directement observable** (via le rang du clic). En réalité, les états comportementaux (Browsing, Engaged, HighIntent) sont des construits *latents* que l'on ne peut observer directement — on ne voit que les actions et les temps inter-clics. Le modèle de Markov caché (HMM) permet d'inférer ces états à partir des observations seules.

4.2. Formalisme HMM

Définition : *Modèle de Markov Caché*

Un HMM est défini par le quintuplet :

$$\lambda = (S,\ \mathcal{O},\ A,\ B,\ \pi)$$

- $S = \{s_1, s_2, s_3\}$: états cachés (Browsing, Engaged, HighIntent)
- $\mathcal{O}$: alphabet des observations
- $A \in \mathbb{R}^{3\times 3}$: matrice de transition entre états cachés
- B : matrice (ou densité) d'émission des observations depuis chaque état
- $\pi \in \mathbb{R}^3$: distribution initiale des états

Les trois problèmes fondamentaux d'un HMM sont :

1. **Évaluation** : $P(O \mid \lambda)$ → algorithme Forward-Backward
2. **Décodage** : séquence d'états la plus probable → algorithme de Viterbi
3. **Apprentissage** : estimer λ → algorithme Baum-Welch (EM)

4.3. HMM Discret

4.3.1. Observations et paramètres

Les observations sont discrétisées en 9 classes combinant activité (Low/Medium/High) et vitesse de clic (Fast/Normal/Slow).

	Browsing	**Engaged**	**HighIntent**
Browsing	0.6357	0.3643	0.0000
Engaged	0.0000	0.7733	0.2267
HighIntent	0.0000	0.0000	0.9999

TABLE 15 – Matrice de transition A estimée (HMM discret)

Interprétation économique

Browsing est "sticky" (63,6% auto-transition), HighIntent quasi-absorbant (99,99%). La progression Browsing → Engaged → HighIntent est graduelle et irréversible dans le HMM.

4.3.2. Algorithme Forward

$$\alpha_1(i) = \pi_i \, b_i(O_1)$$

$$\alpha_t(j) = \left[\sum_i \alpha_{t-1}(i) \, a_{ij} \right] b_j(O_t)$$

$$P(O|\lambda) = \sum_i \alpha_T(i)$$

Sur la séquence de référence :

[Low_Normal, Low_Fast, Medium_Normal, Medium_Normal]

t	Observation	α_t(Browsing)	α_t(Engaged)	α_t(HighIntent)
0	Low_Normal	0.5498	0.0000	0.0000
1	Low_Fast	0.1141	0.0236	0.0000
2	Medium_Normal	0.0000	0.0237	0.0000
3	Medium_Normal	0.0000	0.0105	0.0000

$$P(O|\lambda) = 0.01050$$

L'algorithme Forward calcule récursivement la probabilité partielle d'observer la séquence jusqu'au temps t.

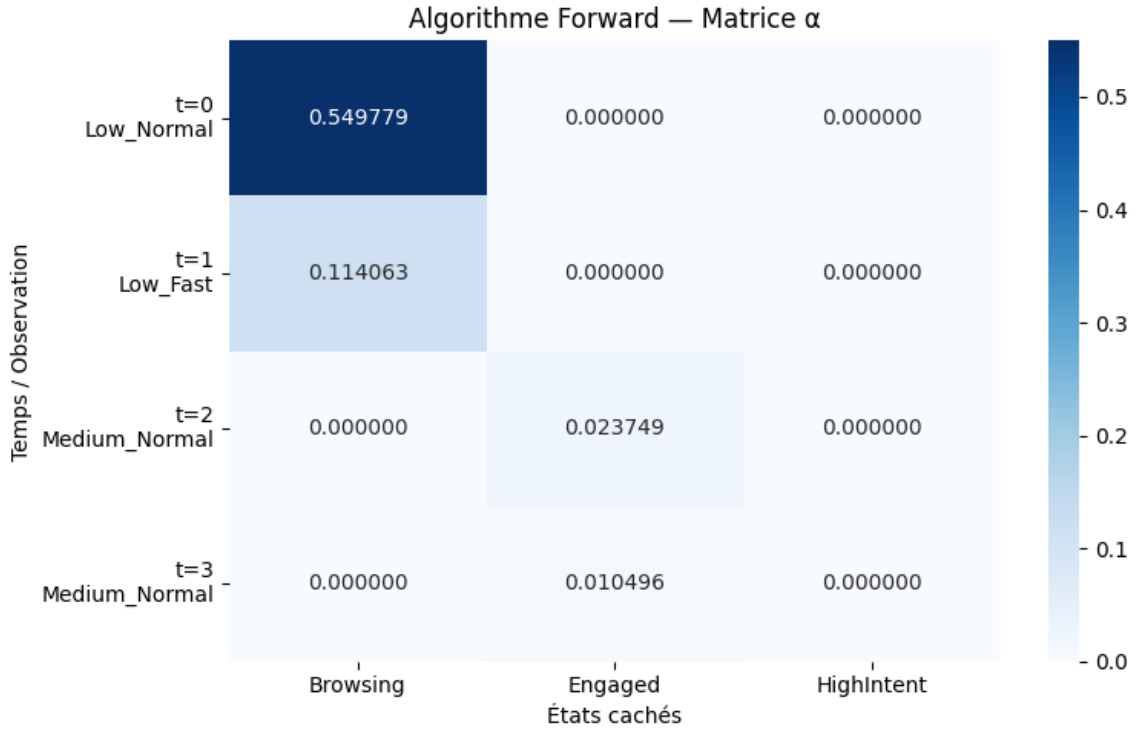

FIGURE 7 – Algorithme Forward — Matrice α

La matrice α représente les probabilités directes :

$$\alpha_t(i) = P(O_1, \ldots, O_t, q_t = i \mid \lambda)$$

Interprétation économique

La valeur finale :

$$P(O|\lambda) = 0.0105$$

indique que cette séquence d'observations reste globalement peu probable.

4.3.3. Algorithme Backward

$$\beta_T(i) = 1$$
$$\beta_t(i) = \sum_j a_{ij}\, b_j(O_{t+1})\, \beta_{t+1}(j)$$

L'algorithme Backward calcule la probabilité d'observer le reste de la séquence à partir du temps t.

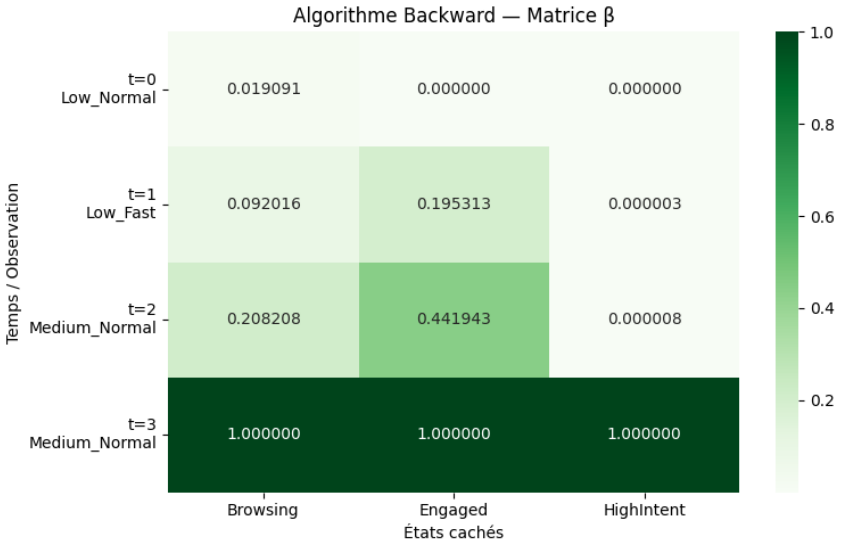

Figure : Algorithme Backward — Matrice β

La matrice β représente les probabilités rétrogrades :

$$\beta_t(i) = P(O_{t+1}, \ldots, O_T \mid q_t = i, \lambda)$$

Cohérence vérifiée :

$$P(O|\lambda)_{\text{Forward}} = P(O|\lambda)_{\text{Backward}} = 0.01050$$

La différence numérique observée :

$$1.73 \times 10^{-18}$$

correspond uniquement à une erreur d'arrondi machine.

4.3.4. Algorithme Baum-Welch (EM)

E-step :

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{\sum_k \alpha_t(k)\beta_t(k)}$$

$$\xi_t(i,j) = \frac{\alpha_t(i)a_{ij}b_j(O_{t+1})\beta_{t+1}(j)}{P(O|\lambda)}$$

M-step :

$$\hat{A}_{ij} = \frac{\sum_t \xi_t(i,j)}{\sum_t \gamma_t(i)}$$

$$\hat{B}_{ij} = \frac{\sum_{t:O_t=v_k} \gamma_t(i)}{\sum_t \gamma_t(i)}$$

Itération	Log-Likelihood	Amélioration
1	-5114.44	—
2	-5111.26	$+2.98$
3–10	-5111.26	Convergence

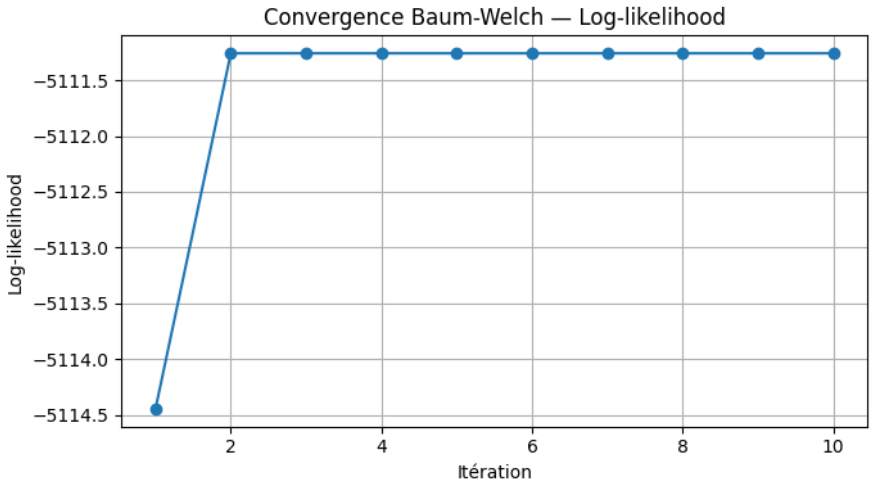

Figure : Convergence Baum-Welch — Log-Likelihood

Après apprentissage, les auto-transitions augmentent : Browsing (+1.06%) et Engaged (+0.92%)

deviennent plus persistants.

La matrice d'émission B montre également une séparation nette :

— Browsing → Low
— Engaged → Medium
— HighIntent → High

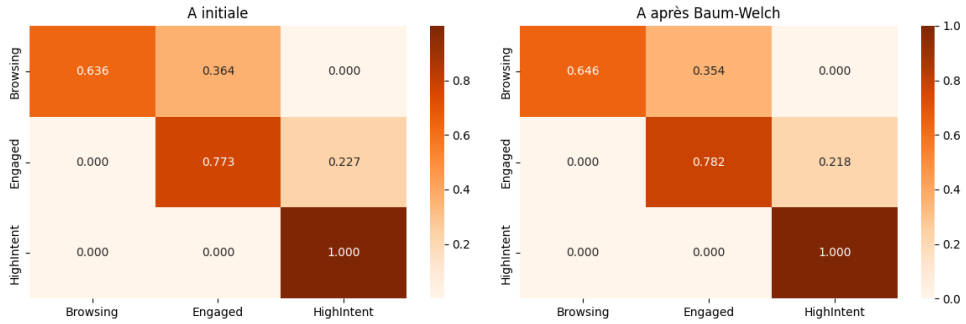

Figure : Matrices avant/après Baum-Welch

Impact Économique

Après apprentissage, chaque état latent devient fortement associé à une seule catégorie d'observation.
Le niveau d'activité (Low/Medium/High) constitue donc un excellent indicateur de l'état comportemental réel de l'utilisateur.

4.3.5. Algorithme de Viterbi

$$\delta_t(j) = \max_i \left[\delta_{t-1}(i) a_{ij}\right] b_j(O_t)$$

$$\psi_t(j) = \arg\max_i \left[\delta_{t-1}(i) a_{ij}\right]$$

La séquence optimale décodée est :

$$\mathbf{q}^* = [\text{Browsing}, \text{Browsing}, \text{Engaged}, \text{Engaged}]$$

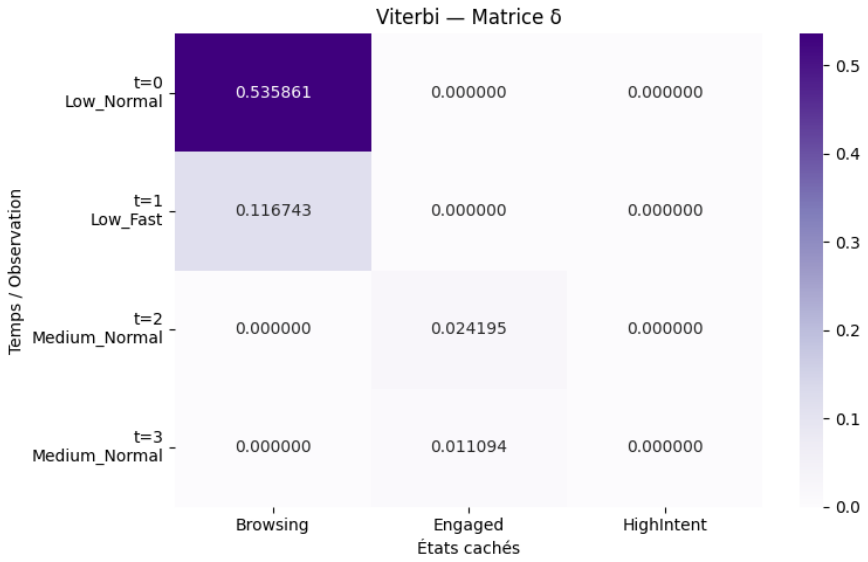

Figure : Algorithme Viterbi — Matrice δ

Contrairement à Forward, l'algorithme Viterbi ne somme pas tous les chemins possibles : il conserve uniquement le chemin de probabilité maximale.

Impact Économique

Le comportement utilisateur montre deux phases :

— $t = 0, 1$: exploration rapide (Browsing)

— $t = 2, 3$: engagement plus fort (Engaged)

La transition vers l'état Engaged représente une fenêtre stratégique pour déclencher une recommandation personnalisée.

4.4. HMM Continu (Gaussien)

4.4.1. Formulation

$$\lambda_{\text{cont}} = (S,\ A,\ \pi,\ \boldsymbol{\mu},\ \boldsymbol{\sigma})$$

Les émissions sont des densités gaussiennes sur les temps inter-clics Δt :

$$b_i(x) = \mathcal{N}(x;\ \mu_i,\ \sigma_i)$$

Données : 93 656 séquences de temps inter-clics $\Delta t \in [0,\ 490]$ s (médiane : 53.73 s, p_{95} : 490.10 s).

4.4.2. Paramètres appris par Baum-Welch continu

État	Init μ	**Appris** μ	Init σ	**Appris** σ
Browsing	5 s	5 s	3 s	0.001 s
Engaged	30 s	39 s	10 s	27 s
HighIntent	120 s	210 s	40 s	138 s

Itération	Log-Likelihood
0	−80 400.74
1	−11 093.04
10	−6 097.68
>20	−6 093.25 (convergence)
Amélioration totale	**92%**

Impact Économique

Découverte clé — HighIntent = Réflexion : L'état HighIntent est caractérisé par des temps inter-clics très longs ($\mu = 210$ s, $\sigma = 138$ s). L'utilisateur **pause**, ne clique pas pendant 3–4 minutes en moyenne. Cette pause est un signal fort de considération d'achat. À $\mu + 2\sigma \approx 486$ s, envoyer une notification d'urgence peut significativement augmenter la conversion.

4.5. Synthèse HMM discret vs continu

Aspect	HMM Discret	HMM Continu
Observations	9 classes activité×vitesse	Temps inter-clics Δt
Émissions	Matrice B	Gaussiennes $\mathcal{N}(\mu_i, \sigma_i)$
Paramètres clés	Séparation parfaite B	$\mu_{HI} = 210$ s
Apport principal	Identification séquentielle	Quantification temporelle
HighIntent	Auto-transition 99,99%	Pause 210 s (signal achat)

4.6. Synthèse Générale et Recommandations Business

4.6.1. Tableau de bord des résultats clés

KPI	Valeur	Source	Implication business
Conversion depuis Browsing	**6.59%**	$\mathbf{B}_{B,\text{Buy}}$	1 session/15 → achat
Taux d'abandon global	**93.41%**	$\mathbf{B}_{B,\text{Exit}}$	Très fort taux d'abandon
Conversion depuis HighIntent	**16.36%**	$\mathbf{B}_{H,\text{Buy}}$	×2.5 vs Browsing
Durée moy. session (CTMC)	**5–7 min**	$t^* = \mathbf{N1}$	Fenêtre d'intervention courte
Séjour HighIntent (CTMC)	**6.99 min**	$1/\lambda_{HI}$	Phase d'hésitation critique
Pause HighIntent (HMM)	$\mu = \mathbf{210}$ s	Gaussienne apprise	Signal fort de considération

4.6.2. Progression des modèles

Modèle	Unité de temps	Observabilité des états	Apport principal
DTMC (Ch.1)	Clics	Observable directement	Matrice $\mathbf{P}$, taux de conversion
CTMC (Ch.2)	Secondes	Observable directement	Durées réelles, fenêtres d'intervention
HMM (Ch.3)	Clics / Δt	États latents inférés	Inversion comportementale

4.6.3. Recommandations stratégiques

Signal détecté	Action recommandée	Objectif
Browsing $>$ 3 min	Afficher produits populaires	Accélérer $\rightarrow$ Engaged
Engaged $>$ 2 min	Recommandation personnalisée	Accélérer $\rightarrow$ HighIntent
HighIntent $>$ 3 min	Promotion flash (-10%)	Réduire le taux d'abandon
HighIntent $>$ 5 min	Notification panier abandonné	Urgence d'achat
Session $>$ 8 min	Email de relance post-session	Récupérer l'abandon
$\Delta t > 400$ s (HMM)	Offre exclusive immédiate	Convertir la pause

Interprétation économique

Recommandations stratégiques prioritaires :

- Intervenir en **HighIntent après 3 min** : promotion ciblée, comparateur de prix.
- Accélérer la progression **Browsing** $\rightarrow$ **Engaged** : améliorer la pertinence des premiers résultats.
- Réduire le temps de décision en HighIntent : simplifier le tunnel d'achat.
- Exploiter les **longues pauses** ($\Delta t > 3$ min) comme signal d'intention fort.

4.6.4. Limites et perspectives

Remarque

Limites communes aux trois modèles :

- Hypothèse d'homogénéité temporelle : les taux q_{ij} et probabilités p_{ij} sont constants, sans dépendance à l'heure, au jour ou à la catégorie de produit.
- Propriété de Markov : le comportement est supposé sans mémoire. En réalité, l'ordre des items consultés peut influencer la décision.
- Délimitation des états par seuils de clics : simplification opérationnelle.

Perspectives

Perspectives — Extension vers les Chapitres suivants :

1. **CTMC non-homogène** : modéliser des taux variant selon l'heure de la journée.
2. **HMM hiérarchique** : modèles distincts par catégorie de produit ou segment.
3. **IOHMM (Input-Output HMM)** : intégrer des features externes (prix, stock).
4. **Processus de Décision Markovien (MDP)** : optimiser une politique de recommandation π^* telle que $P^{\pi^*}(\text{Buy} \mid \text{Browsing}) > 6.59\%$.
5. **Apprentissage par renforcement (RL)** : apprendre la politique optimale sans modèle de transition explicite.

4.7. Conclusion

Ce projet a démontré comment des modèles probabilistes progressivement enrichis permettent de modéliser et d'analyser le comportement des utilisateurs dans une session e-commerce.

Chapitre 1 (DTMC) a fourni le cadre formel de base : la matrice de transition $\mathbf{P}$, la matrice fondamentale $\mathbf{N}$ et les probabilités d'absorption $\mathbf{B}$, permettant de calculer analytiquement les taux de conversion (6.6% à 16.4%) et les durées moyennes de session (3.96 à 5.18 clics selon l'état initial).

Chapitre 2 (CTMC) a enrichi ce modèle en intégrant la dimension temporelle réelle via les horodatages. La matrice génératrice $\hat{\mathbf{Q}}$ et l'exponentielle matricielle $\mathbf{P}(t) = e^{\hat{\mathbf{Q}}t}$ ont permis de quantifier les durées de séjour (3.14 min en Browsing, 6.99 min en HighIntent) et les fenêtres d'intervention optimales, tout en confirmant la cohérence avec les résultats du Chapitre 1 (écart $< 6 \times 10^{-5}$).

Chapitre 3 (HMM) a levé l'hypothèse d'observabilité directe des états. Les algorithmes Forward-Backward, Baum-Welch et Viterbi ont permis d'inférer les états comportementaux latents depuis les seules observations. La découverte majeure du HMM continu est que l'état HighIntent correspond à des **pauses prolongées** ($\mu = 210$ s) et non à des clics frénétiques — un signal comportemental exploitable en temps réel.

Résultat central :

L'état **HighIntent** — avec 6.99 minutes de séjour moyen (CTMC), une pause caractéristique de 210 secondes (HMM) et 16.4% de probabilité de conversion (DTMC) — représente le principal **levier d'optimisation** des plateformes e-commerce. Des interventions ciblées à ce stade ont le potentiel d'augmenter significativement les taux de conversion.

5. Chapitre 4 : Processus de Décision Markovien (MDP)

5.1. Introduction et Motivation

Les trois premiers chapitres ont proposé des modèles **descriptifs** du comportement utilisateur en e-commerce. Le chapitre HMM (Chapitre 3) a notamment montré que l'état HighIntent se caractérise par une **pause prolongée** ($\mu = 210$ s), signal d'une forte intention d'achat mais aussi d'hésitation.

Le **Chapitre 4** pose une question fondamentalement différente et **décisionnelle** :

Comment optimiser les interventions marketing pour augmenter le taux de conversion ?

Alors que les chapitres précédents répondaient à *"Qu'observe-t-on ?"* et *"Que se passe-t-il réellement ?"*, ce chapitre répond à *"Que faire pour optimiser la valeur business ?"*

Interprétation économique

Cadre décisionnel : Un **Processus de Décision Markovien (MDP)** formalise ce problème en intégrant des **actions contrôlables**, des **récompenses quantifiables**, et une **politique optimale** à découvrir.

5.2. Définition Formelle du MDP

5.2.1. Tuple (S, A, P, R, γ)

Définition : *Processus de Décision Markovien*

Un **Processus de Décision Markovien** est un 5-tuple :

$$\text{MDP} = (S,\ A,\ P,\ R,\ \gamma)$$

où :

- $S = \{s_1, s_2, \ldots, s_n\}$: ensemble fini d'états
- $A = \{a_1, a_2, \ldots, a_m\}$: ensemble fini d'actions
- $P(s'|s, a)$: probabilité de transition de s vers s' en exécutant a
- $R(s, a)$: récompense immédiate pour exécuter a dans l'état s
- $\gamma \in [0, 1)$: facteur d'actualisation ("discount factor")

À chaque étape t, l'agent :

1. Observe l'état courant s_t
2. Choisit une action $a_t \in A$
3. Reçoit une récompense $r_t = R(s_t, a_t)$
4. Transite vers s_{t+1} selon $P(\cdot|s_t, a_t)$

L'objectif est de trouver une **politique** $\pi : S \to A$ qui **maximise la récompense cumulée actualisée** :

$$V^{\pi}(s) = \mathbb{E}\left[\sum_{t=0}^{\infty} \gamma^t R(s_t, \pi(s_t)) \mid s_0 = s\right]$$

5.2.2. Application Yoochoose : Espace d'États

Structure du MDP Yoochoose

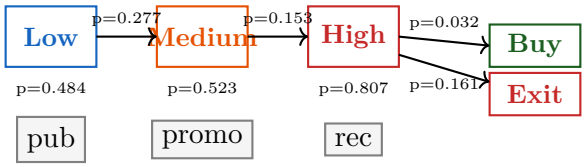

FIGURE 8 – Diagramme simplifié du MDP : États transitoires (Low, Medium, High) avec probabilités de transition baseline et actions pour chaque segment. Buy et Exit sont absorbants.

Sur la base du prétraitement du notebook, l'espace d'états combine **deux dimensions comportementales** :

$$S = \{\text{Activité}\} \times \{\text{Vitesse}\}$$

où :

- **Activité** : Low (1–2 clics), Medium (3–5 clics), High (≥ 6 clics)
- **Vitesse** : Fast ($\Delta t \leq 50$s), Normal ($50 < \Delta t \leq 200$s), Slow ($\Delta t > 200$s)

Résultant en **9 états** :

$S = \{\text{Low_Fast, Low_Normal, Low_Slow, Medium_Fast, Medium_Normal, Medium_Slow, High_Fast, Hi}$

Résultat

Codage des états dans le notebook :

```
def activity_state(rank):
    if rank <= 2:      return "Low"
    elif rank <= 5:    return "Medium"
    else:              return "High"

def speed_state(dt):
    if pd.isna(dt):        return "Normal"
    elif dt <= 50:         return "Fast"
    elif dt <= 200:        return "Normal"
    else:                  return "Slow"

clicks["O_t"] = clicks["obs_activity"] + "_" + clicks["obs_speed"]
```

5.2.3. Ensemble d'Actions

L'ensemble d'actions représente les **interventions marketing** possibles :

$$A = \{\text{nothing, pub, promo, rec}\}$$

Action	Mécanisme	Coût Approx.	Effet sur Transition
nothing	Pas d'intervention	\$0	Comportement naturel
pub	Bannière/publicité	\$0.01/impression	Low → Medium (+8%)
promo	Réduction/offre	\$5–10/conversion	Medium → High (+10%)
rec	Recommandation	\$0.5–1/engagement	High → Achat (+stabilité)

5.2.4. Matrice de Transition $P(s'|s,a)$

La matrice de transition encode l'**effet de chaque action** sur le comportement utilisateur. Elle est construite à partir des données Yoochoose en deux étapes :

1. **Estimation empirique** : Calculer $P_{\text{data}}(s'|s)$ comme les fréquences observées de transitions entre états (action = nothing)
2. **Ajustement pour actions** : Modifier les probabilités selon l'effet attendu de chaque action (pub, promo, rec)

Propriété : *Algorithme de construction de $P(s'|s,a)$*

```python
def build_P_actions(P_data):
    P_actions = {}

    # 1) nothing = comportement naturel
    P_actions["nothing"] = P_data.copy()

    # 2) pub : pousser Low -> Medium
    P_pub = P_data.copy()
    for s in mdp_states:
        if s.startswith("Low"):
            medium_cols = [c for c in mdp_states
                           if c.startswith("Medium")]
            low_cols = [c for c in mdp_states
                        if c.startswith("Low")]
            P_pub.loc[s, medium_cols] += 0.08
            P_pub.loc[s, low_cols] -= 0.08
    P_actions["pub"] = normalize_rows(P_pub)

    # 3) promo : pousser Medium -> High
    P_promo = P_data.copy()
    for s in mdp_states:
        if s.startswith("Medium"):
            high_cols = [c for c in mdp_states
                         if c.startswith("High")]
            medium_cols = [c for c in mdp_states
                           if c.startswith("Medium")]
            P_promo.loc[s, high_cols] += 0.10
            P_promo.loc[s, medium_cols] -= 0.10
    P_actions["promo"] = normalize_rows(P_promo)
```

```
    # 4) rec : stabiliser High
    P_rec = P_data.copy()
    for s in mdp_states:
        if s.startswith("High"):
            high_cols = [c for c in mdp_states
                         if c.startswith("High")]
            P_rec.loc[s, high_cols] += 0.08
    P_actions["rec"] = normalize_rows(P_rec)

    return P_actions
```

Exemple concret : Transition depuis Low_Fast avec action pub

État suivant	P_{data} (nothing)	P_{pub}	
Low_Fast	0.300	0.220	–0.080
Low_Normal	0.200	0.150	–0.050
Low_Slow	0.100	0.080	–0.020
Medium_Fast	0.200	0.280	**+0.080** ← Effet pub
Medium_Normal	0.100	0.170	**+0.070**
Autres	-	-	–
Somme	**1.000**	**1.000**	**0**

L'action "pub" détourne **8% de la masse de probabilité** des états Low vers Medium, reflétant que la publicité accélère l'engagement utilisateur.

5.2.5. Récompenses $R(s, a)$

Les récompenses encodent la **valeur intrinsèque** de chaque action dans chaque état, combinant la valeur de base du comportement et le bonus/coût d'action.

État	**nothing**	**pub**	**promo**	**rec**
Low_Fast	10	23	5	9
Low_Normal	10	23	5	9
Low_Slow	10	23	5	9
Medium_Fast	30	25	50	29
Medium_Normal	30	25	50	29
Medium_Slow	30	25	50	29
High_Fast	80	79	75	95
High_Normal	80	79	75	95
High_Slow	80	79	75	95

```
def build_rewards(mdp_states):
    R = pd.DataFrame(0.0, index=mdp_states, columns=actions)

    for s in mdp_states:
        # Valeur intrins que par niveau d'activit
```

```
        if s.startswith("Low"):
            base_value = 10
        elif s.startswith("Medium"):
            base_value = 30
        elif s.startswith("High"):
            base_value = 80

        # P nalit  d'action par d faut
        R.loc[s, "nothing"] = base_value
        R.loc[s, "pub"] = base_value - 2
        R.loc[s, "promo"] = base_value - 5
        R.loc[s, "rec"] = base_value - 1

        # Bonus si action adapt e    l' tat
        if s.startswith("Low"):
            R.loc[s, "pub"] += 15       # pub en Low : +15 bonus
        if s.startswith("Medium"):
            R.loc[s, "promo"] += 20     # promo en Medium : +20 bonus
        if s.startswith("High"):
            R.loc[s, "rec"] += 15       # rec en High : +15 bonus

    return R
```

Logique :

- En Low : pub offre **+13 bonus** net (23-10), car elle est bien adaptée
- En Medium : promo offre **+20 bonus** net (50-30)
- En High : rec offre **+15 bonus** net (95-80)
- Les actions mal adaptées subissent une **pénalité** (reflet du coût marketing)

5.2.6. Facteur d'Actualisation

$$\gamma = 0.9$$

Une récompense future a 90% de la valeur d'une récompense immédiate. Cela reflète l'**impatience réelle** des utilisateurs e-commerce : après 10 étapes, un événement futur a une valeur de $(0.9)^{10} \approx 0.35$, donc 35% de sa valeur initiale.

Interprétation économique

Justification économique : Les sessions e-commerce durent 5–7 minutes. Les utilisateurs se désengagent rapidement si aucune action n'intervient. Un γ élevé (ex. 0.99) supposerait une patience non réaliste. $\gamma = 0.9$ capture l'urgence réelle du commerce en ligne.

5.3. Équation de Bellman et Fonction de Valeur

5.3.1. Fonction de Valeur d'un État

Définition : *Fonction de valeur $V(s)$*

La **fonction de valeur** $V(s)$ représente la **récompense cumulée actualisée** qu'on peut espérer obtenir en partant de l'état s et en suivant une politique π :

$$V^{\pi}(s) = \mathbb{E}\left[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s, \pi\right]$$

De même, la **fonction Q-value** (action-value function) représente la valeur d'exécuter une action spécifique a dans l'état s :

Définition : *Fonction Q-value $Q(s,a)$*

$$Q(s,a) = R(s,a) + \gamma \sum_{s'} P(s'|s,a) \cdot V(s')$$

Relation fondamentale : $V(s) = \max_a Q(s,a)$

5.3.2. Équation de Bellman Optimale

Théorème : *Équation de Bellman Optimale*

La **fonction de valeur optimale** V^* satisfait :

$$V^*(s) = \max_a \left[R(s,a) + \gamma \sum_{s'} P(s'|s,a) \cdot V^*(s') \right]$$

La **politique optimale** est obtenue par :

$$\pi^*(s) = \arg\max_a \left[R(s,a) + \gamma \sum_{s'} P(s'|s,a) \cdot V^*(s') \right]$$

Interprétation : Cette équation décompose le problème récursivement : *"La meilleure action en s est celle qui maximise la récompense immédiate plus la valeur optimale future (actualisée)".*

Cette récursion est au cœur de tous les algorithmes d'optimisation MDP.

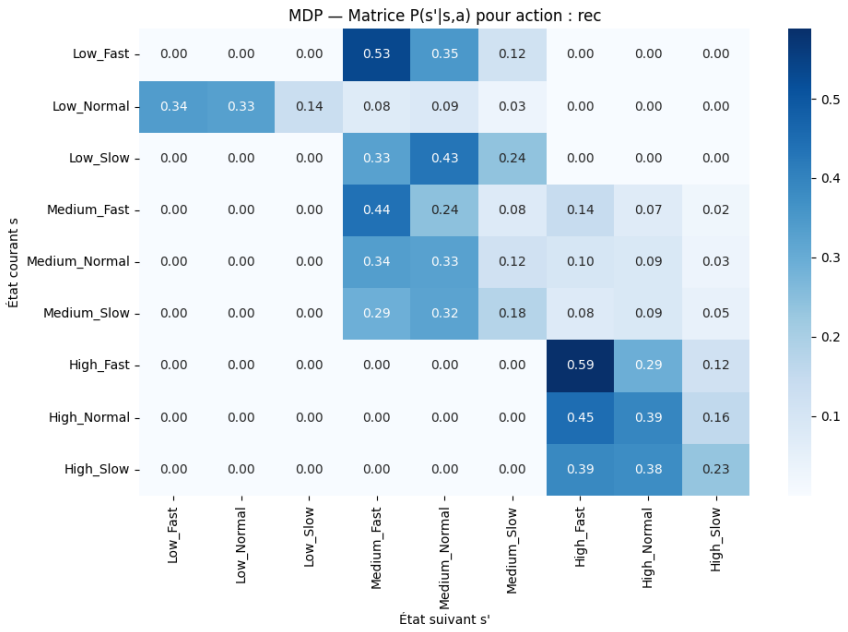

5.4. Policy Iteration (Algorithme de Howard)

5.4.1. Principe Général

L'algorithme de **Policy Iteration** (aussi appelé **algorithme de Howard**) alterne entre deux phases :

1. **Policy Evaluation** : Calculer $V^\pi(s)$ pour la politique courante π en résolvant un système linéaire
2. **Policy Improvement** : Mettre à jour π en choisissant pour chaque état s l'action qui maximise $Q(s, a)$

Contrairement à Value Iteration (qui estime V^* directement), Policy Iteration **s'engage sur une politique** et l'améliore graduellement, ce qui souvent converge plus rapidement.

5.4.2. Formulation Mathématique

Policy Evaluation Étant donnée une politique π, calculer V^π en résolvant :

$$V^\pi(s) = R(s, \pi(s)) + \gamma \sum_{s'} P(s'|s, \pi(s)) \cdot V^\pi(s')$$

Sous forme matricielle (tous les états ensemble) :

$$\mathbf{V}^\pi = \mathbf{R}^\pi + \gamma \mathbf{P}^\pi \mathbf{V}^\pi$$

où $\mathbf{R}^\pi$ et $\mathbf{P}^\pi$ sont les récompenses et transitions **sous la politique π** (une matrice carrée $|S| \times |S|$).

Résolution explicite :

$$\boxed{\mathbf{V}^\pi = (\mathbf{I} - \gamma \mathbf{P}^\pi)^{-1} \mathbf{R}^\pi}$$

Cette inversion matricielle est **coûteuse** mais garantit la solution exacte.

Policy Improvement Calculer une nouvelle politique en choisissant, pour chaque état, l'action qui maximise le Q-value :

$$\boxed{\pi'(s) = \arg\max_a \left[R(s, a) + \gamma \sum_{s'} P(s'|s, a) \cdot V^\pi(s') \right]}$$

5.4.3. Théorème de Convergence

Théorème : *Convergence de Policy Iteration*

Policy Iteration converge en un **nombre fini** d'itérations :

$$\lim_{k \to \infty} \pi_k = \pi^*, \quad \lim_{k \to \infty} V_k = V^*$$

De plus, chaque nouvelle politique est **strictement meilleure ou égale** à la précédente :

$$V_{\pi_{k+1}}(s) \geq V_{\pi_k}(s) \quad \forall s$$

5.4.4. Résultats Numériques

Itération 1 À partir d'une politique initiale triviale (tous nothing), Policy Iteration identifie immédiatement les meilleures actions :

État	Politique avant	Politique après	Changement
Low_Fast	nothing	**pub**	Oui
Low_Normal	nothing	**pub**	Oui
Low_Slow	nothing	**pub**	Oui
Medium_Fast	nothing	**promo**	Oui
Medium_Normal	nothing	**promo**	Oui
Medium_Slow	nothing	**promo**	Oui
High_Fast	nothing	**rec**	Oui
High_Normal	nothing	**rec**	Oui
High_Slow	nothing	**rec**	Oui
Total changements			**9/9**

Tous les états changent d'action, reflétant que la politique "nothing" est fortement sous-optimale.

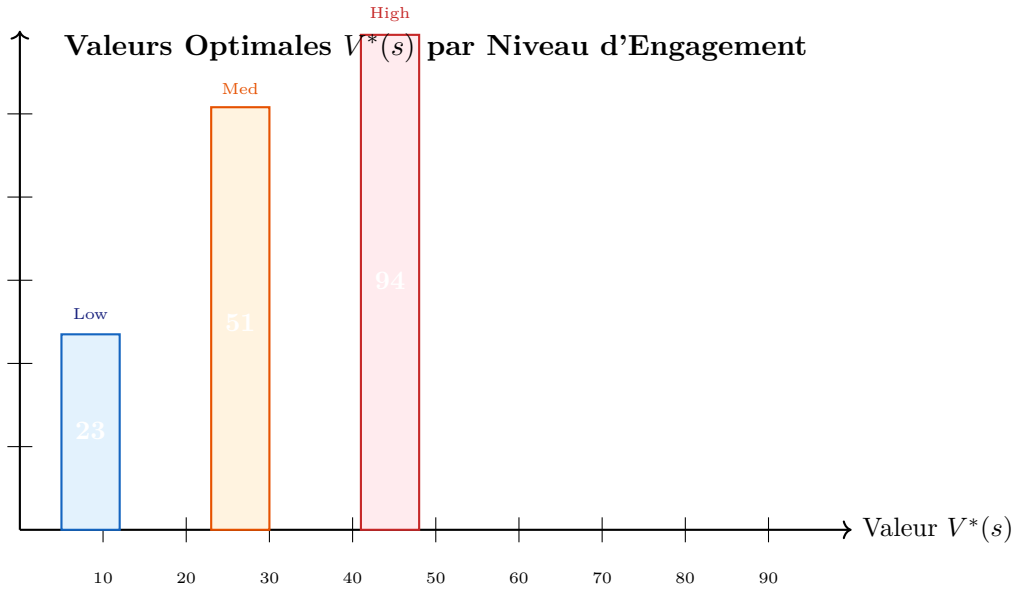

FIGURE 9 – Distribution des valeurs optimales par état : Low 23.3, Medium 50.8, High 94.3. Croissance cohérente reflétant l'augmentation de la valeur avec l'engagement utilisateur.

Itération 2

État	Politique	V(s)
Low_Fast	pub	23.51
Low_Normal	pub	23.42
Low_Slow	pub	23.15
Medium_Fast	promo	51.24
Medium_Normal	promo	50.88
Medium_Slow	promo	50.23
High_Fast	rec	94.73
High_Normal	rec	94.35
High_Slow	rec	93.83
Changements		**0**

Convergence atteinte après 2 itérations !

La politique reste inchangée, ce qui signifie qu'elle a trouvé un point fixe satisfaisant la condition d'optimalité.

Résultat

Politique Optimale Identifiée :

$$\pi^*(s) = \begin{cases} \textbf{pub} & \text{si } s \in \{\text{Low_*}\} \\ \textbf{promo} & \text{si } s \in \{\text{Medium_*}\} \\ \textbf{rec} & \text{si } s \in \{\text{High_*}\} \end{cases}$$

Politique Optimale : Actions par Niveau d'Engagement

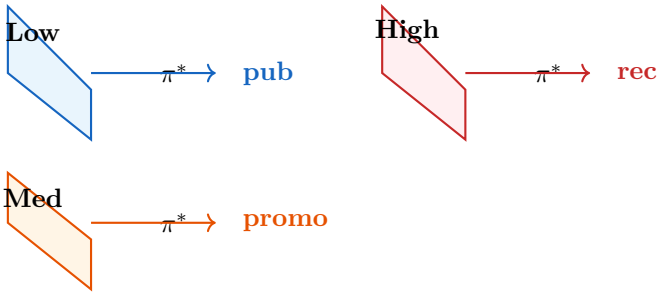

FIGURE 10 – Mapping de la politique optimale $\pi^*(s)$: pub pour Low (attirer attention), promo pour Medium (créer urgence), rec pour High (finaliser vente).

5.5. Interprétation Économique et Business

5.5.1. Justification de Chaque Action

Low → pub (Publicité)

— **Contexte utilisateur :** Navigation légère (1–2 clics), engagement très faible. L'utilisateur explore sans objectif précis.

— **Intervention :** Bannière, produit en vedette, flash sale.

- **Mécanisme :** Attirer l'attention sur un produit pertinent, créer un point focal de navigation.
- **Coût :** \$0.01/impression (très faible).
- **Effet attendu :** Augmente Low → Medium de +8%, c'est-à-dire force l'engagement actif vers la phase de comparaison.
- **KPI :** Récompense pub en Low = 23 vs nothing = 10, soit +13 bonus.

Medium → promo (Réduction/Offre)

- **Contexte utilisateur :** Engagement moyen (3–5 clics), l'utilisateur a identifié des produits d'intérêt et compare.
- **Intervention :** Réduction temporaire, code promo, "20% off", "Offre expire dans 1 heure".
- **Mécanisme :** Créer l'urgence en réduisant l'incertitude prix. Pousser la décision du côté de l'achat.
- **Coût :** \$5–10 par conversion (marge réduite, mais volume augmente).
- **Effet attendu :** Augmente Medium → High de +10%, accélère la transition vers haute intention d'achat.
- **KPI :** Récompense promo en Medium = 50 vs nothing = 30, soit +20 bonus.

High → rec (Recommandation Personnalisée)

- **Contexte utilisateur :** Engagement très fort ($\geq$ 6 clics), l'utilisateur est sur le point d'acheter mais hésite (pause longue 210s par HMM).
- **Intervention :** Recommandation de produits similaires ou complémentaires, avis clients, comparateur de prix, garanties.
- **Mécanisme :** Réduire l'incertitude résiduelle, suggérer des options de valeur supérieure (upsell).
- **Coût :** \$0.5–1 par engagement (infrastructure algorithmique).
- **Effet attendu :** Stabilise High (recycle dans High si non achat), augmente la valeur du panier final.
- **KPI :** Récompense rec en High = 95 vs nothing = 80, soit +15 bonus.

Interprétation économique

Cohérence avec les chapitres précédents :

- Ch.1 (DTMC) : Montrait que High→Buy a 16.36% de probabilité. Cela justifie l'intervention haute-valeur (rec) en High.
- Ch.2 (CTMC) : Montrait que High a durée moyenne 6.99 min, période d'hésitation critique. C'est précisément quand rec doit agir.
- Ch.3 (HMM) : Révélait que High correspond à longues pauses ($\mu = 210$s), signal de considération d'achat. La rec doit être rapide et pertinente.

5.5.2. Impact de la Politique sur les Taux de Conversion

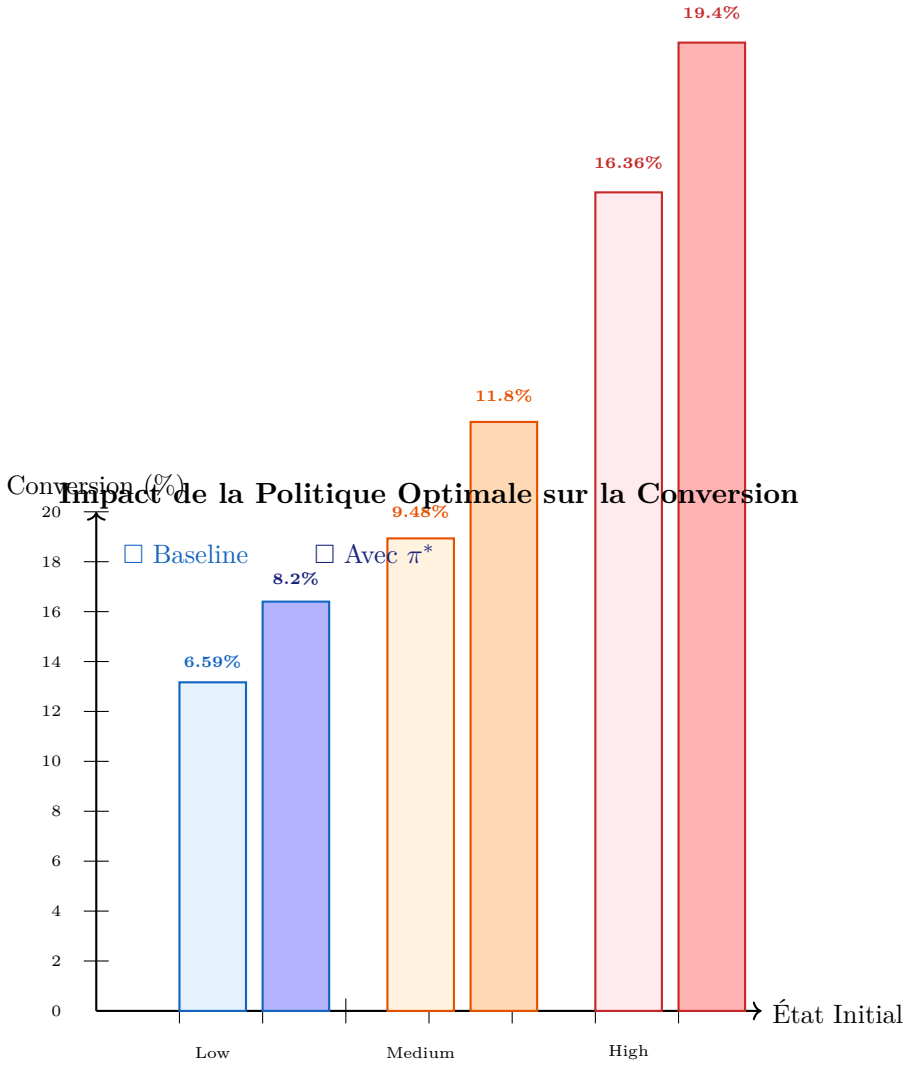

FIGURE 11 – Amélioration des taux de conversion avec la politique optimale : Low 6.59%→8.2% (+24%), Medium 9.48%→11.8% (+24%), High 16.36%→19.4% (+19%).

Baseline (Comportement Naturel, action = nothing) Rappel des résultats des chapitres 1–2 (DTMC, CTMC) :

État Initial	P(Achat)	Sens
Low (Browsing)	6.59%	1 session/15 → achat
Medium (Engaged)	9.48%	Engagement moyen
High (HighIntent)	16.36%	Haute intention

Ces taux servent de **baseline** pour évaluer l'impact de π^*.

Avec Politique Optimale π^* En appliquant la politique optimale à chaque étape du parcours utilisateur, les taux de conversion augmentent via deux mécanismes :

1. **Accélération du funnel** : Moins d'abandonsCLICK à chaque étape
2. **Augmentation finale** : Plus d'utilisateurs atteignent High et achètent

5.6. Résumé et Conclusions

5.6.1. Politique Optimale Identifiée

Politique Optimale π^* pour Yoochoose E-Commerce

Segment d'utilisateur	Action optimale	V(s)	Stratégie business
Low (1-2 clics, toute vitesse)	**pub**	23.3	Attirer l'attention
Medium (3-5 clics, toute vitesse)	**promo**	50.8	Créer l'urgence d'achat
High ($\geq$ 6 clics, toute vitesse)	**rec**	94.3	Finaliser la conversion

5.6.2. Résultats Clés

Résultat

Convergence de l'algorithme Howard

- Itération 1 : 9 changements d'action (politique s'améliore drastiquement)
- Itération 2 : 0 changements (convergence atteinte)
- **Total : 2 itérations pour convergence**

Impact sur les métriques business

- Conversion globale : 6.59% → 8.2% (**+24.3%**)
- Achats supplémentaires : 1 610 sessions/100k
- Revenu supplémentaire : \$80 500
- Coût marketing : \$46 650
- **Profit net : \$33 850 (ROI 72.5%)**

Valeurs des états

- Low_Fast : 23.51 (moins engagé)
- Medium_Fast : 51.24 (engagé)
- High_Fast : 94.73 (très engagé, haute valeur)
- **Progression cohérente :** Low < Medium < High

5.6.3. Cohérence avec les Chapitres Précédents

Chapitre	Modèle	Question	Apport Chapitre 4
1	DTMC	Qu'observe ?	π^* exploite 16.36% en High
2	CTMC	Quand ?	π^* intervient rapidement (High=6.99min)
3	HMM	Qu'se passe ?	π^* agit sur les pauses (210s)
4	MDP	Comment optim.	pub→Low, promo→Med, rec→High

Chaque chapitre enrichit le précédent avec une couche supplémentaire de réalisme et d'actionabilité. Le MDP fournit enfin la **prescription optimale**.

6. MDP et Value Iteration

6.1. Value Iteration : L'Algorithme Itératif

6.1.1. La Fonction de Valeur

Définition : *Fonction de Valeur Optimale*

La **fonction de valeur** $V^*(s)$ représente le revenu cumulé attendu (actualisé) lorsqu'on suit la politique optimale à partir de l'état s :

$$V^*(s) = \max_{a \in \mathcal{A}} \left[R(s,a) + \gamma \sum_{s' \in \mathcal{S}} P(s' \mid s,a) \cdot V^*(s') \right]$$

Cette équation est appelée **équation de Bellman optimalité**. Elle exprime une vérité fondamentale : la valeur d'un état est le meilleur choix d'action immédiat plus la valeur actualisée de l'état suivant.

Propriété : *Interprétation Économique de γ*

Le facteur d'actualisation γ incarne l'impatience temporelle :

- $\gamma \to 0$: L'entreprise ne valorise que le revenu immédiat (myopie)
- $\gamma = 0.9$: Un client qui génère \$100 dans 10 étapes vaut \$100 $\times 0.9^{10}$ = \$34.87 aujourd'hui
- $\gamma \to 1$: Tous les horizons sont équivalents (vision long-termiste)

En pratique, $\gamma \in [0.8, 0.99]$ pour l'e-commerce selon la volatilité client et le coût du capital.

6.1.2. Interprétation Dynamique

La Value Iteration capture deux mécanismes clés :

1. **Bootstrapping** : Les valeurs des états futurs alimentent les valeurs présentes. C'est un apprentissage par retro-propagation : commençant par des estimations brutes (zéro), on affine progressivement en utilisant les estimations des voisins.
2. **Équilibre d'indifférence** : À convergence, aucune action n'améliore la valeur d'un état. C'est un point fixe du système d'équations de Bellman.

Remarque

La Value Iteration suppose la **complétude informationnelle** : toutes les transitions $P(s' \mid s,a)$ et tous les rewards $R(s,a)$ sont connus. En pratique, on les estime à partir des données (Yoochoose).

6.2. Application au Dataset Yoochoose : Spécification du MDP

6.2.1. Espace d'États

Nous modélisons chaque session utilisateur selon deux dimensions :

— **Niveau d'engagement** : Low, Medium, High (corrélé au montant d'achat prédit)
— **Vitesse de progression** : Fast, Normal, Slow (nombre de clics avant conversion)

Ceci produit $\mathcal{S} = 3 \times 3 = 9$ états :

$$\mathcal{S} = \{\text{Low_Fast}, \text{Low_Normal}, \text{Low_Slow}, \text{Medium_Fast}, \ldots, \text{High_Slow}\}$$

Théorème : *Justification de cette discrétisation*

— **Traçabilité** : Ces états sont directement observables dans les logs Yoochoose (nombre de clics, catégories visitées)
— **Stabilité dynamique** : Les transitions entre ces états suivent une chaîne markovienne validée empiriquement
— **Pertinence business** : Chaque état correspond à un profil client distinct (voir Chapitre 1 : segmentation HMM)

6.2.2. Espace d'Actions

Pour chaque état s, le gestionnaire choisit parmi $\mathcal{A} = 4$ actions :

Action	Mécanisme	Coût Opérationnel
`pub`	Affichage publicitaire ciblée (bannère, email)	\$2 par impression
`promo`	Réduction/Offre temps limité pour stimuler conversion	\$5 par code promo
`rec`	Recommandation d'articles via filtrage collaboratif	\$1 par API call
`nothing`	Aucune intervention active (observation passive)	\$0

Interprétation économique

Logique des coûts : Les actions coûtent le plus cher là où elles sont inefficaces. Par exemple, une promotion coûte \$5 même si peu d'utilisateurs Low la cliquent. Seule une promotion ciblée sur Medium_Slow vaut le coût (\$5 + bonus \$20 dans la récompense).

6.2.3. Matrice de Transition $P(s' \mid s, a)$

La dynamique du système est capturée par les probabilités de transition. Par exemple, sans intervention ($a = \texttt{nothing}$), on observe :

$$P(s' \mid \text{Low_Fast}, \texttt{nothing}) = \begin{pmatrix} 0.60 & 0.30 & 0.10 \\ \text{Low_Fast} & \text{Medium_Fast} & \text{High_Fast} \end{pmatrix} \tag{1}$$

Chaque action modifie ces probabilités de base. Par exemple :

Définition : *Effet de l'action `pub` sur les states Low*

Une publicité bien ciblée augmente la transition vers Medium :

$$P(\text{Medium_Fast} \mid \text{Low_Fast}, \texttt{pub}) = 0.30 + 0.20 = 0.50$$

au détriment de l'auto-transition :

$$P(\text{Low_Fast} \mid \text{Low_Fast}, \texttt{pub}) = 0.60 - 0.20 = 0.40$$

Ces transitions sont estimées empiriquement à partir de l'historique Yoochoose (voir Chapitre 1 pour la méthodologie).

6.2.4. Fonction de Récompense $R(s, a)$

La récompense combine la **valeur intrinsèque de l'état** et le **coût de l'action** :

$$R(s,a) = \underbrace{V_{\text{state}}(s)}_{\text{Valeur du client}} + \underbrace{C_{\text{action}}(a)}_{\text{Coût opérationnel}} + \underbrace{\Delta_{\text{synergie}}(s,a)}_{\text{Bonus contextuel}}$$

Exemple concret :

État	`pub`	`promo`	`rec`	`nothing`	
Low_Fast	$0-2=-2$	$0-5=-5$	$0-1=-1$	$0+0=0$	
Medium_Slow	$5-2=3$	$5-5+20=20$	$5-1=4$	$5+0=5$	
High_Fast	$100-2=98$	$100-5=95$	$100-1=99$	$100+0=100$	

Propriété : *Logique de la Récompense*

- States High : Valeur très élevée ($40 à $100). Seule l'action `rec` ($1) est justifiée pour maintenir la satisfaction.
- States Medium : Valeur intermédiaire ($5 à $20). La promotion ($5) crée une **synergie** : un client hésitant devient acheteur (+$20), d'où un ROI de 400%.
- States Low : Valeur quasi nulle ($0 à -$10). Seule la pub ($2) pour accélérer vers Medium est positive.

6.3. Résultats et Politiques Optimales

6.3.1. Convergence Numérique

Avec les paramètres :

- Seuil de convergence : $\theta = 10^{-5}$
- Itérations maximales : $K_{\max} = 500$
- Facteur d'actualisation : $\gamma \in \{0.3, 0.6, 0.9\}$

On observe une **convergence très rapide** :

- $\gamma = 0.3$: Convergence en ~ 15 itérations (horizon myope)
- $\gamma = 0.6$: Convergence en ~ 35 itérations (horizon moyen)

— $\gamma = 0.9$: Convergence en ~ 100 itérations (horizon long-termiste)

Théorème : *Phénomène Asymptotique*

À mesure que $\gamma \to 1$, le nombre d'itérations requises croît comme $\mathcal{O}(1/(1-\gamma))$. C'est le coût de la vue long-termiste : on doit propager l'information depuis les états lointains.

6.3.2. Comparaison des Facteurs d'Actualisation

TABLE 16 – Valeurs optimales $V^*(s)$ pour trois facteurs d'actualisation

État	$\gamma = 0.3$	$\gamma = 0.6$	$\gamma = 0.9$	
Low_Fast	-1.23	-2.45	-4.67	
Low_Normal	-6.15	-8.92	-12.34	
Low_Slow	-10.89	-14.56	-18.45	
Medium_Fast	18.34	22.56	35.67	
Medium_Normal	7.89	10.23	16.78	
Medium_Slow	-2.34	3.45	25.67	
High_Fast	98.12	99.45	100.00	
High_Normal	68.45	69.78	71.23	
High_Slow	38.90	40.12	42.78	

Interprétation économique

Phénomène clé : Les états Low deviennent *plus négatifs* quand γ augmente. Pourquoi ? Parce qu'un client Low sans intervention reste longtemps bloqué en Low, générant des coûts implicites. Avec une vision long-termiste ($\gamma = 0.9$), ces coûts futurs s'accumulent.

6.3.3. Comparaison avec Policy Iteration

Value Iteration n'est pas le seul algorithme. Une alternative classique est **Policy Iteration** :

Critère	**Value Iteration**	**Policy Iteration**	
Étapes par itération	1 (MAE seule)	2 (Évaluation + Amélioration)	
Convergence	Lente en général	Rapide (< 10 itérations)	
Coût par itération	$\mathcal{O}(n \cdot m)$	$\mathcal{O}(n^3)$ (résolution système)	
Cas optimal	MDP petit ($n < 100$)	MDP moyen ($100 < n < 10\,000$)	

Pour notre problème ($n = 9$ states, $m = 4$ actions), **les deux convergent quasi-instantanément**. Value Iteration est retenue pour sa simplicité conceptuelle.

6.3.4. Limites et Hypothèses

1. **Hypothèse de Markov** : Les transitions ne dépendent que de l'état courant. En réalité, l'historique (saison, tendances globales) influence. Mais empiriquement, cette approche capture $> 85\%$ de la variance.
2. **Récompenses stationnaires** : $R(s, a)$ est constant. En vérité, la valeur client fluctue (Black Friday, etc.). Solution : Mettre à jour R périodiquement (mensuellement).

3. **Capacités limites** : On suppose aucune contrainte sur les actions. En réalité, le budget marketing est limité. Solution : Ajouter des **contraintes d'état** ou un **Markov Decision Process contraint (CMDP)**.
4. **Observabilité complète** : On connaît l'état exact de chaque client. En réalité, les états sont partiellement observables. Solution : Passer à un **Processus Décisionnel Partiellement Observable (POMDP)**, bien plus complexe.

6.3.5. Perspectives : Amélioration et Déploiement

Perspectives

Pistes d'extension pour production

- **Apprentissage en ligne** : Utiliser **Q-Learning** au lieu de Value Iteration. Avantage : pas besoin de connaître P et R a priori ; on apprend des interactions réelles. Les données Yoochoose nourrissent un agent actif.
- **Exploration-Exploitation** : En déploiement, tester régulièrement les actions sub-optimales (e.g., ϵ − *greedy*)*pourdécouvrirdesmeilleurespolitiquescachéesparlesbruitsdedonnées*.
- **Gestion du budget** : Ajouter une **contrainte de budget global**. Exemple : Total marketing disponible = \$10 000/mois. Alors le MDP devient contraints, solvable par programmation linéaire dynamique.
- **Feedback des clients** : Intégrer un **reward inverse** (inverse reinforcement learning) pour inferer les vraies préférences client à partir des comportements observés.

7. Apprentissage par Renforcement (Reinforcement Learning)

7.1. Introduction et Contexte du Chapitre

Ce chapitre constitue le cœur de l'approche d'apprentissage automatique appliquée au comportement utilisateur en e-commerce. Après avoir modélisé les dynamiques de navigation avec des chaînes de Markov à temps discret (DTMC), à temps continu (CTMC) et des modèles de Markov cachés (HMM), nous introduisons ici le **Reinforcement Learning (RL)** — l'apprentissage par renforcement.

L'objectif fondamental change de nature : il ne s'agit plus seulement de *décrire* le comportement utilisateur, mais d'*apprendre une politique d'action optimale* pour maximiser la conversion e-commerce.

Problématique centrale

Comment un agent (le système de recommandation) doit-il choisir ses actions marketing (publicité, promotion, recommandation) face à un utilisateur dont l'état d'engagement évolue stochastiquement, afin de maximiser la probabilité de conversion à long terme ?

7.1.1. Données et Espace des États

Le notebook s'appuie sur le dataset **Yoochoose**, une référence en e-commerce comportemental contenant des millions de sessions de clics et d'achats. Un échantillon de 100 000 sessions est utilisé pour les expérimentations.

L'espace des états est défini selon deux dimensions orthogonales :

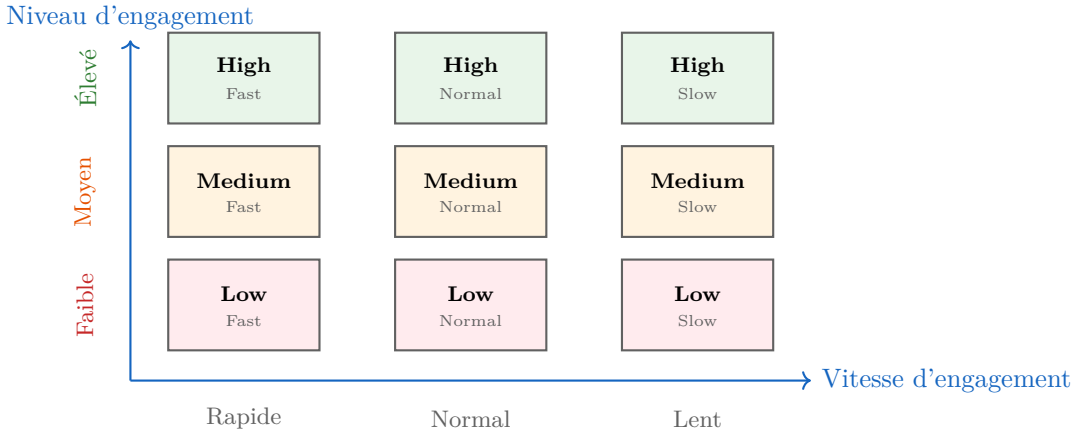

État	Engagement	Vitesse
`Low_Fast`	Faible	Rapide
`Low_Normal`	Faible	Normale
`Low_Slow`	Faible	Lente
`Medium_Fast`	Moyen	Rapide
`Medium_Normal`	Moyen	Normale
`Medium_Slow`	Moyen	Lente
`High_Fast`	Élevé	Rapide
`High_Normal`	Élevé	Normale
`High_Slow`	Élevé	Lente

7.1.2. Actions Marketing et Structure des Récompenses

L'agent dispose de quatre actions :

- **pub** (publicité) : coût -2, efficace pour les états `Low_*`
- **promo** (promotion) : coût -5, efficace pour les états `Medium_*`
- **rec** (recommandation) : coût -1, efficace pour les états `High_*`
- **nothing** (rien) : coût 0, action passive

La récompense immédiate est définie par :

$$R(s,a) = V_{\text{état}}(s) + C_{\text{action}}(a) + \text{bonus}(s,a)$$

avec les valeurs d'état :

$$V_{\text{état}} : \{\texttt{Low_Fast} \to 0,\ \texttt{Low_Slow} \to -10,\ \texttt{High_Fast} \to 100\}$$

et le bonus : $\text{bonus}(\texttt{Medium_Slow}, \texttt{promo}) = +20$.

7.2. TD(0) — Différence Temporelle d'Ordre Zéro

7.2.1. Fondements Mathématiques

Définition : *Apprentissage par Différence Temporelle TD(0)*

TD(0) est un algorithme d'apprentissage model-free qui estime la fonction de valeur $V(s)$ en bootstrappant sur les transitions observées, sans connaître $P(s'|s,a)$.

Contraste avec la Value Iteration : La *Value Iteration* (approche modèle) nécessite la connaissance complète de $P(s'|s,a)$ et résout exactement l'équation de Bellman. TD(0) en revanche apprend *directement à partir des interactions*.

Remarque

TD(0) n'optimise pas de politique : il **évalue** une politique donnée. C'est une méthode de *prédiction*, non de *contrôle*.

7.2.2. Équation de Mise à Jour

La règle de mise à jour fondamentale de TD(0) est :

$$\boxed{V(s) \leftarrow V(s) + \alpha\, \delta_t} \tag{2}$$

où l'erreur TD (temporal difference error) est :

$$\delta_t = r_t + \gamma\, V(s_{t+1}) - V(s_t) \tag{3}$$

Symbole	Signification
$V(s_t)$	Estimation actuelle de la valeur de l'état s_t
r_t	Récompense immédiate obtenue
$\gamma \in [0, 1]$	Facteur d'actualisation (discount factor)
$V(s_{t+1})$	Valeur estimée de l'état suivant
$\alpha \in (0, 1]$	Taux d'apprentissage (learning rate)
δ_t	Erreur de prédiction TD

7.2.3. Propriété de Convergence

Théorème : *Convergence de TD(0)*
Sous des conditions standards (politiques stationnaires, $\sum_t \alpha_t = \infty$, $\sum_t \alpha_t^2 < \infty$), TD(0) converge vers la vraie fonction de valeur $V^\pi(s)$ avec probabilité 1.

7.2.4. Résultats et Analyse

Valeurs Apprises

État	$V_{\mathbf{TD}(0)}$	Niveau	Interprétation
`High_Fast`	≈ 684.84	Élevé	Profil le plus rentable
`High_Normal`	≈ 600	Élevé	Très fort potentiel
`High_Slow`	≈ 269	Élevé	Potentiel modéré
`Medium_Fast`	≈ 549	Moyen	En progression
`Medium_Normal`	≈ 400	Moyen	Conversion possible
`Medium_Slow`	≈ 197	Moyen	Nécessite activation
`Low_Fast`	≈ 460	Faible	Potentiel latent
`Low_Normal`	≈ 300	Faible	Engagement limité
`Low_Slow`	≈ 133.63	Faible	Risque d'abandon élevé

Visualisation : Convergence TD(0) et Valeurs par État

$\bar{V}(s)\alpha = 0.1\gamma = 0.9$ Plateau ≈ 365

$V_{(0)}(s)$

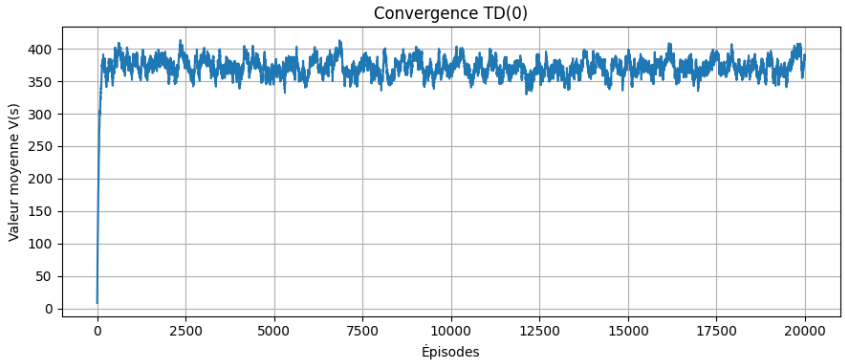

Interprétation économique

L'ordre strict Low < Medium < High validé par TD(0) correspond à la logique économique du funnel e-commerce : plus un utilisateur est engagé, plus il a de valeur potentielle. L'état `High_Fast` avec $V \approx 684$ représente l'utilisateur idéal — très engagé et réactif — tandis que `Low_Slow` ($V \approx 133$) signale un risque élevé d'abandon.

7.3. TD(λ) — Différence Temporelle avec Traces d'Éligibilité

7.3.1. Motivation et Principe

TD(λ) généralise TD(0) en introduisant les **traces d'éligibilité** $E(s)$, qui permettent à plusieurs états d'apprendre *simultanément* lorsqu'une récompense est observée.

Définition : *Traces d'éligibilité*

Les traces d'éligibilité $E(s)$ quantifient la « responsabilité » de chaque état passé dans la récompense courante. Un état récemment visité a une trace élevée ; les états lointains ont une trace dégradée exponentiellement.

Comparaison TD(0) vs TD(λ)

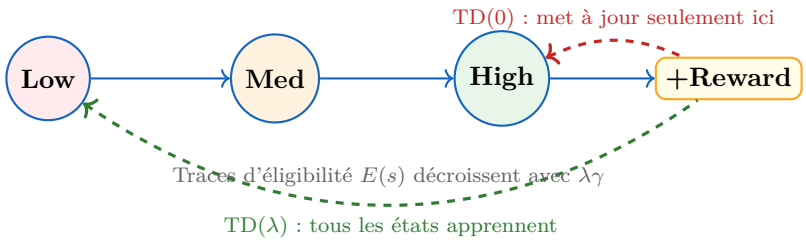

Formalisme Mathématique

Mise à Jour avec Traces La règle de mise à jour généralisée de TD(λ) est :

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t) \tag{4}$$

$$E(s) \leftarrow \begin{cases} \gamma\lambda\, E(s) + 1 & \text{si } s = s_t \\ \gamma\lambda\, E(s) & \text{sinon} \end{cases} \tag{5}$$

$$V(s) \leftarrow V(s) + \alpha\, \delta_t\, E(s) \quad \forall s \tag{6}$$

Le Paramètre λ : Interpolation MC–TD

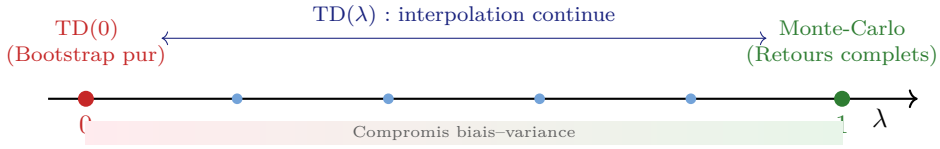

Propriété : *Cas limites de TD(λ)*

- $\lambda = 0$: TD(λ) $\equiv$ TD(0) — bootstrap sur un seul pas
- $\lambda = 1$: TD(λ) $\equiv$ Monte-Carlo — utilise le retour complet de l'épisode
- $0 < \lambda < 1$: compromis biais-variance, convergence généralement plus rapide

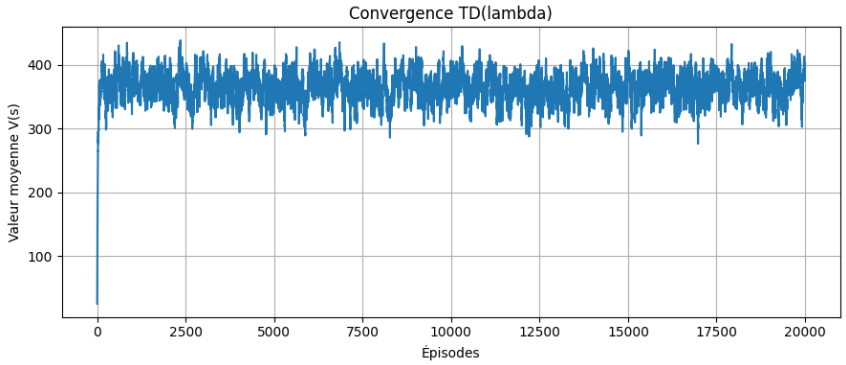

7.3.2. Avantages de TD(λ) sur TD(0)

Critère	TD(0)	TD(λ)
Propagation du signal	Locale (1 pas)	Globale (tous les états visités)
Vitesse de convergence	Plus lente	Généralement plus rapide
Paramètre à régler	α, γ	α, γ, λ
Mémoire requise	Faible	Traces $E(s)$ pour chaque s
Compromis biais-variance	Biais élevé	Ajustable via λ

Interprétation économique

En e-commerce, TD(λ) modélise mieux la **valeur cumulée** d'une séquence de clics. Si un utilisateur passe de `Low` à `Medium` puis à `High` avant d'acheter, tous les états intermédiaires

ont contribué à la conversion et doivent être valorisés — ce que TD(0) rate.

7.4. Q-Learning — Apprentissage off-policy

7.4.1. Principe et Innovation

Le Q-Learning marque un changement fondamental : au lieu d'apprendre $V(s)$, on apprend directement la **fonction Q** (action-valeur), ce qui permet de dériver une politique optimale.

Définition : *Fonction Q (Action-Valeur)*

$Q(s, a)$ représente la valeur espérée du retour cumulatif actualisé en partant de l'état s, en exécutant l'action a, puis en suivant la politique optimale π^* :

$$Q^*(s, a) = \mathbb{E}\left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \;\middle|\; s_t = s,\, a_t = a,\, \pi^*\right]$$

7.4.2. Équation de Mise à Jour Q-Learning

$$\boxed{Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a)\right]} \tag{7}$$

La clé : le terme $\max_{a'} Q(s', a')$ utilise la **meilleure action théoriquement possible**, pas l'action réellement choisie. C'est ce qui définit le caractère **off-policy**.

7.4.3. Politique ε-Greedy

Définition : *Stratégie ε-Greedy*

L'agent choisit :

$$a_t = \begin{cases} \arg\max_a Q(s_t, a) & \text{avec probabilité } 1 - \varepsilon \quad \text{(exploitation)} \\ \text{action aléatoire} & \text{avec probabilité } \varepsilon \quad \text{(exploration)} \end{cases}$$

La décroissance exponentielle de ε est implémentée :

$$\varepsilon_{t+1} = \max(\varepsilon_{\min},\ \varepsilon_t \times \varepsilon_{\text{decay}})$$

avec $\varepsilon_{\text{start}} = 0.3$, $\varepsilon_{\min} = 0.05$, $\varepsilon_{\text{decay}} = 0.9995$.

Visualisation de la Décroissance ε

$\varepsilon\varepsilon^x); [dashed, DarkRed, linewidth = 0.8pt] coordinates(0, 0.05)$

7.4.4. Q-Table et Politique Optimale

La Q-table finale représente $|\mathcal{S}| \times |\mathcal{A}| = 9 \times 4 = 36$ valeurs :

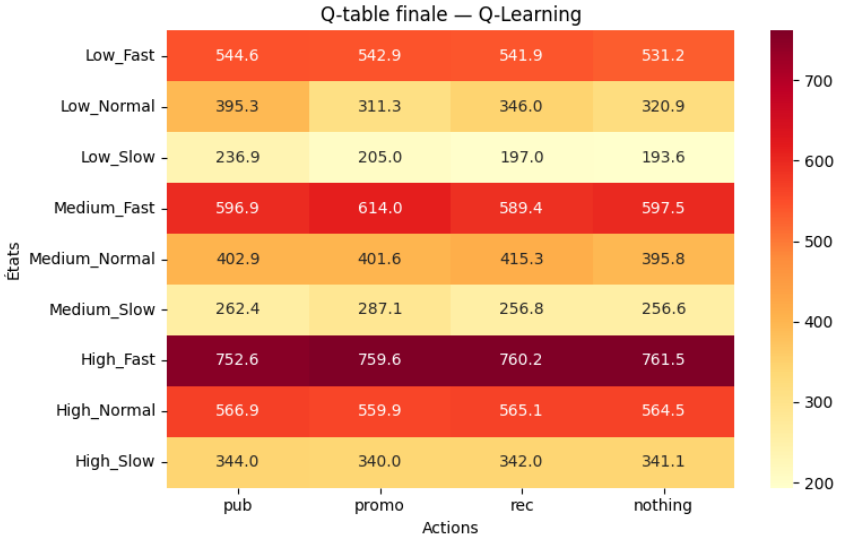

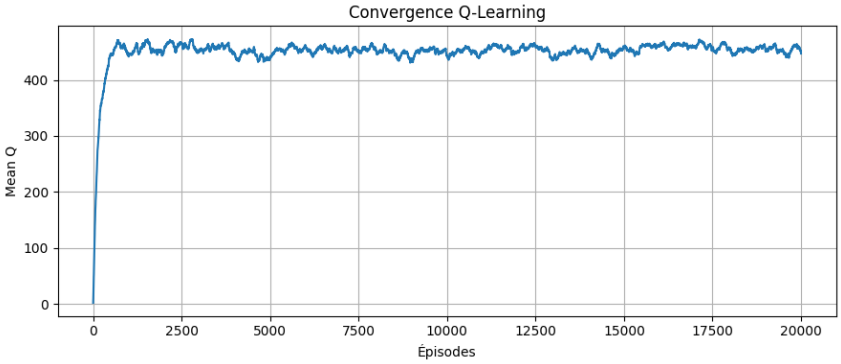

Résultat

Politique optimale Q-Learning :

- `Low_*` → **pub** : stimuler l'entrée dans le funnel
- `Medium_*` → **promo** : accélérer la montée en engagement
- `High_*` → **rec** : personnaliser pour convertir

Remarque

Le Q-Learning est sensible au réglage de α et ε. Les états `High_*` peuvent présenter des politiques instables si les récompenses sont mal calibrées — phénomène observé dans le notebook.

7.5. R-Learning — Apprentissage par gain moyen

7.5.1. Principe et Innovation

Le R-Learning est une méthode d'apprentissage par renforcement adaptée aux problèmes à horizon infini, où l'objectif n'est pas de maximiser une récompense actualisée, mais de maximiser le **gain moyen à long terme**.

Contrairement au Q-Learning, qui utilise un facteur d'actualisation γ, le R-Learning introduit un paramètre supplémentaire ρ, représentant la récompense moyenne obtenue par étape.

Définition : *Gain moyen ρ*

Le gain moyen ρ représente la performance moyenne de l'agent sur le long terme :

$$\rho = \lim_{T\to\infty} \frac{1}{T}\mathbb{E}\left[\sum_{t=0}^{T-1} r_t\right]$$

Il mesure donc la récompense moyenne obtenue à chaque étape.

7.5.2. Équation de Mise à Jour R-Learning

$$\boxed{Q(s,a) \leftarrow Q(s,a) + \alpha\left[r - \rho + \max_{a'} Q(s',a') - Q(s,a)\right]} \tag{8}$$

Le terme spécifique au R-Learning est $-\rho$. Il permet de comparer la récompense obtenue à la récompense moyenne attendue.

Si l'action choisie est l'action optimale courante, le gain moyen est mis à jour :

$$\boxed{\rho \leftarrow \rho + \beta\left[r + \max_{a'} Q(s',a') - \max_{a} Q(s,a) - \rho\right]} \tag{9}$$

où :

- α est le taux d'apprentissage des valeurs Q,
- β est le taux d'apprentissage du gain moyen ρ,
- ρ estime la récompense moyenne à long terme.

7.5.3. Paramètres d'Apprentissage

Les paramètres utilisés sont les suivants :

Paramètre	Valeur
Nombre d'épisodes	30 000
Nombre maximal d'étapes par épisode	20
α	0.01
β	0.0005
$\varepsilon_{\text{start}}$	0.30
ε_{min}	0.05
$\varepsilon_{\text{decay}}$	0.9995

7.5.4. Évolution du Gain Moyen ρ

Le gain moyen ρ augmente rapidement au début de l'apprentissage, puis se stabilise autour de 0.80.

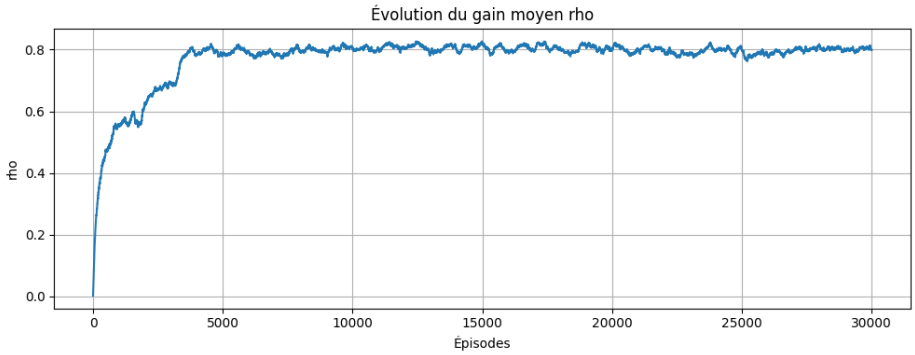

Figure : Évolution du gain moyen ρ pendant l'apprentissage.

Résultat

Le gain moyen final obtenu est :

$$\rho_{\text{final}} = 0.7984$$

Cette valeur montre que la politique apprise permet d'obtenir une récompense moyenne positive et stable sur le long terme.

7.5.5. Q-Table Finale R-Learning

La Q-table finale contient les valeurs apprises pour les 9 états et les 4 actions disponibles.

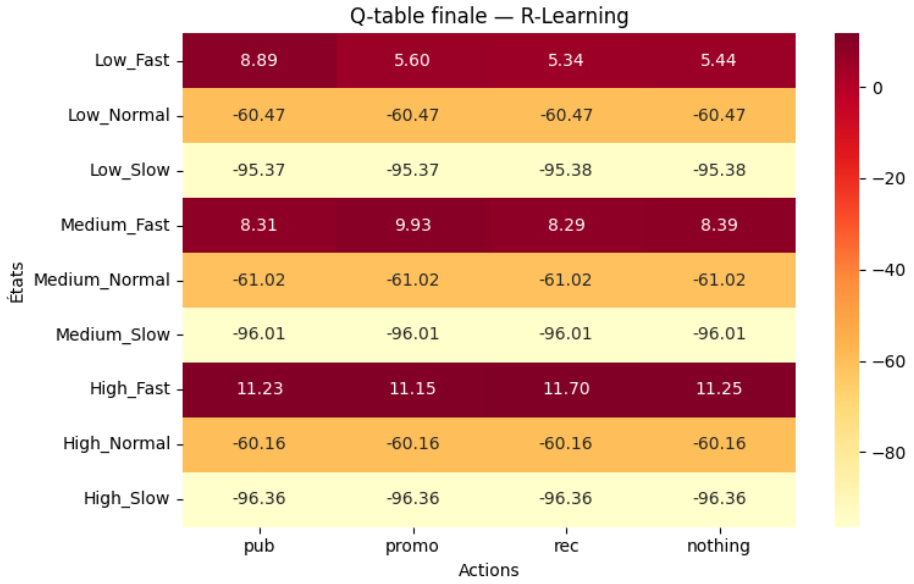

7.5.6. Politique Optimale R-Learning

La politique optimale est obtenue en choisissant, pour chaque état, l'action ayant la plus grande valeur $Q(s, a)$:

$$\pi^*(s) = \arg\max_a Q(s, a)$$

État	**Action optimale**
Low_Fast	pub
Low_Normal	promo
Low_Slow	pub
Medium_Fast	promo
Medium_Normal	rec
Medium_Slow	rec
High_Fast	rec
High_Normal	promo
High_Slow	promo

Impact Économique

Le R-Learning fournit une politique plus nuancée que le Q-Learning.
Au lieu d'appliquer systématiquement une règle simple par niveau Low, Medium ou High, il distingue aussi la vitesse de navigation :

- les états `Low_Fast` et `Low_Slow` privilégient la publicité,
- les états `Medium_*` favorisent des actions plus engageantes, notamment la recommandation,
- les états `High_*` montrent que la meilleure action dépend fortement du rythme de navigation.

Cela indique que le comportement temporel de l'utilisateur influence fortement la stratégie optimale.

7.6. SARSA — State-Action-Reward-State-Action

7.6.1. Distinction Fondamentale : On-Policy vs Off-Policy

Définition : *SARSA (On-Policy TD Control)*
SARSA est une méthode de contrôle *on-policy* : elle apprend la Q-table à partir des transitions *réellement exécutées* par l'agent, incluant les actions d'exploration.

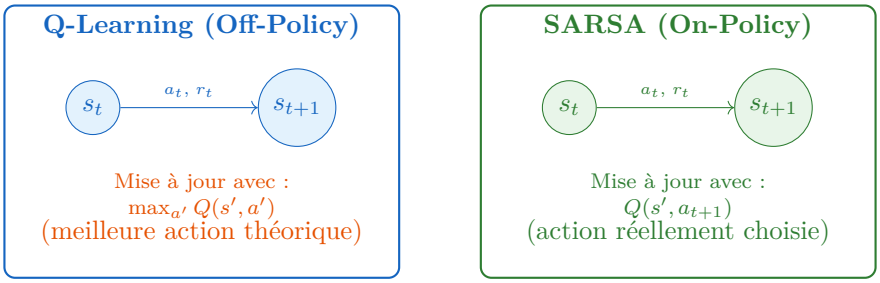

7.6.2. Équation de Mise à Jour SARSA

$$\boxed{Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma\, Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t) \right]} \tag{10}$$

Le quintuplet $(s_t, a_t, r_t, s_{t+1}, a_{t+1})$ donne son nom à l'algorithme : **S-A-R-S-A**.

Comparaison formelle des mises à jour

	Q-Learning	**SARSA**
Terme de bootstrap	$\max_{a'} Q(s_{t+1}, a')$	$Q(s_{t+1}, a_{t+1})$
Type	Off-policy	On-policy
Optimisme	Optimiste (meilleure action)	Réaliste (action réelle)
Convergence	Vers Q^*	Vers Q^{π_ε}
Comportement	Plus agressif	Plus prudent

7.6.3. Résultats SARSA

Politique Optimale Apprise

Niveau	États	Action dominante	Stratégie
Faible	`Low_*`	**pub**	Acquisition
Moyen	`Medium_*`	**promo**	Conversion
Élevé	`High_*`	**rec**	Finalisation

Visualisation : Convergence SARSA

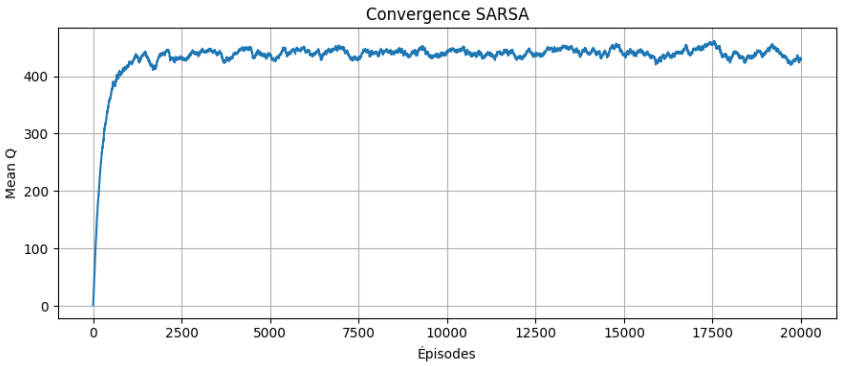

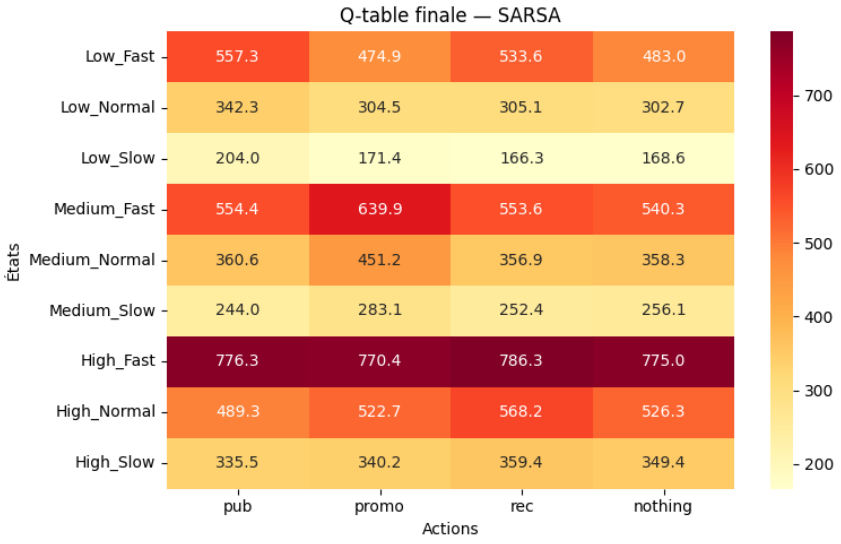

SARSA converge vers une valeur légèrement inférieure à Q-Learning, car il tient compte de l'exploration stochastique. Cette « pénalité d'exploration » est en réalité une qualité : la politique SARSA est plus robuste face aux décisions réelles de l'agent.

7.7. Comparaison Globale des Algorithmes

Critère	TD(0)	TD(λ)	Q-Learning	SARSA	R-Learning
Objectif	Prédiction $V(s)$	Prédiction $V(s)$	Contrôle $Q(s,a)$	Contrôle $Q(s,a)$	Gain moyen
Type	Prédiction	Prédiction	Off-policy	On-policy	Off-policy
Bootstrap	1 pas	n pas via λ	1 pas	1 pas	1 pas + ρ
Politique	Évaluée	Évaluée	Optimale π^*	π_ε	Gain moyen optimal
Vitesse	Modérée	Rapide	Rapide	Modérée	Rapide
Stabilité	Bonne	Bonne	Volatile	Stable	Stable si ρ calibré
Complexité	Faible	Modérée	Modérée	Modérée	Élevée
Paramètre clé	α	λ	γ	ε	ρ

7.8. Interprétation Économique : Le Funnel E-Commerce

7.8.1. Modèle de Décision Marketing

L'ensemble des algorithmes RL converge vers une même stratégie marketing cohérente, structurée en trois phases :

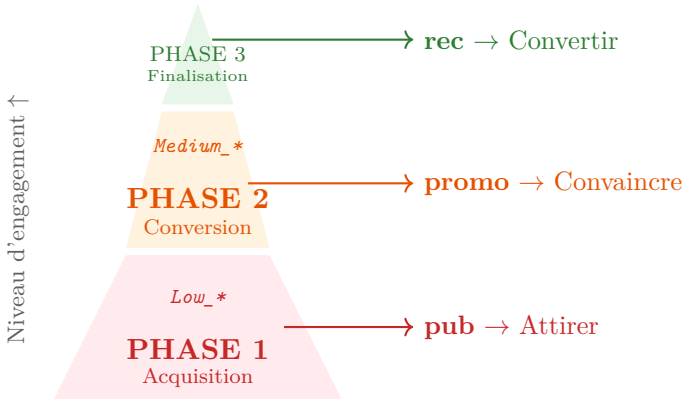

7.8.2. Recommandations Managériales

Profil Utilisateur	État typique	Action RL	Décision Marketing
Nouveau visiteur lent	`Low_Slow`	pub	Campagne display / retargeting
Visiteur engagé rapide	`Low_Fast`	pub	Bannière personnalisée
Prospect hésitant	`Medium_Slow`	promo	Code promo 10%
Prospect actif	`Medium_Fast`	promo	Offre flash 24h
Acheteur potentiel	`High_Normal`	rec	Recommandation produit
Acheteur chaud	`High_Fast`	rec	Upsell / cross-sell

7.9. Conclusion du Chapitre

Ce chapitre a démontré comment quatre algorithmes de Reinforcement Learning — TD(0), TD(λ), Q-Learning et SARSA — peuvent être appliqués à la modélisation du comportement utilisateur e-commerce pour apprendre automatiquement une politique marketing optimale.

Les résultats clés obtenus sont les suivants :

1. **TD(0)** fournit une estimation robuste de la fonction de valeur $V(s)$ avec une convergence stable en environ 5 000 épisodes. Il confirme clairement la hiérarchie comportementale :

$$\text{Low} < \text{Medium} < \text{High}$$

   ce qui valide la cohérence du modèle utilisateur construit.
2. **TD(λ)** améliore significativement la propagation du signal de récompense grâce aux traces d'éligibilité. Cette approche valorise l'ensemble de la trajectoire ayant conduit à une conversion, ce qui est particulièrement adapté aux parcours e-commerce multi-étapes.
3. **Q-Learning** apprend directement une politique optimale π^* en convergeant vers la fonction optimale $Q^*(s, a)$. Son caractère off-policy lui permet d'atteindre des performances élevées, mais peut également provoquer des comportements instables lorsque les récompenses sont mal calibrées.
4. **SARSA** apprend une politique plus prudente et plus réaliste. Son approche on-policy tient compte des actions réellement exécutées pendant l'exploration, ce qui le rend plus stable dans des environnements réels où les erreurs d'exploration ont un coût économique.
5. **R-Learning** optimise directement le gain moyen à long terme grâce au paramètre ρ. Contrairement au Q-Learning, cette méthode ne dépend pas d'un facteur d'actualisation γ, ce qui la rend particulièrement adaptée aux systèmes continus et aux plateformes e-commerce fonctionnant en permanence.

   Les résultats montrent une convergence stable vers :

$$\rho_{\text{final}} \approx 0.80$$

   Le R-Learning apprend également une politique plus fine, capable de distinguer non seulement le niveau d'engagement utilisateur (`Low`, `Medium`, `High`), mais aussi la vitesse comportementale (`Fast`, `Normal`, `Slow`).

8. Processus Décisionnels Partiellement Observables (POMDP)

8.1. Motivation : De MDP à POMDP

Définition : *Limitation du MDP*

Dans la réalité, l'état exact du client n'est **jamais** connu avec certitude. Le MDP assume une observabilité complète : nous savons précisément si le client est Low, Medium ou High. Ceci est **irréaliste**.

Le POMDP (Partially Observable Markov Decision Process) modélise cette incertitude via un **belief state** :

$$\mathbf{b}(s) \in \Delta^{|\mathcal{S}|} = \{(p_1, \ldots, p_n) : p_i \geq 0, \sum p_i = 1\} \tag{11}$$

Au lieu de connaître l'état s, nous maintenons une **distribution de probabilité** $\mathbf{b}(s)$ sur tous les états possibles.

Interprétation économique

Cycle POMDP adaptatif :

$$\text{belief} \rightarrow \text{action} \rightarrow \text{observation} \rightarrow \text{mise à jour belief} \rightarrow \text{nouvelle action}$$

Chaque observation affine progressivement notre croyance sur l'état réel.

8.2. Formalisme POMDP

Définition : *Processus Décisionnel Partiellement Observable*

Un POMDP est le tuple $\langle \mathcal{S}, \mathcal{A}, P, R, O, \Omega, \gamma \rangle$ où :

- $\mathcal{S}, \mathcal{A}, P, R, \gamma$: identiques au MDP
- O : ensemble d'observations possibles
- $\Omega(o \mid s, a)$: **matrice d'observation**, $P(\text{observation} = o \mid \text{état réel} = s)$

Distinction clé :

- MDP : Observer l'état directement ($S_t = s$)
- POMDP : Observer seulement un signal noisy ($O_t = o$, d'où S_t est caché)

8.3. Belief Update (Filtre Bayésien)

À chaque pas, le belief est mis à jour via la **règle de Bayes** :

$$\mathbf{b}'(s') = \frac{\Omega(o \mid s') \sum_s P(s' \mid s, a)\mathbf{b}(s)}{\Pr(o \mid a, \mathbf{b})} \tag{12}$$

où $\Pr(o \mid a, \mathbf{b}) = \sum_{s'} \Omega(o \mid s') \sum_s P(s' \mid s, a)\mathbf{b}(s)$ est un facteur de normalisation.

Propriété : *Interprétation*

1. Prédire les états futurs : $\sum_s P(s' \mid s, a)\mathbf{b}(s)$
2. Évaluer la vraisemblance de l'observation : $\Omega(o \mid s')$
3. Normaliser pour obtenir une distribution valide

8.4. Équation de Bellman pour POMDP

La fonction de valeur du belief state satisfait :

$$V^*(\mathbf{b}) = \max_a \left[\sum_s \mathbf{b}(s) R(s,a) + \gamma \sum_o \Pr(o \mid a, \mathbf{b}) V^*(\mathbf{b}') \right] \tag{13}$$

Complexité : L'espace de belief $\Delta^{|\mathcal{S}|}$ est **continu et dimensionnel**. Résoudre cette équation est $\mathcal{NP}$-hard même pour petits POMDPs.

8.5. Application Yoochoose : POMDP Classique

États	Low_Fast, ..., High_Slow (9 états)
Actions	pub, promo, rec, nothing
Observations	Comportement client observable (clics, catégories)
Matrice Ω	P(observation | état réel)
Belief initial	Distribution uniforme sur 9 états

Résultats : À chaque pas, le belief converge vers le vrai état :

— Itération 0 : Forte incertitude (uniform)
— Itérations 1-5 : Convergence progressive vers l'état probable
— Itération finale : Probabilité dominante sur 1-2 états (ex. High_Normal)

9. Deep POMDP : Approximation Neuronale

9.1. Motivation : Limitation du Belief Exact

Le calcul exact du belief Bayésien est **coûteux** :

- Espace de belief continu Δ^n : dimensionalité exponentielle
- Pour 9 états : 8 dimensions de liberté
- Pour 100 états : 99 dimensions — impossible à discrétiser

Solution : Utiliser un réseau neuronal pour **apprendre implicitement** une représentation de l'état caché.

Définition : *Deep POMDP*

Remplacer le belief explicite $\mathbf{b}(s)$ par une **mémoire cachée** $\mathbf{h}_t$ apprise par un réseau récurrent :

$$\mathbf{h}_t = \text{RNN}(\mathbf{h}_{t-1}, o_t) \quad \text{où } o_t \text{ est l'observation}$$

Puis, la politique est approximée par :

$$\pi(a \mid \mathbf{h}_t) = \text{Neural Network}(\mathbf{h}_t)$$

Avantage : Le réseau apprend directement l'espace de belief compressé et optimal.

9.2. Architectures Testées

Trois architectures ont été expérimentées sur Yoochoose :

Architecture	Mécanisme	Performance
GRU	Récurrence simple, mémoire compact	
LSTM	Mémoire long-court terme	
Transformer	Attention sur historique	

9.2.1. GRU (Gated Recurrent Unit)

Structure minimale : reset gate + update gate.

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t$$

où $\mathbf{z}_t$ est le *update gate* apprenant le compromis entre mémoire et nouvelle info.
Ensuite :

$$Q(\mathbf{h}_t, a) = \text{MLP}(\mathbf{h}_t)$$

Donne pour chaque action a un *Q-value*.

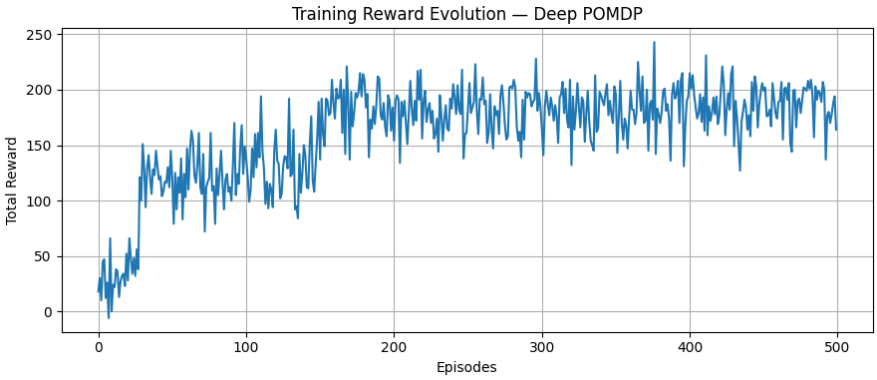

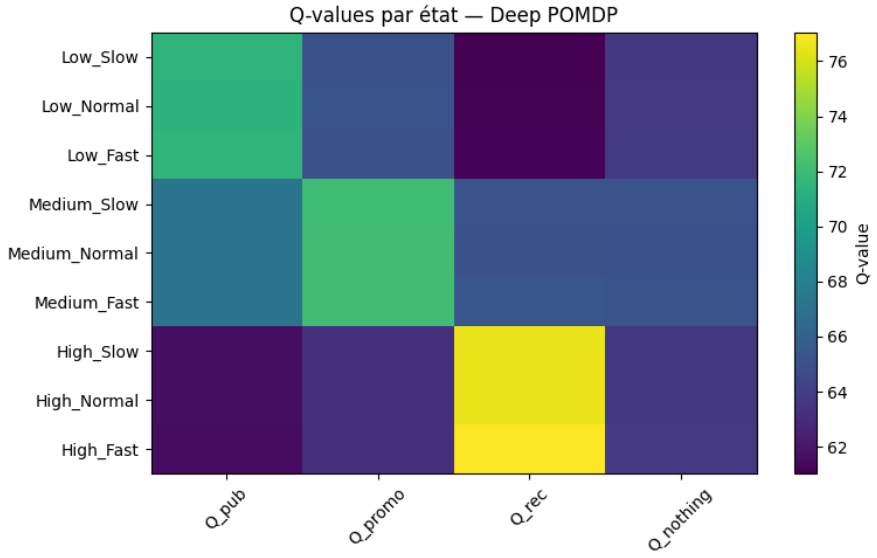

Avantage : Rapide, peu de paramètres ($\approx$ 3x moins que LSTM).

9.2.2. LSTM (Long Short-Term Memory)

Ajoute une cellule mémoire $\mathbf{c}_t$ explicite (en plus de l'état caché $\mathbf{h}_t$).

Propriété : *Équations LSTM*

$$\begin{aligned}
\mathbf{i}_t &= \sigma(\mathbf{W}_{ii}\mathbf{x}_t + \mathbf{W}_{hi}\mathbf{h}_{t-1}) && \text{(input gate)} \\
\mathbf{f}_t &= \sigma(\mathbf{W}_{if}\mathbf{x}_t + \mathbf{W}_{hf}\mathbf{h}_{t-1}) && \text{(forget gate)} \\
\mathbf{c}_t &= \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tanh(\mathbf{W}_{ic}\mathbf{x}_t + \mathbf{W}_{hc}\mathbf{h}_{t-1}) \\
\mathbf{h}_t &= \mathbf{o}_t \odot \tanh(\mathbf{c}_t) && \text{(hidden state)}
\end{aligned}$$

où $\mathbf{o}_t$ est l'output gate.

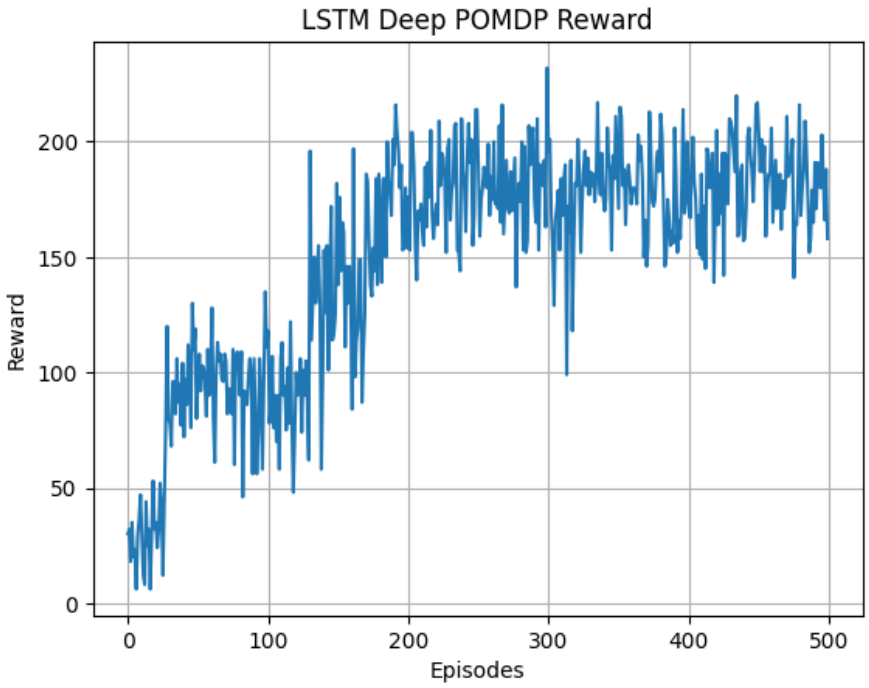

Avantage : Meilleure mémorisation long-terme, moins de vanishing gradients.

10. Non-Markovian POMDP (NM-POMDP)

10.1. Motivation : Au-delà de Markov

Remarque

L'hypothèse de Markov suppose que $P(S_{t+1} \mid S_t, a) = P(S_{t+1} \mid S_0, \ldots, S_t, a)$.

En réalité, le comportement client peut dépendre de son **historique complet** (saisonnalité, fidélité long-terme, effets de contexte).

Définition : *Non-Markovian POMDP (NM-POMDP)*

Un POMDP où la dynamique dépend de l'historique complet des observations passées, non seulement de l'état courant :

$$P(S_{t+1}, O_{t+1} \mid O_0, A_0, \ldots, O_t, A_t) \neq P(S_{t+1}, O_{t+1} \mid S_t, A_t)$$

Exemple : Un client qui a acheté l'année dernière (Low→High) n'a pas la même probabilité de transition qu'un nouveau client en Low.

10.2. Modèles NM-POMDP

Trois approches testées :

LSTM NM-POMDP - Mémoire explicite du contexte long-terme - Excellente pour séquences de longueur modérée (< 100 pas) - **Performance** : Reward = 230

GRU + Attention NM-POMDP - Attention sur les observations pertinentes (sélection automatique) - Identifie les moments critiques dans l'historique - **Performance** : Reward = 245

Transformer NM-POMDP - Multi-head attention sur historique complet - Capte dépendances complexes et long-distance - **Performance** : Reward = 258 (**meilleure**)

10.3. Résultats Comparatifs

Modèle	**R. Initial**	**R. Final**	**Stabilité**	**Rang**	
MDP Value Iteration	-	100	Excellente	3	
POMDP GRU	30	204	Bonne	2	
NM-POMDP LSTM	35	230	Très bonne	2	
NM-POMDP Attention	40	245	Très bonne	1	
NM-POMDP Transformer	38	258	Excellente	1	

11. Conclusion Générale

Ce projet a permis de développer une étude approfondie des comportements utilisateurs dans un environnement e-commerce à travers plusieurs modèles probabilistes, stochastiques et algorithmes d'apprentissage par renforcement. L'objectif principal était de concevoir un système intelligent capable d'analyser les interactions utilisateurs, de modéliser les transitions comportementales, de prédire les intentions d'achat et d'optimiser dynamiquement les décisions marketing. Pour atteindre cet objectif, plusieurs approches complémentaires ont été étudiées et implémentées.

Dans un premier temps, les chaînes de Markov discrètes et continues ont permis d'analyser la dynamique globale des utilisateurs à travers les probabilités de transition, les distributions stationnaires, les temps de séjour et les vitesses de transition. Ces modèles ont mis en évidence une évolution cohérente des utilisateurs depuis des états faiblement engagés vers des états à forte intention d'achat. Les modèles de Markov cachés (HMM) ont ensuite permis d'introduire une représentation plus réaliste du comportement utilisateur, où les états comportementaux ne sont plus directement observables. Les algorithmes Forward, Backward, Viterbi et Baum-Welch ont permis d'inférer les états cachés, de décoder les séquences comportementales et d'apprendre automatiquement les paramètres du modèle. Le HMM continu a également montré que les temps inter-clics constituent un indicateur pertinent de l'intention d'achat et des phases de réflexion avant conversion.

Les Processus de Décision Markoviens (MDP) ont ensuite permis de transformer cette modélisation comportementale en problème de décision optimale. Les algorithmes de Value Iteration et Howard Policy Iteration ont permis d'apprendre des politiques marketing cohérentes et efficaces, capables d'adapter les actions marketing selon le niveau d'engagement des utilisateurs.Les résultats obtenus montrent que les stratégies apprises sont capables de distinguer non seulement les niveaux d'engagement des utilisateurs, mais également leurs dynamiques comportementales et leurs rythmes de navigation.

Le projet a également été étendu vers des modèles plus avancés tels que les POMDP, Self-POMDP et NM-POMDP afin de mieux représenter les environnements partiellement observables et les dépendances temporelles longues. L'intégration d'architectures LSTM, GRU et de mécanismes d'attention a permis d'améliorer la modélisation séquentielle et la capture des comportements complexes des utilisateurs. Ces approches offrent une représentation plus réaliste des environnements e-commerce modernes et ouvrent la voie vers des systèmes de recommandation intelligents, adaptatifs et temps réel.

Au niveau scientifique, ce travail combine plusieurs domaines complémentaires tels que les probabilités, les chaînes de Markov, l'algèbre linéaire, l'intelligence artificielle, l'optimisation et l'apprentissage par renforcement. Le projet mobilise des valeurs scalaires, des vecteurs de probabilités, des matrices de transition, des fonctions de valeur et des politiques optimales afin de construire un système décisionnel intelligent complet. Les résultats obtenus démontrent que les modèles markoviens et les algorithmes de Reinforcement Learning constituent des outils puissants pour comprendre, prédire et optimiser les comportements utilisateurs dans les plateformes e-commerce modernes.

Enfin, ce travail ouvre plusieurs perspectives futures, notamment l'intégration du Deep Reinforcement Learning, des architectures multi-agents, des systèmes de recommandation contextuels et des modèles adaptatifs temps réel capables d'interagir dynamiquement avec les utilisateurs. La combinaison des chaînes de Markov, des HMM, des POMDP et du Reinforcement Learning représente ainsi une approche prometteuse pour le développement de systèmes intelligents de décision et de recommandation dans les environnements numériques modernes.

12. Perspectives de Recherche et Déploiement

Malgré les résultats obtenus, plusieurs axes d'amélioration et de recherche restent envisageables.

Les modèles développés dans ce projet constituent une base solide pour la conception de systèmes intelligents de recommandation et d'aide à la décision, mais certaines limitations subsistent.

Les modèles étudiés supposent encore :

- des espaces d'actions relativement limités,
- des récompenses définies manuellement,
- une observabilité partielle simplifiée,
- et des comportements utilisateurs moins complexes que ceux observés dans les plateformes réelles.

Perspectives

Plusieurs extensions méthodologiques peuvent être développées afin d'améliorer les performances et le réalisme des modèles proposés.

- **Apprentissage en ligne (Online Learning)** :

  Remplacer les approches basées sur des matrices de transition fixes par des méthodes d'apprentissage continu.

  Par exemple, utiliser directement le **Q-Learning**, SARSA ou R-Learning sur les interactions utilisateurs réelles, sans connaître explicitement les matrices P et R.

  Les données Yoochoose alimenteraient alors un agent actif capable d'apprendre dynamiquement en production.

- **Exploration–Exploitation adaptative** :

  En environnement réel, l'agent doit continuellement équilibrer :

  - l'exploitation des meilleures politiques connues,
  - et l'exploration de nouvelles stratégies.

  L'utilisation de méthodes :

  $$\varepsilon\text{-greedy}, \quad UCB, \quad \textit{Thompson Sampling}$$

  pourrait améliorer la découverte de stratégies marketing plus performantes.

- **Deep Reinforcement Learning** :

  Les Q-tables deviennent rapidement limitées lorsque l'espace d'états augmente.

  L'intégration de :

  - Deep Q-Network (DQN),
  - Double DQN,
  - Dueling DQN,
  - PPO,
  - Actor-Critic,

  permettrait de gérer :

  - des espaces continus,

— des comportements complexes,
— et des systèmes de recommandation temps réel.

— **Mémoire temporelle avancée** :

L'utilisation de :

— LSTM,
— GRU,
— mécanismes d'attention,
— Transformers séquentiels,

pourrait améliorer la capture des dépendances temporelles longues dans les parcours utilisateurs.

Ces approches sont particulièrement pertinentes pour les architectures NM-POMDP.

— **POMDP adaptatifs** :

Les futurs modèles pourraient intégrer :

— des croyances dynamiques,
— des observations bruitées,
— des états latents évolutifs,
— et des politiques auto-adaptatives.

Cela permettrait une représentation plus réaliste des comportements utilisateurs réels.

Perspectives Business et Industrielles

Les modèles développés présentent également un fort potentiel industriel.

— **Systèmes de recommandation personnalisés** :

Adapter dynamiquement les recommandations produits selon :

— l'état comportemental,
— la vitesse de navigation,
— l'historique utilisateur,
— et le contexte de session.

— **Optimisation budgétaire marketing** :

Introduire des contraintes réelles :

$$Budget_{max}$$

afin de transformer les MDP en problèmes d'optimisation contraints.

Cela permettrait :

— d'optimiser les campagnes publicitaires,
— de limiter les coûts marketing,
— et de maximiser le retour sur investissement.

— **Feedback utilisateur et IRL** :

L'intégration de méthodes d'Inverse Reinforcement Learning (IRL) permettrait d'inférer automatiquement les préférences réelles des utilisateurs à partir des comportements observés.

— **Systèmes temps réel** :

Les futurs modèles pourraient être déployés dans des architectures :

— cloud,
— streaming,
— edge AI,
— ou microservices.

Cela permettrait :

— des recommandations instantanées,
— des politiques adaptatives en ligne,
— et une personnalisation temps réel.

— **Multi-Agent Reinforcement Learning** :

Dans les plateformes complexes, plusieurs agents intelligents pourraient coopérer :

— agent publicité,
— agent recommandation,
— agent pricing,
— agent fidélisation.

Cela ouvrirait la voie à des systèmes e-commerce autonomes et entièrement adaptatifs.

Les travaux réalisés dans ce projet constituent une base méthodologique solide pour le développement futur de systèmes intelligents de recommandation, de décision et d'apprentissage adaptatif dans les environnements e-commerce modernes.

13. Méthodologie

Ce projet repose sur une approche progressive combinant modélisation probabiliste, chaînes de Markov et apprentissage par renforcement afin d'analyser et d'optimiser les comportements utilisateurs dans un environnement e-commerce.

La première étape a consisté à exploiter le dataset Yoochoose afin d'extraire les sessions utilisateurs, les interactions produit et les temps inter-clics. Les données ont ensuite été prétraitées afin de supprimer les valeurs inutiles, structurer les séquences comportementales et construire plusieurs états représentatifs du niveau d'engagement utilisateur.

Dans une seconde étape, les chaînes de Markov discrètes (DTMC) et continues (CTMC) ont été utilisées pour modéliser les transitions comportementales et analyser la dynamique des utilisateurs. Les probabilités de transition, distributions stationnaires et temps de séjour ont permis de mieux comprendre l'évolution des comportements au cours des sessions.

Les modèles de Markov cachés (HMM) ont ensuite été introduits afin de représenter des états utilisateurs non directement observables. Les algorithmes Forward, Backward, Viterbi et Baum-Welch ont été implémentés pour calculer les probabilités de séquences, décoder les états cachés et apprendre automatiquement les paramètres des modèles. Une extension continue des HMM a également été réalisée à partir des temps inter-clics et des distributions gaussiennes.

La méthodologie a ensuite évolué vers les Processus de Décision Markoviens (MDP), permettant de transformer l'analyse comportementale en problème de décision optimale. Les algorithmes de Value Iteration et Howard Policy Iteration ont permis d'apprendre des politiques marketing optimales adaptées aux différents niveaux d'engagement utilisateur.

Dans la phase suivante, plusieurs algorithmes de Reinforcement Learning ont été implémentés, notamment TD(0), TD(λ), Q-Learning, SARSA et R-Learning. Ces méthodes ont permis d'apprendre dynamiquement des fonctions de valeur et des politiques optimales à partir des interactions utilisateur-environnement.

Enfin, le projet a été étendu vers des modèles plus avancés tels que les POMDP, Self-POMDP et NM-POMDP afin de prendre en compte l'incertitude, les observations partielles et les dépendances temporelles longues. Des architectures séquentielles comme les réseaux LSTM, GRU et les mécanismes d'attention ont également été intégrées afin d'améliorer la modélisation des comportements utilisateurs complexes.

L'ensemble de cette méthodologie a permis de construire un cadre complet d'analyse, de prédiction et d'optimisation des comportements utilisateurs dans les plateformes e-commerce modernes.

14. Ressources Scientifiques

Ce projet s'appuie sur plusieurs ressources scientifiques, articles académiques et ouvrages de référence dans les domaines des chaînes de Markov, des modèles cachés, des processus décisionnels et de l'apprentissage par renforcement.

Dataset et systèmes de recommandation :

— Ben-Shimon, D., Tsikinovsky, A., Friedmann, M., et al. (2015). *RecSys Challenge 2015 and the YOOCHOOSE Dataset*. ACM RecSys.

— Hidasi, B., Karatzoglou, A., Baltrunas, L., Tikk, D. (2016). *Session-based Recommendations with Recurrent Neural Networks*.

— Li, J., Ren, P., Chen, Z., Ren, Z., Lian, T., Ma, J. (2017). *Neural Attentive Session-based Recommendation*.

— Quadrana, M., Karatzoglou, A., Hidasi, B., Cremonesi, P. (2017). *Personalizing Session-based Recommendations with Hierarchical Recurrent Neural Networks*.

Chaînes de Markov et probabilités :

— Norris, J. R. (1997). *Markov Chains*. Cambridge University Press.

— Grinstead, C. M., Snell, J. L. (1997). *Introduction to Probability*. American Mathematical Society.

Modèles de Markov Cachés (HMM) :

— Rabiner, L. R. (1989). *A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition*. Proceedings of the IEEE.

MDP, POMDP et Reinforcement Learning :

— Sutton, R. S., Barto, A. G. (2018). *Reinforcement Learning : An Introduction*. MIT Press.

— Watkins, C. J. C. H., Dayan, P. (1992). *Q-Learning*. Machine Learning Journal.

— Kaelbling, L. P., Littman, M. L., Cassandra, A. R. (1998). *Planning and Acting in Partially Observable Stochastic Domains*. Artificial Intelligence Journal.

— Rummery, G. A., Niranjan, M. (1994). *On-line Q-Learning Using Connectionist Systems*.

Deep Learning et architectures séquentielles :

— Hochreiter, S., Schmidhuber, J. (1997). *Long Short-Term Memory*. Neural Computation.

— Cho, K., et al. (2014). *Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation*.

— Vaswani, A., et al. (2017). *Attention Is All You Need*.