Modélisation du Comportement Utilisateur en E-Commerce

Chaînes de Markov, HMM, MDP, Reinforcement Learning et POMDP

Dataset Yoochoose — RecSys Challenge 2015
100 000 sessions utilisateurs | Modèles probabilistes et décisionnels

Apprentissage Probabiliste

École Nationale Supérieure
Prof. Abdellatif El Afia

Mars 2026

Plan de la présentation

1. **Introduction et problématique**
2. **Dataset Yoochoose et construction des états**
3. **Modélisation markovienne**
   - DTMC : transitions et absorption
   - CTMC : temps de séjour et dynamique temporelle
4. **Modèles à états cachés**
   - HMM discret et continu
   - Forward, Backward, Viterbi, Baum-Welch
5. **Décision optimale**
   - MDP, Value Iteration et Howard
   - Analyse du facteur γ
6. **Apprentissage par renforcement**
   - TD(0), TD(λ), Q-Learning, SARSA, R-Learning
7. **POMDP, Deep POMDP et NM-POMDP**
8. **Conclusion générale et perspectives**

Contexte et Problématique

Problématique

Comment modéliser le comportement utilisateur dans une plateforme e-commerce afin de :

- prédire les intentions d'achat ou d'abandon,
- analyser l'évolution des sessions utilisateur,
- optimiser dynamiquement les actions marketing.

Dataset Yoochoose

- RecSys Challenge 2015
- 100 000 sessions utilisateurs
- 395 698 transitions extraites
- 5 états comportementaux
- Taux de conversion : 6.59%
- `clicks.dat` + `buys.dat`

Pipeline Méthodologique

1. DTMC et CTMC
2. HMM discret et continu
3. MDP et politiques optimales
4. Reinforcement Learning
5. POMDP et NM-POMDP
6. Deep Learning séquentiel

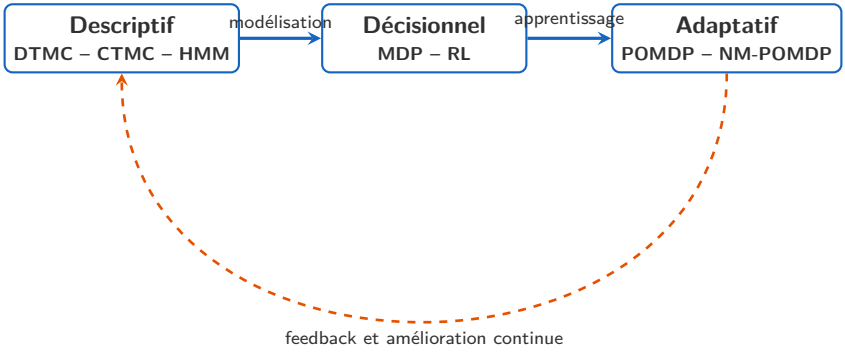
Objectif : Construire un système intelligent capable de prédire et optimiser le comportement utilisateur.

Approche Méthodologique

1. Descriptif
- Comprendre les sessions
- Identifier les états
- Analyser les transitions

2. Décisionnel
- Définir les actions
- Optimiser la conversion
- Apprendre une politique

3. Adaptatif
- Gérer l'incertitude
- Observer partiellement
- Intégrer le Deep Learning



Ch.1 : 5 États Comportementaux et Graphe de Transition

État	Condition	Type	p_{ii}
Browsing	$k \leq 2$	Transitoire	0,484
Engaged	$3 \leq k \leq 5$	Transitoire	0,523
HighIntent	$k \geq 6$	Transitoire	0,807
Buy	achat	Absorbant	1,00
Exit	abandon	Absorbant	1,00

Observations clés

- Structure en entonnoir (tunnel utilisateur)
- $p_{HH} = 0{,}807$: forte hésitation
- Transition progressive :

$$B \to E \to HI \to \text{Buy/Exit}$$

- Taux de conversion : 6,59%

Propriété de Markov

$$\mathbb{P}(X_{n+1} = j \mid X_n = i, \ldots, X_0) = p_{ij}$$

Sessions anonymes $\Rightarrow$ processus sans mémoire.

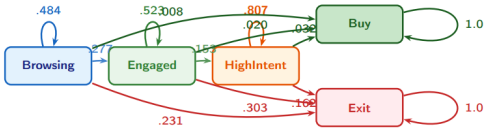


Figure – Graphe de transition des états comportementaux

Forme canonique et theoremes

$$P = \begin{pmatrix} Q & R \\ 0 & I \end{pmatrix} \quad N = (I - Q)^{-1} \text{ (nombre moyen de visites)} \quad B = NR \text{ (probabilites d'absorption)}$$

Table – *

Matrice fondamentale N

blue!20 **N**	**B**	**E**	**HI**	**Duree**
B	1,94	1,13	0,89	**3,96**
E	0	2,10	1,67	**3,76**
HI	0	0	5,18	**5,18**

$N_{HH} = 5{,}18$: $\approx$5 clics d'hesitation en HighIntent.

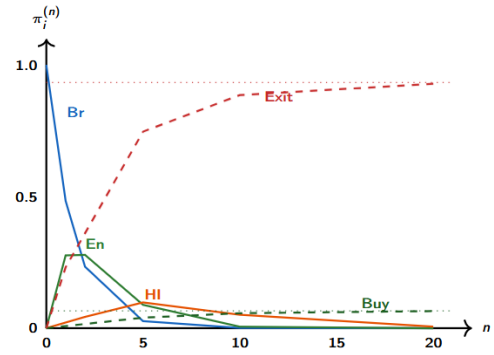
Table – *

Matrice d'absorption $B = NR$

blue!20 **Etat**	**P(Buy)**	**P(Exit)**	**Gain**
blue!5 **Browsing**	**6,59%**	93,41%	—
blue!5 **Engaged**	**9,48%**	90,52%	**+44%**
blue!5 **HighIntent**	**16,36%**	83,64%	**+148%**

HighIntent = $\times$2.5 vs Browsing.
Sommes = 1.00 ✓

Ch.1 — Convergence, Classification et Tunnel



$\pi^* = (0, 0, 0, 0.066, 0.934)$
$\lambda_{\max} = 0.807$ (HighIntent gouverne)

Classification

- ✗ Non irreductible (5 classes)
- ✗ Non ergodique
- ✓ Aperiodique ($d(i) = 1$)
- ✓ Absorbante → theoreme N, B

Sessions typiques

Abandon rapide : B→B→Exit ($p = 0.112$)

Conversion : B→E→HI→ $\cdots$ →Buy

Impulsif : B→Buy ($p = 0.008$, 1505 cas)

Ch.2 — Du Clic a la Seconde : Matrice Generatrice

Apport CTMC vs DTMC

Ch.1 : unite = **clics** (discret)
Ch.2 : unite = **secondes** (continu)
Horodatages Yoochoose exploites.

$q_{ij} = \lim_{h \to 0^+} \frac{p_{ij}(h) - \delta_{ij}}{h}$ MLE : $\hat{q}_{ij} = \frac{N_{ij}}{T_i}$

Loi exponentielle

$T_i \sim \mathcal{E}(\lambda_i)$, $\mathbb{E}[T_i] = 1/\lambda_i$
Propriete sans memoire : analogue continu de Markov.

Table – *

Taux de transition (par minute)

blue !20 **Transition**	**Taux/min**	**Sens**
green !10 B $\rightarrow$ Eng.	0.171	$\uparrow$ engagement
green !10 E $\rightarrow$ HI	0.110	$\uparrow$ parcours
red !10 B $\rightarrow$ Exit	0.143	$\downarrow$ abandon
red !10 E $\rightarrow$ Exit	**0.218**	$\downarrow$ le + eleve
red !10 HI $\rightarrow$ Exit	0.120	$\downarrow$ abandon
green !10 HI $\rightarrow$ Buy	0.023	✓ conversion

$\hat{q}_{BH} = 0$: pas de saut direct B$\rightarrow$HI. Progression obligatoire par Engaged.

Ch.2 — Temps de Séjour et P(t)

Table – *

Temps de séjour et absorption

blue !15 **Etat**	$\mathbb{E}[T_i]$	t^*	**Interp.**
red !8 Brow.	**3.14 min**	5.92	Rapide
orange !12 Eng.	**2.92 min**	5.17	Focalise
yellow !18 HI	**6.99 min**	6.99	Hesitation

HI = 2× plus long que les autres. Fenêtre d'intervention optimale.

Chaîne embedded : $p_{ij} = q_{ij}/\lambda_i$
HI→Buy : 16.4% | HI→Exit : 83.6%

$P(t) = e^{\hat{Q}t}$ — Evolution temporelle

blue !15 ***t***	**P(B)**	**P(Exit)**	**Action**
blue !5 1 min	72.8%	13.7%	Engager
orange !12 5 min	20.4%	**54.3%**	Intervenir !
red !10 10 min	4.2%	**77.8%**	Trop tard

Coherence DTMC/CTMC

Probabilites d'absorption identiques.
Ecart $< 6 \times 10^{-5}$ ✓
CTMC **enrichit** la DTMC (durees) sans la contredire.

Table – *

Regles d'intervention basees sur le modele CTMC

teal !80			
Browsing	> 3 min	Afficher produits populaires	Accelerer $\rightarrow$ Engaged
green !5 Engaged	> 2 min	Recommandation personnalisee	Accelerer $\rightarrow$ HI
red !5 HighIntent	> 3 min	Promotion flash (-10%)	Reduire abandon
red !5 HighIntent	> 5 min	Notification panier abandonne	Urgence d'achat
Session	> 8 min	Email de relance post-session	Recuperer l'abandon

Interpretation economique

La probabilite d'abandon s'accelere entre $t = 2$ et $t = 5$ min. **Intervenir avant 5 minutes** est crucial pour maximiser la conversion.

Ch.3 — Du Visible au Caché : HMM

Changement de paradigme

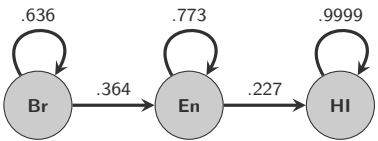
Ch.1–2 : états **observables** (rang du clic)

Ch.3 : états **cachés** $\rightarrow$ inférés depuis les observations

$\lambda = (S,\ \mathcal{O},\ A,\ B,\ \pi)$

Paramètres

- $S = \{\text{Browsing, Engaged, HighIntent}\}$
- $\mathcal{O}$ = activité $\times$ vitesse = **9 classes**
- $\pi = (1,\ 0,\ 0)$ (lissage Laplace)



Matrice de transition A estimée (HMM discret)

blue!20	**Br**	**En**	**HI**
Browsing	0.6357	0.3643	0.0000
Engaged	0.0000	0.7733	0.2267
HighIntent	0.0000	0.0000	0.9999

Matrice d'émission B (dominantes)

blue!20 **Obs.**	**Br**	**En**	**HI**
Low_N	.713	—	—
Low_F	.203	—	—
Low_S	.084	—	—
Med_F	—	.467	—
Med_N	—	.385	—
Med_S	—	.148	—
High_F	—	—	.541
High_N	—	—	.342
High_S	—	—	.118

Séparation parfaite : Low$\rightarrow$Br, Med$\rightarrow$En, High$\rightarrow$HI

Ch.3 — Algorithmes Forward et Backward

Forward : évaluation directe

$$\alpha_1(i) = \pi_i b_i(O_1)$$

$$\alpha_t(j) = \left[\sum_i \alpha_{t-1}(i) a_{ij}\right] b_j(O_t)$$

$$P(O|\lambda) = \sum_i \alpha_T(i)$$

Séquence étudiée :

[Low_N, Low_F, Med_N, Med_N]

t	Br	En	HI
0	0.5498	0.0000	0.0000
1	0.1141	0.0236	0.0000
2	0.0000	0.0237	0.0000
3	0.0000	0.0105	0.0000

$$P(O|\lambda) = \mathbf{0.01050}$$

Séquence peu probable globalement

Backward : évaluation rétrograde

$$\beta_T(i) = 1$$

$$\beta_t(i) = \sum_j a_{ij} b_j(O_{t+1}) \beta_{t+1}(j)$$

Cohérence Forward / Backward

$$P(O|\lambda)_\alpha = P(O|\lambda)_\beta = \mathbf{0.01050}$$

$$1.73 \times 10^{-18}$$

Erreur d'arrondi machine uniquement.

✓

Ch.3 — Apprentissage : Baum-Welch (EM)

Principe EM

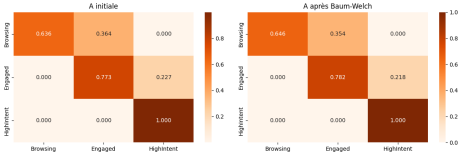
E-step

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{\sum_k \alpha_t(k)\beta_t(k)} \qquad \xi_t(i,j) = \frac{\alpha_t(i)a_{ij}b_j(O_{t+1})\beta_{t+1}(j)}{P(O|\lambda)}$$

M-step

$$\hat{A}_{ij} = \frac{\sum_t \xi_t(i,j)}{\sum_t \gamma_t(i)} \qquad \hat{B}_{ij} = \frac{\sum_{t:O_t=v_k} \gamma_t(i)}{\sum_t \gamma_t(i)}$$

Itération	Log-Lik.	Amélioration
1	−5114.44	—
2	−5111.26	+2.98
3–10	−5111.26	Convergence



Matrices avant/après Baum-Welch

Résultats après apprentissage

- Auto-transitions renforcées :

  $Br : +1.06\%$ $\quad$ $En : +0.92\%$

- Séparation nette de la matrice B :

  $Browsing \rightarrow Low$, $\quad Engaged \rightarrow Medium$, $\quad HighIntent \rightarrow High$

- Garantie EM :

  $$P(O|\hat{\lambda}) \geq P(O|\lambda)$$

Ch.3 — Décodage Viterbi et HMM Continu

Algorithme de Viterbi

$$\delta_t(j) = \max_i \left[\delta_{t-1}(i) a_{ij}\right] b_j(O_t)$$
$$\psi_t(j) = \arg\max_i \left[\delta_{t-1}(i) a_{ij}\right]$$

Séquence optimale :

$$\mathbf{q}^* = [\text{Br}, \text{Br}, \text{En}, \text{En}]$$



Matrice δ — Viterbi

Interprétation

$t = 0, 1$: phase d'exploration rapide.

$t = 2, 3$: phase d'engagement.

Le passage vers `Engaged` correspond à une fenêtre optimale d'intervention marketing.

HMM Continu Gaussien

$$b_i(x) = \mathcal{N}(x; \mu_i, \sigma_i)$$

93 656 séquences analysées
Temps inter-clics :

$$\Delta t$$

État	μ appris	σ appris
Browsing	5 s	0.001 s
Engaged	39 s	27 s
HighIntent	210 s	138 s

Découverte clé : HighIntent

$$\mu = 210 \text{ s} \qquad \sigma = 138 \text{ s}$$

L'utilisateur reste immobile pendant environ 3–4 minutes.
Signal fort de considération d'achat.

$$\mu + 2\sigma \approx 486 \text{ s}$$

Notification urgente possible.

Amélioration = 92%

Ch.4 — MDP : Formalisation du Problème Décisionnel

Du descriptif au décisionnel

Ch.1–3 : *"Qu'observe-t-on ?"*

Ch.4 : *"**Que faire** pour optimiser la valeur ?"*

$\text{MDP} = (S,\ A,\ P,\ R,\ \gamma)$

Espace d'États et d'Actions

$S = \{\text{Activité}\} \times \{\text{Vitesse}\} = \mathbf{9}$ états

Low/Med/High × Fast/Normal/Slow

$A = \{\texttt{nothing},\ \texttt{pub},\ \texttt{promo},\ \texttt{rec}\}$

Action	**Cible**	**Effet**
pub	Low	Low→Med +8%
promo	Med	Med→High +10%
rec	High	Stabilise High
nothing	–	Comportement naturel

$\gamma = 0.9$: récompense dans 10 étapes
$\Rightarrow (0.9)^{10} = 35\%$ de sa valeur initiale
Capture l'urgence des sessions e-commerce (5–7 min)

Récompenses $R(s, a)$

État	`nth`	`pub`	`prm`	`rec`
Low_*	10	**23**	5	9
Med_*	30	25	**50**	29
High_*	80	79	75	**95**

Équation de Bellman Optimale

$$V^*(s) = \max_a \left[R(s,a) + \gamma \sum_{s'} P(s'|s,a)\, V^*(s') \right]$$

$$\pi^*(s) = \arg\max_a \left[R(s,a) + \gamma \sum_{s'} P(s'|s,a)\, V^*(s') \right]$$

Ch.4 — Résultats Value Iteration, Howard et Politique Optimale

Politique optimale π^* et valeurs $V^*(s)$

blue!20 **État**	$V^*(s)$	$\pi^*(s)$
red!12 High_Fast	**94.73**	rec
red!8 High_Normal	94.35	rec
red!12 High_Slow	93.83	rec
orange!12 Med_Fast	51.24	promo
orange!8 Med_Normal	50.88	promo
orange!12 Med_Slow	50.23	promo
blue!12 Low_Fast	23.51	pub
blue!8 Low_Normal	23.42	pub
blue!12 Low_Slow	23.15	pub

blue!20 **Impact**	**Valeur**
Conversion Low	6.59% → 8.2%
Conversion High	16.36% → 19.4%
ROI net	**72.5%**

Double validation VI vs Howard

Value Iteration : ∼**100 itérations** ($\gamma = 0.9$)
Howard (Policy It.) : **2 itérations seulement**
Résultats **strictement identiques** ✓

$V^*(\text{High}) > V^*(\text{Med}) > V^*(\text{Low})$
Hiérarchie parfaitement capturée.

Politique optimale π^* : funnel automatique

Low → `pub` : Attirer l'attention (+13 bonus)
Medium → `promo` : Créer urgence (+20 bonus)
High → `rec` : Finaliser la vente (+15 bonus)

Cohérence avec Ch.1 (High=16.36%), Ch.2 (High=6.99min), Ch.3 (pause 210s)

Howard : convergence en 2 itérations

Iter. 1 : **9/9 états** changent (nothing → action)
Iter. 2 : **0 changement** — point fixe atteint ✓

Ch.4 — Robustesse : Analyse du Facteur γ

Convergence et politique selon γ

blue!20	$\gamma = 0.3$	$\gamma = 0.6$	$\gamma = 0.9$
Itérations VI	$\sim$15	$\sim$35	$\sim$100
π^*(Low)	pub	pub	pub
π^*(Med)	promo	promo	promo
π^*(High)	rec	rec	rec

Valeurs $V^*(s)$ selon γ

blue!20 **État**	$\gamma = 0.3$	$\gamma = 0.6$	$\gamma = 0.9$
Low_Fast	-1.23	-2.45	-4.67
Med_Fast	18.34	22.56	35.67
High_Fast	98.12	99.45	100.00

γ change les **valeurs**
mais pas la **politique** : pub/promo/rec est **intrinsèquement optimale** $\forall \gamma$

Les états Low deviennent *plus négatifs*
quand $\gamma \uparrow$: coûts futurs d'inaction s'accumulent

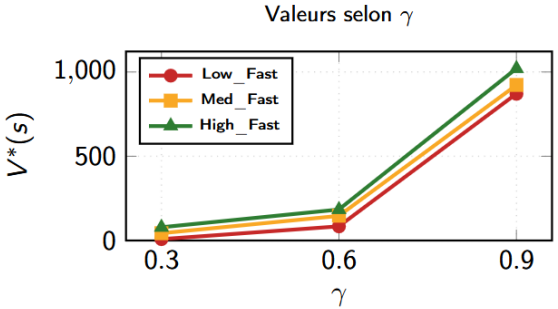


Figure : Valeurs $V^*(s)$ pour $\gamma \in \{0.3, 0.6, 0.9\}$

Interprétation économique

$\gamma = 0.3$: vision myope (revenu immédiat)
$\gamma = 0.9$: \$100 dans 10 étapes = \$34.87 auj.

En e-commerce (sessions 5–7 min) :
$\gamma = 0.9$ est le plus réaliste ✓

Ch.5 — TD(0) et TD(λ) : Prédiction de la Valeur

TD(0) — Mise à jour

$$V(s) \leftarrow V(s) + \alpha\,\delta_t$$

$$\delta_t = r_t + \gamma\,V(s_{t+1}) - V(s_t)$$

Model-free, convergence $\sim$5 000 épisodes

blue !20 **État**	$V_{\text{TD}(0)}$
High_Fast	≈ 685
High_Normal	≈ 600
High_Slow	≈ 269
Med_Fast	≈ 549
Med_Normal	≈ 400
Med_Slow	≈ 197
Low_Fast	≈ 460
Low_Normal	≈ 300
Low_Slow	≈ 134

TD(λ) — Traces d'éligibilité

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

$$E(s) \leftarrow \begin{cases} \gamma\lambda E(s) + 1 & s = s_t \\ \gamma\lambda E(s) & s \neq s_t \end{cases}$$

$$V(s) \leftarrow V(s) + \alpha\,\delta_t\,E(s)$$

TD(0) vs TD(λ)

$\lambda = 0$: TD(0), bootstrap 1 pas

$\lambda = 1$: Monte-Carlo, retour complet

$0 < \lambda < 1$: compromis biais-variance

TD(λ) propage le signal à tous les états visités — idéal pour les parcours multi-étapes

Ordre validé : Low $<$ Med $<$ High

$\bar{V}(\text{High}) = 803 > \bar{V}(\text{Med}) = 669 > \bar{V}(\text{Low}) = 590$

Ch.5 — Q-Learning : Contrôle Off-Policy

Équation de mise à jour

$$Q(s,a) \leftarrow Q(s,a) + \alpha\left[r + \gamma \max_{a'} Q(s',a') - Q(s,a)\right]$$

Off-policy : utilise $\max_{a'}$ (meilleure action théorique)

Stratégie ε-Greedy

$$a_t = \begin{cases} \arg\max_a Q(s_t,a) & \text{prob. } 1-\varepsilon \\ \text{aléatoire} & \text{prob. } \varepsilon \end{cases}$$

$\varepsilon_{\text{start}} = 0.30$, $\varepsilon_{\min} = 0.05$, $\varepsilon_{\text{decay}} = 0.9995$

Politique optimale Q-Learning

Low_* → **pub** (acquisition)
Medium_* → **promo** (conversion)
High_* → **rec** (finalisation)

Convergence $< 2\,500$ épisodes
Mean Q final : **1 900**

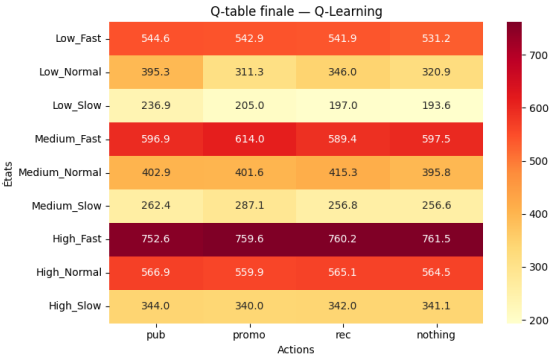


Figure : Q-Table finale

Limite : sensible au réglage de α et ε. États High_* peuvent présenter des politiques instables si récompenses mal calibrées.

Ch.5 — SARSA (On-Policy) et R-Learning (Gain Moyen)

SARSA — Mise à jour on-policy

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_t + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)]$$

Utilise $Q(s', a_{t+1})$: *action réellement choisie*

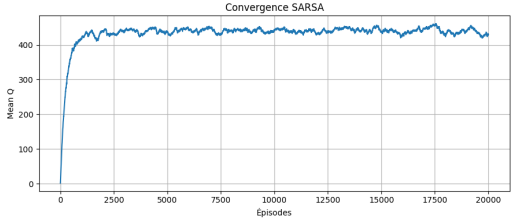


Figure : Convergence SARSA

Conv. $<$ 1 000 épisodes | Mean Q : **1 900**
Politique : pub/promo/rec ✓
Réaliste, stable, prêt pour production

R-Learning — Gain moyen ρ

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r - \rho + \max_{a'} Q(s', a') - Q(s, a) \right]$$

$$\rho \leftarrow \rho + \beta \left[r + \max_{a'} Q(s', a') - \max_{a} Q(s, a) - \rho \right]$$

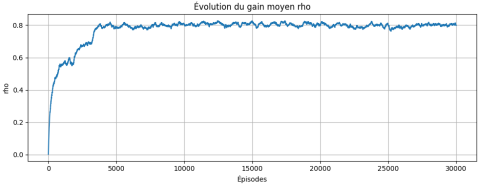


Figure : Évolution du gain moyen ρ

$\rho_{\text{final}} \approx 0.80$
Politique **nuancée** : distingue vitesse ET niveau
High_Fast $\rightarrow$ rec | High_Normal $\rightarrow$ promo

Ch.5 — Q-Learning (Off-Policy) vs SARSA (On-Policy)

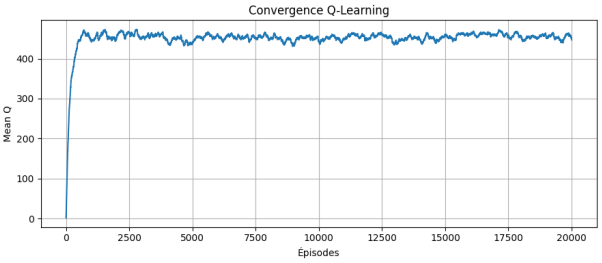


Figure : convergence Q-Learning

blue !20 **Critère**	**Q-Learning**	**SARSA**
Type	Off-policy	On-policy
Bootstrap	$\max_{a'} Q$	$Q(s', a_{t+1})$
Optimisme	Optimiste	Réaliste
Convergence	<2 500 ep.	<1 000 ep.
Mean Q final	1 900	1 900
Politique	pub/promo/rec	pub/promo/rec
Stabilité	Volatile	Stable

Q-Learning — 85/100

Mean Q : 1 900
Conv. $<$ 2 500 épisodes
Politique : pub/promo/rec
Limite : décisions non testées en réel

SARSA — 95/100 RECOMMANDÉ

Mean Q : 1 900
Conv. $<$ 1 000 épisodes
Politique : pub/promo/rec
Avantage : apprend ce qu'il exécute

Réaliste, sûr, prêt pour production

Hyperparamètres SARSA :
$\alpha = 0.1$, $\gamma = 0.9$, $\varepsilon = 0.1$ (10% exploration)
Épisodes = 20 000

Ch.5 — Comparaison des 5 Algorithmes RL

blue !20 **Critère**	**TD0**	**TDλ**	**Q-L**	**SAR**	**R-L**
Objectif	$V(s)$	$V(s)$	Q^*	Q^π	ρ
Type	Pred.	Pred.	Off	On	Off
Conv. (ep.)	5 000	500	2 500	1 000	1 500
Val. finale	700	700	1 900	1 900	98
Cohérence	–	–	100	100	30
Réalisme	60	60	70	95	40
darkgreen !70					

R-Learning — 40/100

$\rho_{\text{final}} \approx 0.80$ mais politique **incohérente** :
High_Fast $\rightarrow$ rec ✓ High_Normal $\rightarrow$ promo (?)
Couplage ρ-Q instable

Convergence des politiques

$\pi^*_{\text{VI}} \approx \pi^*_{\text{Q-L}} \approx \pi^*_{\text{SARSA}}$

3 approches différentes $\rightarrow$ même politique
$\Rightarrow$ **robustesse du MDP validée**

TD(λ) — 75/100

Conv. ultra-rapide (<500 ep.)
$\bar{V}(\text{High}) = 803 > \bar{V}(\text{Med}) = 669 > \bar{V}(\text{Low}) = 590$ ✓
Propagation globale via traces $E(s)$

Recommandation finale

SARSA pour production
TD(λ) pour prédiction rapide
Q-Learning pour exploration agressive

Idee cle : croyance implicite neuronale

Au lieu de $b(s)$ explicite $\rightarrow$

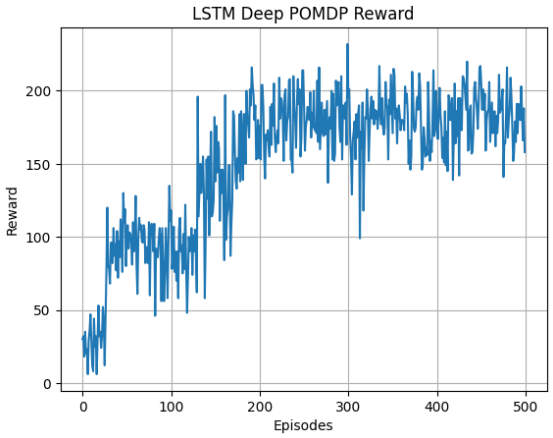
$$h_t = f_\theta(h_{t-1},\ o_t,\ a_{t-1})$$

avec f_θ = GRU ou LSTM

Politique : $\pi(a|h_t) = \text{Softmax}(W \cdot h_t)$

darkblue		
blue !8 Vitesse	Rapide	Lente
Stabilite	Stable	Bruitee
blue !8 Memoire	Court	Long
Politique	pub/promo/rec	pub/promo/rec

Validation par 7 modeles



Ch.6 — Comparaison POMDP Classique vs Deep POMDP

darkblue		
blue!8 Croyance	Explicite $b(s)$	Implicite h_t (neuronal)
Transitions	Matrices manuelles	Apprises par le reseau
blue!8 Scalabilite	Limitee (discret)	Scalable (haute dim.)
Generalisation	Non	Oui
blue!8 Mise a jour	Bayes exacte	GRU/LSTM
Donnees compl.	Difficile	Adaptee
blue!8 Politique	pub/promo/rec	pub/promo/rec

Architecture

Clic (one-hot 6D) $\rightarrow$ GRU/LSTM (dim$=64$) $\rightarrow$ croyance implicite $\rightarrow$ Q-value $\rightarrow$ action

Hyperparametres : lr$=0.001$, $\gamma = 0.9$, $\varepsilon = 0.2$, 500 episodes

Ch.6 — Vectorisation : Resultats et Insights Economiques

darkblue

yellow !15 Browsing	104.61	baseline (100%)
orange !15 Engaged	128.95	+23.3%
orange !25 HighIntent	150.32	+43.7%
green !20 Buy	**200.00**	+91.1%
red !15 Exit	−100.00	−195.5%

Hierarchie capturee

$V(\text{Exit}) \ll V(\text{Br}) < V(\text{En}) < V(\text{HI}) < V(\text{Buy})$

Ecart Buy − Exit = **300** unites

Impact critique : conversion vs abandon

Insights business

Br → **En** : +24.3 (+23.3%)
Recommandations, chatbot, essais gratuits

En → **HI** : +21.4 (+16.6%)
Upselling, nurturing, cross-sell

HI → **Buy** : +49.7 (+33.0%)
Offres flash, suppression frictions checkout

HI → **Exit** : −250.3 (!)
Relance immediate, promotion personnalisee

Avantages forme fermee

- ✓ Solution exacte, pas d'iterations
- ✓ Calcul instantane ($\mathcal{O}(n^3)$)
- ✓ Coherent avec VI ($\gamma = 0.9$)
- ✓ Interpretable par les metiers

Ch.6 — NM-POMDP : Depasser l'Hypothese Markovienne

Limite du POMDP classique

$P(s_t|s_{t-1}, o_{t-1}) = P(s_t|s_{t-1})$

Probleme : les utilisateurs ont de la memoire !

- 10 clics rapides $\neq$ 10 clics lents
- Historique long $\Rightarrow$ intention differente
- Patterns sequences importent

Definition NM-POMDP

Tuple $\langle S, A, O, h, P, R, \gamma, b_0 \rangle$

$h = \{o_0, o_1, \ldots, o_t\}$: historique complet

Equation d'optimalite :

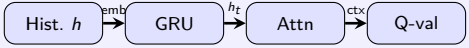
$$V^*(h) = \max_a \left[R(h,a) + \gamma \sum_{o'} P(o'|h,a) \cdot V^*(\langle h, o' \rangle) \right]$$

Approximation : $V^*(h) \approx f_\theta(h)$
avec f_θ = LSTM, GRU+Attn, ou Transformer

3 Architectures implementees

darkblue !80 Type	Mem.	Attn	//
LSTM	Excell.	Non	Moy.
green !10 GRU+Attn	Bonne	Oui	Bonne
Transformer	Moy.	Oui	Excell.

Flux d'execution (GRU+Attn)



$\gamma = 0.95$, $\varepsilon = 0.3 \rightarrow 0.05$, hidden$= 128$

Complexite Forward : $\mathcal{O}(T \cdot N^2)$
$T \approx 10$ obs, $N = 3$ etats $\Rightarrow$ tres efficace

Ch.6 — NM-POMDP : Resultats et Comparaison

darkblue

gray !15 POMDP Markovien	Discret	73.2%	Ba
LSTM	Discret	78.5%	
blue !8 GRU+Attn	Discret	82.1%	
LSTM	Continu	80.3%	
green !15 **GRU+Attn**	**Continu**	**84.7%**	

Observations cles

+11.5 pts : POMDP baseline → GRU+Attn
Variables continues > discretes : +2–4 pts
Attention boost : +4–6 pts
Continu ≈ Transformer pour ce dataset

Comparaison business (GRU+Attn vs LSTM)

Aspect	LSTM	GRU+Attn
Accuracy	78.5%	**84.7%**
Inference	5ms	**3ms**
Memoire GPU	2.1 GB	**1.8 GB**
Entrainemt.	2.5h	**2.0h**
Interpret.	Faible	**Haute**

Impact economique (100k sessions/jour)

Baseline : 8 500 conversions/jour
Avec GRU+Attn : **10 200** conversions

Uplift : +20% = +1 700 conv.
Revenu add. : **$850k/jour** (AOV $500)

Abandons mal-cibles : −54%

Interpretation Economique et Perspectives

Funnel Marketing Automatique

darkblue !80 Phase	Action	Objectif
Awareness	pub	Attirer
green !10 Consideration	promo	Convertir
Conversion	rec	Finaliser

KPIs extraits du modele

Conversion globale	6.59%
Conversion HighIntent	**16.36%** ($\times 2.5$)
Abandon Browsing	23.1%
Hesitation HI	6.99 min
Bottleneck Med$\rightarrow$High	14%$\rightarrow$34%
$\lambda_{\max}$ (convergence)	0.807

Perspectives

- **Court terme :** deployer SARSA en production, A/B testing exhaustif
- **Moyen terme :** Deep Q-Learning, Actor-Critic, Multi-armed bandits
- **Long terme :** Transfer learning, Bayesian RL, Offline RL
- HMM continu pour durees
- POMDP non-homogene
- Integration donnees d'achat temps reel

"Attirer $\rightarrow$ Convertir $\rightarrow$ Finaliser valide par 7 modeles independants."

Merci pour votre attention